

Laksmi Prita Wardhani, Valeriana Lukitosari, Endah Rokhmati
Merdika Putri, Sena Safarina, Amirul Hakam, Raden Aurelius
Andhika Viadinugroho

Matematika Statistika

Konsep dan Aplikasinya Menggunakan R

August 29, 2026

Prakata

Puji syukur penulis panjatkan kepada Tuhan Yang Maha Esa atas berkat dan limpahan nikmatnya, sehingga penyusunan Buku Matematika Statistika ini dapat terselesaikan. Tujuan dibuatnya buku ini adalah sebagai pedoman dalam melakukan kegiatan pembelajaran kuliah Matematika Statistika yang merupakan mata kuliah wajib semester 5 di program studi S1 Matematika ITS. Buku Matematika Statistika ini diharapkan dapat membantu mahasiswa memahami materi perkuliahan Matematika Statistika.

Materi yang dijelaskan pada buku ini dibagi menjadi beberapa bagian, yaitu:

1. Konvergensi Distribusi, *Limiting Distribution*, dan Teorema Limit Pusat;
2. Statistika dan Distribusi Sampling;
3. Metode Estimasi Titik;
4. Kecukupan, Ketakbiasan, dan Teori Sampel Besar;
5. Estimasi Interval;
6. Uji Hipotesis

Penulis meyakini bahwa Buku Matematika Statistika ini masih jauh dari sempurna. Oleh karena itu, penyusun mengharapkan kritik dan saran yang membangun guna penyempurnaan buku ini dimasa yang akan datang. Akhir kata, semoga buku ini bisa bermanfaat untuk mahasiswa/i program studi S1 Matematika ITS maupun semua pihak yang bisa mengaksesnya.

Surabaya, Juni 2026
Penulis

Daftar Isi

Bagian I Matematika Statistika

1	Konvergensi Distribusi, <i>Limiting Distribution</i>, dan Teorema Limit Pusat	3
1.1	Review Teori Peluang	3
1.1.1	<i>Order Statistics</i>	3
1.1.2	Fungsi Pembangkit Momen	4
1.2	Barisan dan Variabel Random	5
1.2.1	Konvergen dalam Distribusi	5
1.2.2	Konvergen Stokastik	7
1.2.3	Teorema Limit Pusat	10
1.2.4	Pendekatan Distribusi Binomial	13
1.2.5	Distribusi Normal Asimtotik	14
1.2.6	Konvergen dalam Probabilitas	16
1.2.7	Konvergen Hampir Pasti	18
	Latihan Soal	20
2	Statistik dan Distribusi Sampling	23
2.1	Review Populasi dan Sampel	23
2.2	Statistik dan Distribusi Sampling	24
2.2.1	Distribusi Sampling	24
2.2.2	Distribusi <i>Chi-square</i>	25
2.2.3	Distribusi t dan F	28
2.2.4	Distribusi Beta	29
2.3	Aproksimasi Sampel Besar	30
	Latihan Soal	31
3	Estimasi Titik	33
3.1	Motivasi	33
3.2	Metode Momen	33
3.3	Metode <i>Maximum Likelihood Estimator</i> (MLE)	35
3.4	Ukuran Kebaikan Estimator	40
3.4.1	Estimator Takbias	40
3.4.2	<i>Mean Square Error</i>	40
3.4.3	Estimator Takbias Terbaik	42
3.5	Teori Sampel Besar	46
3.6	Sifat Asimtotik MLE	48
3.7	Pojok Komputasi: MLE menggunakan Newton-Raphson	51
	Latihan Soal	54

4	Statistik Cukup	57
4.1	Statistik Cukup	57
4.2	Statistik Cukup Minimal	60
4.3	Statistik Ancillary dan Statistik Lengkap	61
4.4	Teorema Rao-Blackwell	63
	Latihan Soal	67
5	Estimasi Interval	71
5.1	Interval Konfidensi	71
5.2	Metode Pencarian Estimator Interval	73
5.2.1	Metode Pivot	74
5.2.2	Metode Umum	76
	Latihan Soal	78
6	Uji Hipotesis	81
6.1	Pengertian Uji Hipotesis	81
6.2	Tipe Kesalahan dan Fungsi Kuasa	82
6.3	Metode Uji Hipotesis	86
6.3.1	Uji Rasio Likelihood	86
6.3.2	Uji Paling Kuasa	88
	Latihan Soal	90
	Daftar Pustaka	93
	Tabel Distribusi Khusus	95
	Pembahasan Soal	97

Istilah Penting

ABC Spelled-out abbreviation and definition

BABI Spelled-out abbreviation and definition

CABR Spelled-out abbreviation and definition

Bagian I

Matematika Statistika

Bab 1

Konvergensi Distribusi, *Limiting Distribution*, dan Teorema Limit Pusat

Abstrak Bab ini akan menjelaskan kembali beberapa materi yang telah dipelajari pada mata kuliah Teori Peluang, yaitu Konvergensi Distribusi, *Limiting Distribution*, dan Teorema Limit Pusat. Secara spesifik, bab ini akan membahas tentang kekonvergensi dari barisan variabel random, dan salah satu metode yang banyak digunakan adalah Teorema Limit pusat, juga dibahas asimtotik distribusi Normal serta konvergensi Peluang, konvergensi distribusi, konvergensi Probabilitas dan konvergensi Stokastik dan sifat sifat dari konvergensi barisan variabel random.

1.1 Review Teori Peluang

1.1.1 Order Statistics

Definisi 1.1 Diberikan $X_1, X_2, \dots, X_n$ sampel variabel random dari suatu distribusi yang memiliki PDF $f(x)$ dengan support $\mathcal{S} = (a, b)$ dengan $-\infty \leq a < b \leq \infty$. Misalkan Y_1 adalah yang terkecil diantara X_i , kemudian diurutkan sedemikian hingga Y_n adalah yang terbesar diantara X_i . Atau dengan kata lain, $Y_1 < Y_2 < \dots < Y_n$ menyatakan $X_1, X_2, \dots, X_n$ yang diurutkan dari yang terkecil sampai terbesar. Maka $Y_i, i = 1, 2, \dots, n$ disebut **order statistics** ke- i dari sampel random $X_1, X_2, \dots, X_n$.

Catatan 1.1 Dalam beberapa referensi, terkadang *order statistics* ke- i dituliskan dengan $Y_i = X_{(i)}$.

Umumnya, **order statistics** ke- k dari suatu sampel variabel random berukuran n dapat dicari menggunakan teorema berikut.

Teorema 1.1 (Order statistics untuk kasus univariat) Diberikan $X_1, X_2, \dots, X_n$ sampel variabel random dari suatu distribusi yang memiliki PDF $f_X(x)$ dan CDF $F_X(x)$, dengan support $\mathcal{S} = (a, b)$ dengan $-\infty \leq a < b \leq \infty$. Maka PDF dari order statistics ke- k , yaitu Y_k , diberikan oleh persamaan

$$g_k(y_k) = \frac{n!}{(k-1)!(n-k)!} [F(y_k)]^{k-1} [1 - F(y_k)]^{n-k} f(y_k), \quad a < y_k < b.$$

Selanjutnya, CDF marginal dari order statistics ke- k diberikan oleh persamaan

$$G_k(y_k) = \sum_{j=k}^n \binom{n}{j} [F(y_k)]^j [1 - F(y_k)]^{n-j}.$$

Akibat 1.1 Diberikan $X_1, X_2, \dots, X_n$ sampel variabel random dari suatu distribusi yang memiliki PDF $f_X(x)$ dan CDF $F_X(x)$, dengan support $\mathcal{S} = (a, b)$ dengan $-\infty \leq a < b \leq \infty$. PDF dari Order statistics terkecil (dinotasikan oleh Y_1) dan terbesar (dinotasikan oleh Y_n) berturut-turut dinyatakan

oleh persamaan

$$\begin{aligned} g_1(y_1) &= n[1 - F(y_1)]^{n-1} f(y_1), \quad a < y_1 < b \\ g_n(y_n) &= n[F(y_n)]^{n-1} f(y_n), \quad a < y_n < b. \end{aligned}$$

Teorema 1.2 (Order statistics untuk kasus bivariat) Diberikan $X_1, X_2, \dots, X_n$ sampel variabel random dari suatu distribusi yang memiliki PDF $f_X(x)$ dan CDF $F_X(x)$. Maka PDF bersama dari order statistics ke- i dan j , dengan $1 \leq i < j \leq n$, adalah

$$\begin{aligned} f_{X_i, X_j}(u, v) &= \frac{n!}{(i-1)!(j-1-i)!(n-j)!} f_X(u) f_X(v) [F_X(u)]^{i-1} \\ &\quad \times [F_X(v) - F_X(u)]^{j-1-i} [1 - F_X(v)]^{n-j} \end{aligned}$$

1.1.2 Fungsi Pembangkit Momen

Definisi 1.2 (Fungsi Pembangkit Momen) Jika X adalah variabel random, maka nilai ekspektasi

$$M_X(t) = E(e^{tX})$$

disebut fungsi pembangkit momen (*moment generating function*) - selanjutnya disebut MGF - dari X .

- Untuk X variabel random diskrit:

$$M_X(t) = \sum_{i=1}^{\infty} e^{tx_i} p_X(x_i)$$

- Untuk X variabel random kontinu:

$$M_X(t) = \int_{-\infty}^{\infty} e^{tx} f_X(x) dx$$

Sifat berikut berlaku untuk sebarang variabel random yang memiliki MGF.

Teorema 1.3 Diberikan variabel random X . Jika MGF dari X ada, maka berlaku

$$E(X^r) = M_X^{(r)}(0), \quad \text{untuk setiap } r = 1, 2, \dots$$

dan

$$M_X(t) = 1 + \sum_{r=1}^{\infty} \frac{E(X^r) t^r}{r!}.$$

Teorema 1.4 Untuk sebarang konstanta real a dan b , MGF dari variabel random $aX + b$ diberikan oleh

$$M_{aX+b}(t) = e^{bt} M_X(at).$$

1.2 Barisan dan Variabel Random

Pada Bab Fungsi Variabel Random di Teori Peluang, telah dipelajari bagaimana mendapatkan distribusi dari n variabel random, misalkan $Y_n = u(X_1, \dots, X_n)$. Umumnya, Y_n dapat diperoleh dengan mudah dengan memanfaatkan sifat dari fungsi variabel random, tetapi dalam beberapa kasus khusus, Y_n tidak dapat diperoleh dengan mudah. Dalam kasus ini, dimungkinkan untuk memperoleh hasil aproksimasi yang berlaku untuk n yang besar. Hasil-hasil yang akan dibahas pada subbab berikut diperoleh berdasarkan sifat-sifat konvergen dalam distribusi dan *limiting distribution*.

1.2.1 Konvergen dalam Distribusi

Perhatikan barisan variabel random $Y_1, Y_2, \dots$ yang berhubungan dengan CDF yang berkaitan yaitu $G_1(y), G_2(y), \dots$ sedemikian hingga untuk setiap $n = 1, 2, \dots$ CDF yang berkaitan adalah

$$G_n(y) = P(Y_n \leq y)$$

Definisi 1.3 berikut membahas tentang definisi dari konvergen dalam distribusi dan *Limiting distribution*.

Definisi 1.3 Jika diketahui barisan variabel random $Y_1, Y_2, \dots$ dengan CDF $G_i(y); i = 1, 2, \dots$ dan

$$\lim_{n \rightarrow \infty} G_n(y) = G(y)$$

untuk semua nilai y dengan fungsi $G(y)$ kontinu, Maka barisan variabel random $Y_1, Y_2, \dots$ dikatakan **konvergen dalam distribusi** ke $Y \sim G(y)$, dinotasikan dengan $Y \xrightarrow{d} Y$. Selanjutnya, distribusi yang berhubungan dengan CDF $G(y)$ disebut **limiting distribution** dari Y_n .

Untuk mempermudah pemahaman, perhatikan ilustrasi berikut.

$$\begin{aligned} Y_1 &\sim G_1(y) \\ Y_2 &\sim G_2(y) \\ &\downarrow \\ Y_n &\sim G_n(y) \\ &\downarrow \text{ untuk } n \rightarrow \infty \\ Y &\sim G(y) \end{aligned}$$

Selanjutnya, perhatikan contoh berikut.

Contoh 1.1 Misalkan diketahui $X_1, X_2, \dots, X_n$ sampel random dari distribusi Uniform dengan $X_i \sim UNIF(0, 1)$. Misalkan pula $Y_n = X_{n:n}$ adalah *order statistic* terbesar. Dapatkan konvergensi dalam distribusi dan *limiting distribution* dari Y_n .

Solusi 1.1 Perlu diingat kembali bahwa CDF dari $X \sim UNIF(0, 1)$ adalah:

$$F(x) = \begin{cases} 0, & x \leq 0 \\ \frac{x - a}{b - a}, & a < x < b \\ 1, & x \geq b \end{cases}$$

Selanjutnya, perhatikan bahwa CDF dari $Y_n = X_{(n)}$ adalah $G_n(y_n) = [F(y_n)]^n$, dengan $X_i \sim UNIF(0, 1)$. Maka,

$$G_n(y) = \begin{cases} 0, & y \leq 0 \\ y^n, & 0 < y < 1 \\ 1, & y \geq 1 \end{cases}$$

Lebih lanjut,

$$\lim_{n \rightarrow \infty} G_n(y) = \begin{cases} 0, & y \leq 0 \\ 0, & 0 < y < 1 \\ 1, & y \geq 1 \end{cases}$$

Sehingga diperoleh $\lim_{n \rightarrow \infty} G_n(y) = G(y)$, dengan

$$G(y) = \begin{cases} 0, & y < 1 \\ 1, & y \geq 1 \end{cases}$$

Dengan demikian, CDF tersebut terpusat pada satu nilai yaitu $y = 1$.

Dari Contoh 1.1, diperoleh CDF dari suatu distribusi khusus yang dinamakan distribusi *degenerate*, dengan definisi sebagai berikut.

Definisi 1.4 Fungsi $G(x)$ adalah CDF dari distribusi *degenerate* di titik $x = c$ jika

$$G(x) = \begin{cases} 0, & x < c \\ 1, & x \geq c \end{cases}$$

Dengan kata lain, $G(x)$ adalah CDF dari distribusi variabel random diskrit yang memetakan probabilitas bernilai 1 di titik $x = c$ dan 0 di x lainnya.

Selanjutnya, perhatikan contoh berikut.

Contoh 1.2 Misalkan diketahui $X_1, X_2, \dots, X_n$ adalah suatu sampel acak dari distribusi eksponensial, dengan $X_i \sim EXP(\theta)$. Misalkan $Y_n = X_{(1:n)}$ adalah *order statistic* terkecil. Apakah *limiting distribution* dari Y_n ?

Solusi 1.2 Karena $X_i \sim EXP(\theta)$, maka fungsi distribusi kumulatif (CDF) dari X_i adalah

$$F(x_i) = 1 - e^{-x_i/\theta}, \quad x_i > 0,$$

sedangkan fungsi kepadatan peluang (PDF) adalah

$$f(x_i) = \frac{1}{\theta} e^{-x_i/\theta}.$$

Selanjutnya dicari CDF dari Y_n , yaitu $G_n(y)$:

$$G_n(y) = P(Y_n \leq y) = 1 - [1 - F(y)]^n.$$

Substitusi $F(y)$:

$$\begin{aligned} G_n(y) &= 1 - [1 - (1 - e^{-y/\theta})]^n \\ &= 1 - (e^{-y/\theta})^n \\ &= 1 - e^{-ny/\theta}, \quad y > 0. \end{aligned}$$

Dan untuk $y \leq 0$:

$$G_n(y) = 0.$$

Selanjutnya, tinjau limitnya:

$$\lim_{n \rightarrow \infty} G_n(y) = \begin{cases} 1, & y > 0, \\ 0, & y \leq 0. \end{cases}$$

Dengan demikian, *limiting distribution* dari Y_n adalah

$$G(y) = \begin{cases} 0, & y \leq 0, \\ 1, & y > 0, \end{cases}$$

yaitu distribusi *degenerate* di $y = 0$.

1.2.2 Konvergen Stokastik

Definisi 1.5 (Konvergen Stokastik) Suatu barisan variabel random $Y_1, Y_2, \dots$ dikatakan konvergen secara stokastik menuju sebuah konstanta c jika barisan tersebut terdistribusi terbatas pada satu nilai pada $y = c$. Artinya, barisan variabel random tersebut berdistribusi *degenerate*.

Formulasi alternatif tentang konvergensi stokastik akan dipertimbangkan dalam konsep yang lebih umum yang disebut konvergensi dalam probabilitas. Perlu diperhatikan bahwa tidak semua *limiting distribution* adalah *degenerate distribution*.

Rumusan tentang limit pada Persamaan 1.1 dan 1.2 sangat banyak berguna dalam berbagai masalah mencari *limiting distribution*.

$$\lim_{n \rightarrow \infty} \left(1 + \frac{c}{n}\right)^{nb} = e^{cb} \quad (1.1)$$

$$\lim_{n \rightarrow \infty} \left(1 + \frac{c}{n} + \frac{d(n)}{n}\right)^{nb} = e^{cb}, \text{ jika } \lim_{n \rightarrow \infty} d(n) = 0 \quad (1.2)$$

Teorema 1.5 Barisan variabel random $Y_1, Y_2, \dots$ konvergen stokastik menuju c jika dan hanya jika untuk setiap $\epsilon > 0$,

$$\lim_{n \rightarrow \infty} P[|Y_n - c| < \epsilon] = 1$$

Contoh 1.3 $X_1, X_2, \dots, X_n$ adalah sampel random dari distribusi Pareto, yaitu $X_i \sim PAR(1, 1)$, dengan CDF $F(x) = 1 - (1 + x)^{-1}; x > 0$ dan $Y_n = nX_n$. Diperoleh CDF dari Y_n yaitu

$$G_n(y) = 1 - \left(1 + \frac{y}{n}\right)^{-n}, y > 0$$

$$G(y) = \lim_{n \rightarrow \infty} G_n(y)$$

$$= \lim_{n \rightarrow \infty} 1 - \left(1 + \frac{y}{n}\right)^{-n}$$

$$= 1 - e^{-y}, y > 0$$

dan nol untuk lainnya. Jadi, $Y_n \xrightarrow{d} Y$ dengan $Y \sim EXP(1)$.

Pada bagian sebelumnya dalam mencari *limiting distribution* yang harus diketahui terlebih dahulu adalah CDF untuk n berhingga. Jika distribusi peluang tidak diketahui, maka kita bisa menggunakan *Momen Generating Function* (MGF) untuk mendapatkan *limiting distribution* dari barisan variabel random seperti Teorema 1.6 berikut

Teorema 1.6 Diketahui $Y_1, Y_2, \dots$ adalah barisan peubah acak yang masing-masing mempunyai fungsi distribusi kumulatif (CDF) $G_1(y), G_2(y), \dots$ dan fungsi pembangkit momen (MGF) $M_1(t), M_2(t), \dots$. Jika diketahui $M(t)$ adalah MGF dari suatu peubah acak dengan CDF $G(y)$, dan jika

$$\lim_{n \rightarrow \infty} M_n(t) = M(t),$$

untuk semua t pada interval $-h < t < h$, maka

$$\lim_{n \rightarrow \infty} G_n(y) = G(y),$$

untuk semua titik kontinu dari $G(y)$.

Contoh 1.4 Misalkan $X_1, X_2, \dots, X_n$ adalah suatu sampel acak berukuran n dari distribusi Bernoulli, dengan $X_i \sim \text{BIN}(1, p)$, dan misalkan $Y_n = \sum_{i=1}^n X_i$. Dapatkan limiting distribution untuk barisan Y_n .

Solusi 1.3 MGF untuk distribusi Bernoulli $X_i \sim \text{BIN}(1, p)$ adalah

$$M_i(t) = (pe^t + q)^1,$$

dengan $q = 1 - p$.

Sehingga MGF untuk Y_n sama dengan MGF dari distribusi Binomial (n, p) , yaitu

$$M_n(t) = (pe^t + q)^n.$$

Berikutnya akan dicari limiting distribution dari Y_n dengan menggunakan MGF:

$$\lim_{n \rightarrow \infty} (pe^t + q)^n.$$

Jika $n \rightarrow \infty$, $p \rightarrow 0$, dan $np = \mu$, maka

$$\begin{aligned} \lim_{n \rightarrow \infty} (pe^t + q)^n &= \lim_{n \rightarrow \infty} \left(\frac{\mu e^t}{n} + 1 - \frac{\mu}{n} \right)^n \\ &= \lim_{n \rightarrow \infty} \left(1 + \frac{\mu(e^t - 1)}{n} \right)^n \\ &= e^{\mu(e^t - 1)} \\ &= M(t). \end{aligned}$$

Hasil limit tersebut menyatakan bahwa $M(t)$ adalah MGF dari distribusi Poisson dengan parameter μ . Oleh karena itu,

$$Y_n \xrightarrow{d} Y \sim \text{Poisson}(\mu).$$

Contoh 1.5 $X_1, X_2, \dots, X_n$ adalah sampel random dari distribusi Pareto, yaitu $X_i \sim \text{PAR}(1, 1)$, dengan CDF $F(x) = 1 - (1 + x)^{-1}$; $x > 0$ dan $Y_n = nX_n$. Diperoleh CDF dari Y_n yaitu

$$\begin{aligned} G_n(y) &= 1 - \left(1 + \frac{y}{n} \right)^{-n}, \quad y > 0 \\ G(y) &= \lim_{n \rightarrow \infty} G_n(y) \\ &= \lim_{n \rightarrow \infty} 1 - \left(1 + \frac{y}{n} \right)^{-n} \\ &= 1 - e^{-y}, \quad y > 0 \end{aligned}$$

dan nol untuk lainnya. Jadi, $Y_n \xrightarrow{d} Y$ dengan $Y \sim \text{EXP}(1)$.

1.2.3 Teorema Limit Pusat

Salah satu kelebihan dari *limiting distribution* adalah kemampuannya untuk memberikan aproksimasi dari suatu distribusi ketika probabilitas dari distribusi eksak tidak diketahui. Salah satu metode untuk mendapatkan hasil ini adalah dengan menggunakan sifat dari teknik MGF, yang dijelaskan pada Teorema 1.7 berikut.

Teorema 1.7 (Teorema Limit Pusat) Jika $X_1, X_2, \dots, X_n$ sampel random dari suatu distribusi dengan mean μ dan variansi $\sigma^2 < \infty$, maka limiting distribution dari

$$Z_n = \frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n}\sigma}$$

berdistribusi normal standar untuk $n \rightarrow \infty$, atau dengan kata lain $Z_n \xrightarrow{d} Z \sim N(0, 1)$.

Bukti. Misalkan $m(t)$ adalah MGF untuk $X - \mu$, yaitu

$$m(t) = M_{X-\mu}(t),$$

dengan

$$\begin{aligned} m(0) &= 1, \\ m'(0) &= E(X - \mu) = 0, \\ m''(0) &= E((X - \mu)^2) = \sigma^2. \end{aligned}$$

Deret Maclaurin untuk $m(t)$ adalah

$$\begin{aligned} m(t) &= m(0) + m'(0)t + \frac{m''(0)}{2}t^2 + \dots \\ &= 1 + \frac{\sigma^2 t^2}{2} + \dots \end{aligned}$$

Perhatikan

$$Z_n = \frac{\sum_{i=1}^n (X_i - \mu)}{\sqrt{n}\sigma}.$$

MGF untuk Z_n adalah

$$\begin{aligned}
M_{Z_n}(t) &= E\left(e^{tZ_n}\right) \\
&= E\left(e^{\frac{t}{\sqrt{n}\sigma} \sum_{i=1}^n (X_i - \mu)}\right) \\
&= M_{\sum_{i=1}^n (X_i - \mu)}\left(\frac{t}{\sqrt{n}\sigma}\right) \\
&= \prod_{i=1}^n M_{X_i - \mu}\left(\frac{t}{\sqrt{n}\sigma}\right) \\
&= \left(M_{X - \mu}\left(\frac{t}{\sqrt{n}\sigma}\right)\right)^n \\
&= \left(m\left(\frac{t}{\sqrt{n}\sigma}\right)\right)^n.
\end{aligned}$$

Gunakan ekspansi Maclaurin:

$$\begin{aligned}
m\left(\frac{t}{\sqrt{n}\sigma}\right) &= 1 + \frac{\sigma^2}{2} \left(\frac{t}{\sqrt{n}\sigma}\right)^2 + \dots \\
&= 1 + \frac{t^2}{2n} + d(n),
\end{aligned}$$

dengan $d(n) \rightarrow 0$ saat $n \rightarrow \infty$.

Sehingga

$$M_{Z_n}(t) = \left(1 + \frac{t^2}{2n} + d(n)\right)^n.$$

Ambil limit saat $n \rightarrow \infty$:

$$\lim_{n \rightarrow \infty} M_{Z_n}(t) = e^{t^2/2} = M_Z(t),$$

yang merupakan MGF dari distribusi normal standar.

Dengan demikian,

$$Z_n \xrightarrow{d} Z \sim N(0, 1).$$

□

Contoh 1.6 Diberikan $X_1, \dots, X_n$ sampel random berdistribusi Bernoulli dengan $X_i \sim \text{BIN}(1, p)$. Didefinisikan barisan variabel random

$$Z_n = \frac{Y_n - np}{\sqrt{np(1-p)}}$$

dengan $Y_n = \sum_{i=1}^n X_i$. Jika didefinisikan $\sigma_n = \sqrt{np(1(p))}$, maka $Z_n = \frac{Y_n - np}{\sigma_n}$, sehingga

$$\begin{aligned}
M_{Z_n}(t) &= \exp [-npt/\sigma_n(pe^{t/\sigma_n} + 1 - p)^n] \\
&= \exp [-pt/\sigma_n(pe^{t/\sigma_n} + 1 - p)]^n \\
&= \left[\left(1 - \frac{pt}{\sigma_n} + \left(\frac{pt}{\sigma_n} \right)^2 + \dots \right) \left(1 + \frac{pt}{\sigma_n} + \left(\frac{pt}{\sigma_n} \right)^2 + \dots \right) \right]^n \\
&= \left[1 + \frac{t^2}{2n} + \frac{d(n)}{n} \right]^n
\end{aligned}$$

dengan $d(n) \rightarrow 0$ ketika $n \rightarrow \infty$. Oleh karena itu,

$$\lim_{n \rightarrow \infty} M_{Z_n}(t) = e^{\frac{t^2}{2}}$$

yang merupakan MGF distribusi normal standar, dan $Z_n \xrightarrow{d} Z \sim N(0, 1)$.

Contoh 1.7 Misalkan diketahui $X_1, X_2, \dots, X_n$ adalah sampel acak dari suatu distribusi uniform, dengan $X_i \sim UNIF(0, 1)$. Jika $Y_n = \sum_{i=1}^n X_i$, maka pendekatan untuk $n \rightarrow \infty$ adalah sebagai berikut.

Pertama ingat kembali bahwa jika $X \sim UNIF(a, b)$, maka

$$\begin{aligned}
E(X) &= \frac{a+b}{2}, \\
\text{Var}(X) &= \frac{(b-a)^2}{12}.
\end{aligned}$$

Diketahui bahwa

$$\begin{aligned}
E(X) &= \frac{1}{2}, \\
\text{Var}(X) &= \frac{1}{12}.
\end{aligned}$$

Selanjutnya,

$$\begin{aligned}
E(Y_n) &= E\left(\sum_{i=1}^n X_i\right) = n \cdot \frac{1}{2} = \frac{n}{2}, \\
\text{Var}(Y_n) &= n \cdot \frac{1}{12} = \frac{n}{12}.
\end{aligned}$$

Berdasarkan Teorema Limit Pusat,

$$\frac{Y_n - \frac{n}{2}}{\sqrt{\frac{n}{12}}} \xrightarrow{d} N(0, 1).$$

Sebagai contoh, untuk $n = 12$, diperoleh

$$\frac{Y_{12} - 6}{1} = Y_{12} - 6 \xrightarrow{d} N(0, 1).$$

Catatan 1.2 Berdasarkan Teorema 1.7, konvergen distribusi juga berlaku bagi barisan mean sampel $\bar{X}_n$, sehingga

$$Z_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} Z \sim N(0, 1).$$

1.2.4 Pendekatan Distribusi Binomial

Contoh 1.2 dan 1.4 menunjukkan bagaimana limiting distribution berlaku untuk berbagai distribusi. Pada Contoh 1.4 diperlihatkan bahwa suatu peubah acak Binomial $Y_n \sim \text{Bin}(n, p)$, jika n besar dan p kecil, maka pendekatannya adalah $Y_n \sim \text{Poisson}(np)$. Pada subbab ini didiskusikan pendekatan distribusi Binomial ke distribusi Normal berdasarkan prinsip Teorema Limit Pusat.

Perhatikan bahwa jika $Y_n \sim \text{Bin}(n, p)$, maka

$$\begin{aligned} E(Y_n) &= np, \\ \text{Var}(Y_n) &= npq, \end{aligned}$$

dengan $q = 1 - p$.

Pendekatan untuk n besar dan p kecil berbeda dengan pendekatan terbaik untuk $p = 0.5$, karena untuk $p = 0.5$ distribusi Y_n bersifat simetris. Pendekatan distribusi normal digunakan jika $np \geq 5$ dan $nq \geq 5$.

Contoh 1.8 Peluang seorang pemain basket untuk melakukan tembakan adalah $p = 0.5$. Jika ia melakukan 20 tembakan, berapa peluang ia untuk melakukan setidaknya sembilan tembakan?

Solusi 1.4 Peluang eksak adalah

$$\begin{aligned} P(Y_{20} \geq 9) &= 1 - P(Y_{20} \leq 8) \\ &= 1 - \sum_{y=0}^8 \binom{20}{y} (0.5)^y (0.5)^{20-y} \\ &= 0.7483. \end{aligned} \tag{1.3}$$

Selanjutnya dicari dengan pendekatan distribusi normal:

$$\begin{aligned} P(Y_{20} \geq 9) &= 1 - P(Y_{20} \leq 8) \\ &= 1 - P\left(Z \leq \frac{8 - 10}{\sqrt{5}}\right) \\ &= 1 - P(Z \leq -0.89) \\ &= 0.8133. \end{aligned} \tag{1.4}$$

Karena distribusi Binomial bersifat diskrit dan distribusi Normal bersifat kontinu, pendekatannya dapat ditingkatkan dengan melakukan koreksi kontinuitas (continuity correction). Secara khusus,

setiap probabilitas Binomial $b(y; n, p)$ dapat dipandang sebagai luas persegi panjang dengan tinggi $b(y; n, p)$ dan lebar interval $[y - 0.5, y + 0.5]$.

Sebagai ilustrasi, untuk $n = 20$, $p = 0.5$, dan $y = 7$:

$$P(Y = 7) = \binom{20}{7} (0.5)^7 (0.5)^{13} = 0.0739,$$

yang dapat didekati dengan

$$\begin{aligned} P(Y = 7) &= P(Y \leq 7.5) - P(Y \leq 6.5) \\ &= P\left(Z \leq \frac{7.5 - 10}{\sqrt{5}}\right) - P\left(Z \leq \frac{6.5 - 10}{\sqrt{5}}\right) \\ &= 0.0732. \end{aligned}$$

Dengan menggunakan koreksi kontinuitas, Persamaan 1.3 dapat didekati sebagai berikut:

$$\begin{aligned} P(Y_{20} \geq 9) &= 1 - P(Y_{20} \leq 8) \\ &= 1 - P\left(Z \leq \frac{8.5 - 10}{\sqrt{5}}\right) \\ &= 1 - P(Z \leq -0.67) \\ &= 0.7486. \end{aligned} \tag{1.5}$$

Terlihat bahwa hasil Persamaan 1.5 lebih mendekati nilai eksak (Persamaan 1.3) dibandingkan dengan Persamaan 1.4.

Secara umum, jika $Y_n \sim \text{Bin}(n, p)$ dan $a \leq b$ adalah bilangan bulat, maka

$$P(a \leq Y_n \leq b) = P\left(Z \leq \frac{(b + 0.5) - np}{\sqrt{npq}}\right) - P\left(Z \leq \frac{(a - 0.5) - np}{\sqrt{npq}}\right). \tag{1.6}$$

1.2.5 Distribusi Normal Asimtotik

Berdasarkan Teorema Limit Pusat, sampel mean dapat distandardisasi menjadi distribusi normal standar, sebagai berikut.

Definisi 1.6 (Distribusi Normal Asimtotik) Jika $Y_1, Y_2, \dots$ adalah barisan variabel random dan m dan c adalah konstanta sedemikian sehingga

$$Z_n = \frac{Y_n - m}{c/\sqrt{n}} \xrightarrow{d} Z \sim N(0, 1)$$

untuk $n \rightarrow \infty$, Maka Y_n dikatakan berdistribusi normal asimtotik dengan mean asimtotik m dan variansi asimtotik $\frac{c^2}{n}$

Contoh 1.9 Suatu sampel acak berukuran $n = 40$ dari waktu hidup peralatan elektronik mengikuti distribusi eksponensial, dengan $X_i \sim EXP(100)$. Mean dan varians dari $X_i \sim EXP(100)$ adalah

$$\begin{aligned} E(X_i) &= 100, \\ \text{Var}(X_i) &= 100^2. \end{aligned}$$

Selanjutnya dicari mean dan varians dari $\bar{X}_{40}$ sebagai berikut:

$$\begin{aligned} E(\bar{X}_{40}) &= E\left(\frac{1}{40} \sum_{i=1}^{40} X_i\right) \\ &= \frac{1}{40} \sum_{i=1}^{40} E(X_i) \\ &= \frac{1}{40} \sum_{i=1}^{40} 100 \\ &= \frac{40 \cdot 100}{40} = 100, \end{aligned}$$

$$\begin{aligned} \text{Var}(\bar{X}_{40}) &= \text{Var}\left(\frac{1}{40} \sum_{i=1}^{40} X_i\right) \\ &= \frac{1}{40^2} \text{Var}\left(\sum_{i=1}^{40} X_i\right) \\ &= \frac{1}{40^2} \sum_{i=1}^{40} \text{Var}(X_i) \\ &= \frac{1}{40^2} \cdot 40 \cdot 100^2 \\ &= \frac{100^2}{40}. \end{aligned}$$

Menurut Teorema Limit Pusat, diperoleh

$$Z_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} Z \sim N(0, 1).$$

Untuk kasus ini,

$$Z_{40} = \frac{\bar{X}_{40} - 100}{100/\sqrt{40}} \xrightarrow{d} Z \sim N(0, 1).$$

Sehingga, berdasarkan definisi distribusi asimtotik, $\bar{X}_n$ berdistribusi normal asimtotik dengan mean

$$\mu = 100$$

dan varians

$$\frac{100^2}{40} = 250.$$

Teorema 1.8 Diberikan $X_1, \dots, X_n$ adalah sampel random dari suatu distribusi kontinu dengan PDF $f(x)$ dan tidak nol pada persentil ke- p , x_p , $0 < p < 1$. Jika $\frac{k}{n} \rightarrow p$ (dengan $k - np$ terbatas), maka barisan order statistic ke- k , $X_{(k)}$ adalah berdistribusi normal asimtotik dengan mean x_p dan variansi $\frac{c^2}{n}$, dengan

$$c^2 = \frac{p(1-p)}{[f(x_p)]^2}.$$

Contoh 1.10 Misalkan $X_1, \dots, X_n$ adalah sampel random berdistribusi eksponensial, yaitu $X_i \sim EXP(1)$, dengan $f(x) = e^{-x}$ dan $F(x) = 1 - e^{-x}$, $x > 0$. Untuk n ganjil, didefinisikan $k = \frac{n+1}{2}$, sehingga $Y_k = X_{(k)}$ adalah median. Jika $p = 0.5$, maka mediannya yaitu $x_{0.5} = -\ln(0.5) = \ln(2)$, dan

$$c^2 = \frac{0.5(1-0.5)}{[f(\ln(2))]^2} = 1$$

Dengan demikian, $X_{(k)}$ berdistribusi normal asimtotik dengan mean asimtotik $x_{0.5} = \ln(2)$ dan variansi asimtotik $\frac{c^2}{n} = \frac{1}{n}$.

1.2.6 Konvergen dalam Probabilitas

Definisi 1.7 (Konvergen dalam Probabilitas) Barisan variabel random $\{X_n, n = 1, 2, \dots\}$ dikatakan konvergen dalam probabilitas ke variabel random X jika

$$\lim_{n \rightarrow \infty} P\{|X_n - X| \leq \epsilon\} = 1, \text{ untuk setiap } \epsilon > 0$$

dan dinotasikan dengan $X_n \xrightarrow{p} X$. Jenis konvergensi ini sering disebut konvergensi stokastik. Lebih lanjut, barisan variabel random $\{X_n, n = 1, 2, \dots\}$ dikatakan konvergen dalam probabilitas ke konstanta c jika

$$\lim_{n \rightarrow \infty} P\{|X_n - c| \leq \epsilon\} = 1, \text{ untuk setiap } \epsilon > 0$$

dan dinotasikan dengan $X_n \xrightarrow{p} c$.

Perhatikan bahwa definisi konvergensi dalam probabilitas sering menggunakan definisi

$$\lim_{n \rightarrow \infty} P\{|X_n - X| > \epsilon\} = 0, \text{ untuk setiap } \epsilon > 0$$

Ketaksamaan Chebychev mempunyai peran yang sangat penting dalam membuktikan konvergensi dalam probabilitas.

Teorema 1.9 (Pertidaksamaan Chebychev) Jika X adalah variabel random dengan mean μ dan variansi σ^2 , maka untuk setiap $\epsilon > 0$, berlaku

$$P\{|X - \mu| \geq \epsilon\sigma\} \leq \frac{1}{\epsilon^2}$$

Contoh 1.11 Diberikan variabel random X_n dengan PDF

$$f_n(x) = \frac{x^{n-1} e^{-nx} n^n}{\Gamma(n)}, x > 0, n = 1, 2, \dots$$

Maka diperoleh $X_n \sim GAM(n, \frac{1}{n})$ dengan $E(X_n) = n \cdot \frac{1}{n} = 1$ dan $Var(X_n) = n \cdot \frac{1}{n^2} = \frac{1}{n}$. Menggunakan pertidaksamaan Chebychev, diperoleh untuk setiap $\epsilon > 0$

$$P\{|X_n - 1| > \epsilon\} \leq \frac{1}{n\epsilon^2} \rightarrow 0 \text{ untuk } n \rightarrow \infty$$

Jadi, $X_n \xrightarrow{p} 1$.

Contoh 1.12 Untuk $n = 1, 2, \dots$, misalkan X_n variabel random sedemikian hingga

$$X_n = \begin{cases} 0 & \text{dengan probabilitas } \frac{1}{n} \\ 1 & \text{dengan probabilitas } 1 - \frac{1}{n} \end{cases}$$

Misalkan X_1 dengan probabilitas 1. Harga yang mungkin dari $|X_n - X|$ adalah 0 dan 1. Artinya,

$$|X_n - X| = \begin{cases} 0 & \text{dengan probabilitas } 1 - \frac{1}{n} \\ 1 & \text{dengan probabilitas } \frac{1}{n} \end{cases}$$

Akibatnya, fungsi distribusi dari $|X_n - X|$ adalah

$$P\{|X_n - X| \leq \epsilon\} = \begin{cases} 0, & \epsilon < 0 \\ 1 - \frac{1}{n}, & 0 \leq \epsilon < 1 \\ 1, & \epsilon \geq 1 \end{cases}$$

Sehingga diperoleh

$$\lim_{n \rightarrow \infty} P\{|X_n - X| \leq \epsilon\} = 1$$

untuk setiap $\epsilon > 0$. Jadi, $X_n \xrightarrow{p} X$.

Teorema 1.10 Jika $X_1, \dots, X_n$ adalah sampel random dari suatu distribusi dengan mean berhingga μ dan variansi σ^2 , maka barisan sampel mean konvergen dalam probabilitas menuju μ , dinotasikan dengan $\bar{X}_n \xrightarrow{p} \mu$.

Teorema 1.11 Jika $Z_n = \frac{Y_n - m}{c/\sqrt{n}} \xrightarrow{d} Z \sim N(0, 1)$, maka $Y_n \xrightarrow{p} m$.

1.2.7 Konvergen Hampir Pasti

Konvergensi hampir pasti mengacu pada kondisi di mana probabilitas bahwa urutan variabel acak konvergen ke suatu limit sama dengan satu, artinya hasil dari variabel acak tersebut mendekati limit tersebut dengan probabilitas satu. Secara formal, konvergensi hampir pasti didefinisikan sebagai berikut.

Definisi 1.8 (Konvergen hampir pasti) Misalkan $X_1, X_2, \dots, X_n$ dan X barisan variabel random yang didefinisikan pada ruang probabilitas yang sama. X_n dikatakan konvergen hampir pasti (*almost surely convergent*) ke X - dinotasikan dengan $X_n \xrightarrow{a.s} X$ jika

$$P(\lim_{n \rightarrow \infty} X_n = X) = 1.$$

Teorema-teorema berikut menjelaskan sifat penting dari konvergensi yang hampir pasti dari suatu variabel random.

Teorema 1.12 $X_n \xrightarrow{a.s} X$ jika dan hanya jika $\lim_{n \rightarrow \infty} P\{\sup_{m \geq n} |X_m - X_n| > \epsilon\} = 0$ untuk setiap $\epsilon > 0$.

Teorema 1.13 Misalkan $X_1, X_2, \dots, X_n$ barisan variabel random independen. Maka $X_n \xrightarrow{a.s} X$ jika dan hanya jika $\sum_{n=1}^{\infty} P(|X_n - X| > \epsilon) < \infty$ untuk setiap $\epsilon > 0$.

Contoh 1.13 Untuk $\alpha > 1$, misalkan $X_1, X_2, \dots, X_n$ barisan variabel random independen sedemikian sehingga

$$P(X_n = 0) = 1 - \frac{1}{n^\alpha} \text{ dan } P(X_n = n) = \frac{1}{n^\alpha}, n \geq 1$$

Perhatikan bahwa untuk $\epsilon > 0$,

$$P(|X_n| > \epsilon) = P(X_n = n) = \frac{1}{n^\alpha}$$

Sekarang,

$$\sum_{n=1}^{\infty} P(|X_n| > \epsilon) = \sum_{n=1}^{\infty} \frac{1}{n^\alpha} < \infty \text{ karena } \alpha > 1$$

Sehingga menurut teorema di atas, $X_n \xrightarrow{a.s.} 0$.

Definisi 1.9 (Konvergen dalam mean) Misalkan $X_1, X_2, \dots$ barisan variabel random yang didefinisikan pada ruang probabilitas yang sama. X_n dikatakan konvergen dalam mean ke r - dinotasikan dengan $X_n \xrightarrow{r} X$ - variabel random X untuk $n \rightarrow \infty$ jika $E(X_n - X)^r \rightarrow 0$ untuk $n \rightarrow \infty$. Jika $r = 2$, maka $X_n \xrightarrow{2} X$ disebut konvergen dalam mean kuadrat.

Catatan 1.3 Jika $X_n \xrightarrow{d} X$ untuk $n \rightarrow \infty$ dengan $X \sim N(0, 1)$, sering ditulis singkat $X_n \xrightarrow{d} N(0, 1)$.

Hubungan antara sifat konvergensi dapat dijelaskan pada teorema berikut.

Teorema 1.14 Misalkan X dan $X_1, X_2, \dots$ adalah variabel random yang didefinisikan pada ruang probabilitas yang sama, maka implikasi-implikasi berikut berlaku untuk $n \rightarrow \infty$.

$$\begin{array}{ccccc} X_n \xrightarrow{a.s.} X & \implies & X_n \xrightarrow{p} X & \implies & X_n \xrightarrow{d} X \\ & & \uparrow & & \\ & & X_n \xrightarrow{r} X & & \end{array}$$

Contoh 1.14 Misalkan $X_1, X_2, \dots$ variabel random independen sedemikian sehingga

$$P(X_n = 0) = 1 - \frac{1}{n^\alpha} \text{ dan } P(X_n = n) = \frac{1}{n^\alpha}, n \geq 1$$

Karena $P(|X_n| > \epsilon) = P(X_n = n) = \frac{1}{n^\alpha} \rightarrow 0$ untuk $n \rightarrow \infty$, maka $X_n \xrightarrow{p} 0$. Selanjutnya,

$$\sum_{n=1}^{\infty} P(|X_n| > \epsilon) = \begin{cases} < \infty & \text{jika } \alpha > 1 \\ \infty & \text{jika } \alpha \leq 1 \end{cases}$$

Artinya, $X_n \xrightarrow{p} 0$ tetapi $X_n \not\xrightarrow{a.s.} 0$ untuk $\alpha \leq 1$.

Teorema 1.15 Jika X_n dan Y_n adalah dua barisan variabel random sedemikian sehingga $X_n \xrightarrow{p} c$ dan $Y_n \xrightarrow{p} d$, maka:

1. $aX_n + bY_n \xrightarrow{p} ac + bd$
2. $X_n Y_n \xrightarrow{p} cd$
3. $X_n/c \xrightarrow{p} 1$, untuk $c \neq 0$

4. $1/X_n \xrightarrow{p} 1/c$, jika $P[X_n \neq 0] = 1$, $n, c \neq 0$
5. $\sqrt{X_n} \xrightarrow{p} \sqrt{c}$, jika $P[X_n \geq 0] = 1$

Teorema 1.16 (Teorema Slutsky) Jika X_n dan Y_n adalah dua barisan variabel random, sedemikian sehingga $X_n \xrightarrow{p} c$ dan $Y_n \xrightarrow{d} Y$, maka:

1. $X_n + Y_n \xrightarrow{d} c + Y$
2. $X_n Y_n \xrightarrow{d} cY$
3. $Y_n/X_n \xrightarrow{d} Y/c$, untuk $c \neq 0$

Teorema 1.17 Jika $Y_n \xrightarrow{d} Y$, maka untuk setiap fungsi kontinu $g(y)$, $g(Y_n) \xrightarrow{d} g(Y)$, $g(y)$ tidak bergantung pada n .

Teorema 1.18 Jika $\sqrt{n}(Y_n - m)/c \xrightarrow{d} Z \sim N(0, 1)$ dan jika $g(y)$ memiliki turunan tidak nol pada $y = m$, $g'(m) \neq 0$ maka

$$\frac{\sqrt{n}[g(Y_n) - g(m)]}{|cg'(m)|} \xrightarrow{d} Z \sim N(0, 1).$$

Latihan Soal

1.1 Misalkan $X_1, X_2, \dots, X_n$ adalah suatu sampel acak dari distribusi Pareto, dengan $X_i \sim \text{PAR}(1, 1)$. Misalkan $Y_n = nX_{(1:n)}$. Dapatkan limiting distribution dari barisan Y_n .

1.2 Kerjakan ulang soal nomor 1, dengan $Y_n = X_{(n:n)}$.

1.3 Kerjakan ulang soal nomor 1, dengan $Y_n = \frac{1}{n}X_{(n:n)}$.

1.4 Perhatikan sampel acak berukuran n dengan CDF:

$$F(x) = \begin{cases} 1 - \frac{1}{x}, & 1 \leq x < \infty, \\ 0, & \text{lainnya.} \end{cases}$$

- (a) Dapatkan CDF dari order statistic $X_{(1:n)}$.
- (b) Dapatkan limiting distribution dari $X_{(1:n)}$.
- (c) Dapatkan limiting distribution dari $X_{(1:n)}^n$.

1.5 Perhatikan sampel acak berukuran n dari suatu distribusi dengan CDF:

$$F(x) = \begin{cases} 1 - x^{-2}, & x \geq 1, \\ 0, & \text{lainnya.} \end{cases}$$

Tunjukkan apakah barisan sampel acak berikut mempunyai limiting distribution. Jika ada, tentukan *limiting distribution* nya.

- (a) $X_{(1:n)}$
- (b) $X_{(n:n)}$
- (c) $n^{-1/2}X_{(n:n)}$

1.6 Misalkan Y_i adalah berat bagasi penumpang ke- i dari suatu pesawat terbang (dalam kg). Diasumsikan berat bagasi saling independen dengan pdf $f(y_i) = \theta\beta^{-\theta}y_i^{\theta-1}$ untuk $0 < y_i < \beta$. Jika diketahui $n = 100$, $\theta = 3$, $\beta = 80$, maka

- (a) Dapatkan $E(Y_i)$ dan $Var(Y_i)$.
- (b) Dapatkan $E(\sum_{i=1}^n Y_i)$ dan $Var(\sum_{i=1}^n Y_i)$.
- (c) Dapatkan peluang total berat 100 bagasi paling sedikit 6025 kg.

1.7 Misalkan $X_1, X_2, \dots, X_n$ adalah barisan variabel acak independen berdistribusi uniform, $X_i \sim \text{UNIF}(0, \theta)$ dan diberikan $Y_n = n(\theta - X_{n:n})$.

- (a) Tunjukkan bahwa $X_{n:n}$ konvergen stokastik pada θ .
- (b) Dapatkan distribusi terbatas Y_n .

1.8 Misalkan $X_1, X_2, \dots$ adalah variabel acak berdistribusi *Poisson* dengan $X_i \sim \text{POI}(\lambda_i)$ dan $Y_n = \sum_{i=1}^n \frac{X_i - \lambda_i}{n}$. Gunakan ketidaksamaan Chebychev untuk menunjukkan bahwa barisan $Y_1, Y_2, \dots$ konvergen stokastik ke $c = 0$ untuk $n \rightarrow \infty$!

1.9 Diberikan $Z_1, Z_2, \dots, Z_n$ sampel random iid berdistribusi normal standar. Gunakan MGF untuk mencari distribusi terbatas dari $\sum_{i=1}^n \frac{Z_i + \frac{1}{n}}{\sqrt{n}}$.

1.10 Diberikan $X_1, X_2, \dots, X_n$ sampel random berdistribusi Poisson, yaitu $X_i \sim \text{POI}(\mu)$.

- (a) Tunjukkan bahwa $Y_n = \exp(-\bar{X}_n)$ konvergen secara stokastik ke $P(X = 0) = e^{-\mu}$.
- (b) Carilah distribusi normal asimtotik dari Y_n .
- (c) Tunjukkan bahwa $\bar{X}_n \exp(-\bar{X}_n)$ konvergen secara stokastik ke $P(X = 1) = \mu e^{-\mu}$.

1.11 Diberikan (a_n) barisan bilangan real. Dengan kata lain, (a_n) adalah barisan variabel random konstan (*degenerate*). Misalkan $a \in \mathbb{R}$. Tunjukkan bahwa a_n konvergen ke a ekuivalen dengan $a_n \xrightarrow{p} a$.

1.12 Misalkan W_n adalah suatu variabel random dengan mean μ dan variansi $\frac{b}{n^p}$, dengan $p > 0$, μ, b adalah konstanta. Gunakan ketidaksamaan Chebychev untuk menunjukkan bahwa $W_n \xrightarrow{p} \mu$.

1.13 Diberikan $X_1, X_2, \dots, X_n$ sampel random iid dari suatu distribusi dengan PDF

$$f(x) = \begin{cases} e^{-(x-\theta)}, & x > 0, -\infty < \theta < \infty \\ 0, & \text{lainnya} \end{cases}$$

Misalkan $Y_n = \min\{X_1, \dots, X_n\}$. Tunjukkan bahwa $Y_n \xrightarrow{p} \theta$.

Petunjuk: Cari CDF dari Y_n terlebih dahulu.

1.14 Diberikan $Y_1 < Y_2 < \dots < Y_n$ order statistics dari sampel random suatu distribusi dengan PDF $f(x) = 5x^4$, $0 < x < 1$. Cari nilai p agar $Z_n = n^p Y_1 \xrightarrow{d} Z$.

1.15 Diberikan $Y \sim \text{BIN}(n, 0.55)$. Tentukan nilai terkecil dari n agar $P\left(\frac{Y}{n} > 0.5\right) \geq 0.95$.

1.16 Diberikan $X_1, X_2, \dots, X_n$ sampel random iid berdistribusi geometri, $X_1 \sim \text{GEO}(p)$. Misalkan variabel random $Y = X_1 + X_2 + \dots + X_n$.

- (a) Dapatkan MGF dari Y .
- (b) Tentukan distribusi dari Y .

1.17 Diberikan $X_1, X_2, \dots, X_n$ sampel random iid berdistribusi eksponensial dengan mean 3, yaitu $X_i \sim \text{EXP}(3)$. Misalkan $n = 20$.

- (a) Dapatkan MGF dari $Y = \sum_{i=1}^{20} X_i$.
- (b) Tentukan distribusi dari Y .

Bab 2

Statistik dan Distribusi Sampling

Abstrak Bab ini akan memperkenalkan konsep statistik yang meliputi sampel mean dan variansi sebagai kasus khusus dan untuk mendapatkan sifat statistik tertentu yang berperan penting pada bab-bab selanjutnya.

2.1 Review Populasi dan Sampel

Diberikan populasi $X \sim f(x|\theta)$, dengan bentuk f diketahui tetapi mengandung parameter $\theta \in \Omega$.

Contoh 2.1 Perhatikan contoh-contoh berikut.

1. $X \sim f(x|\theta) = \frac{1}{\theta} e^{-\frac{x}{\theta}}, x > 0$
 $\Omega\{\theta : \theta > 0\}$
2. $X \sim p(x|\theta) = \binom{n}{x} \theta^x (1 - \theta)^{n-x}, x = 0, 1, 2, \dots$
 $\Omega\{\theta : 0 < \theta < 1\}$
3. $X \sim f(x|\alpha, \beta) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-\frac{x}{\beta}}, x \geq 0$
 $\Omega\{(\alpha, \beta) : \alpha > 0, \beta > 0\}$

Keterangan: Ω disebut ruang parameter.

Tujuan analisis adalah untuk menentukan nilai θ yang paling masuk akal (estimasi titik) atau menentukan himpunan bagian dari Ω untuk menyatakan bahwa daerah tersebut memuat θ atau tidak (uji hipotesis). Analisis yang dilakukan didasarkan dari pengamatan sampel random.

Definisi 2.1 Variabel random $X_1, X_2, \dots, X_n$ membangun sampel random pada variabel random X jika $X_1, X_2, \dots, X_n$ i.i.d.

Definisi 2.2 Misalkan n variabel random $(X_1, X_2, \dots, X_n)$ merupakan sampel random dari variabel random X . Maka sebarang fungsi $T = T(X_1, X_2, \dots, X_n)$ dari sampel disebut statistik.

Karena statistik adalah fungsi sampel, maka statistik juga merupakan variabel random. Statistik juga sering digunakan untuk meringkas data. Suatu statistik $T = T(X_1, X_2, \dots, X_n)$ bisa memberi informasi tentang parameter θ yang tidak diketahui. Dalam kasus seperti itu, statistik yang bersesuaian disebut estimator titik dari θ . Jika $E(T) = \theta$, maka T disebut estimator takbias dari θ , dan jika $T_n \xrightarrow{p} \theta$, T disebut estimator yang konsisten dari θ .

Contoh 2.2 Pandang persoalan kotak dengan m bola. Dimisalkan bola-bolanya identik kecuali nomornya dan misalkan m tidak diketahui. Untuk mengestimasi m diambil sampel random $(X_1, X_2, \dots, X_n)$ dengan pengembalian. Distribusi dari masing-masing X_i adalah $P(X = x) = \frac{1}{m}$ untuk $x = 1, 2, \dots, m$. Secara intuitif, estimator titik dari m adalah statistik $T = \max(X_1, X_2, \dots, X_n)$.

Berdasarkan contoh tersebut, muncul satu pertanyaan: seberapa 'dekat' T dengan m agar bisa disebut estimator yang 'baik'? Untuk menjawab pertanyaan ini kita harus mencari distribusi dari T . Support dari T adalah $\{1, 2, \dots, m\}$. Untuk menentukan fungsi distribusi kumulatif dari T , karena T adalah maksimum observasi X , maka kejadian $T \leq t$ untuk $1 \leq t \leq m$ adalah:

$$\{T \leq t\} = \{X_1 \leq t, \dots, X_n \leq t\} = \bigcap_{i=1}^n \{X_i \leq t\}$$

Menggunakan fakta bahwa $(X_1, X_2, \dots, X_n)$ i.i.d., maka fungsi distribusi kumulatif (CDF) T adalah

$$P(T \leq t) = \prod_{i=1}^n P(X_i \leq t) = P(X_i \leq t)^n = \left(\frac{\lfloor t \rfloor}{m}\right)^n$$

dengan $\lfloor t \rfloor$ menyatakan bilangan bulat terbesar yang lebih kecil atau sama dengan t . Sehingga untuk $0 \leq t \leq m$,

$$P(T_n \leq t) = \left(\frac{\lfloor t \rfloor}{m}\right)^n \rightarrow \begin{cases} 0 & \text{jika } t < m \\ 1 & \text{jika } t = m \end{cases}$$

Berdasarkan hasil tersebut, artinya $T_n \xrightarrow{d} m$. Selanjutnya, menggunakan sifat konvergensi ke suatu konstanta, karena $T_n \xrightarrow{d} m$, maka $T_n \xrightarrow{p} m$. Jadi T_n estimator konsisten untuk m . Perhatikan untuk kasus $E(X) = \frac{m+1}{2}$. Akibatnya $E(2\bar{X} - 1) = m$, dengan $\bar{X} = \frac{\sum_{i=1}^n X_i}{n}$. Artinya, $2\bar{X} - 1$ adalah estimator takbias untuk m .

2.2 Statistik dan Distribusi Sampling

Dalam bab ini akan dijabarkan distribusi sampling yang terkait dengan distribusi normal karena hasilnya akan membawa pada distribusi-distribusi yang memainkan peran penting dalam statistika inferensi.

2.2.1 Distribusi Sampling

Misalkan $(X_1, X_2, \dots, X_n)$ merupakan sampel random dari variabel random X . Statistik $T(X_1, X_2, \dots, X_n)$ adalah variabel random dengan distribusi yang pada dasarnya dapat dijabarkan dari distribusi gabungan $X_1, X_2, \dots, X_n$. Distribusi T sering disebut distribusi sampling statistik T karena dijabarkan melalui distribusi gabungan sampel terobservasi.

Teorema 2.1 Jika $X_i \sim N(\mu_i, \sigma_i^2)$, $i = 1, 2, \dots, n$ menyatakan n variabel random normal independen, maka:

$$Y = \sum_{i=1}^n a_i X_i \sim N\left(\sum_{i=1}^n a_i \mu_i, \sum_{i=1}^n a_i^2 \sigma_i^2\right).$$

Bukti. Misalkan $M_Y(t) = E(e^{ty})$ adalah MGF Y , maka

$$\begin{aligned} M_Y(t) &= \prod_{i=1}^n M_{X_i}(a_i t) \\ &= \prod_{i=1}^n e^{a_i \mu_i t + \frac{1}{2} a_i^2 \sigma_i^2 t^2} \\ &= \exp\left(t \sum_{i=1}^n a_i \mu_i + t^2 \sum_{i=1}^n \frac{a_i^2 \sigma_i^2}{2}\right) \end{aligned}$$

yang merupakan MGF variabel random normal dengan mean $Y \sim N(\sum_{i=1}^n a_i \mu_i, \sum_{i=1}^n a_i^2 \sigma_i^2)$ $\square$

Akibat 2.1 Jika $X_1, X_2, \dots, X_n$ menyatakan sampel random dari $N(\mu, \sigma^2)$, maka $\bar{X} \sim N(\mu, \frac{\sigma^2}{n})$.

Beberapa sifat distribusi sampling berhubungan erat dengan distribusi gamma khusus yang disebut dengan distribusi khi-kuadrat (*chi-square*).

2.2.2 Distribusi *Chi-square*

Subbab ini akan menjelaskan secara detail tentang distribusi *chi-square* dan teorema yang berkaitan dengan distribusi *chi-square*. Untuk mempermudah pemahaman tentang distribusi *chi-square*, terlebih dahulu didefinisikan Distribusi Gamma sebagai berikut.

Definisi 2.3 Variabel random X disebut berdistribusi gamma dengan parameter α dan β - dinotasikan dengan $X \sim GAM(\alpha, \beta)$ - jika

$$f(x|\alpha, \beta) = \frac{x^{\alpha-1} e^{-\frac{x}{\beta}}}{\Gamma(\alpha) \beta^\alpha}; x > 0, \alpha > 0, \beta > 0$$

Teorema 2.2 Jika $X \sim GAM(\alpha, \beta)$, maka $M_X(t) = \frac{1}{(1-\beta t)^\alpha}$, dengan $E(X) = \alpha\beta$, dan $Var(X) = \alpha\beta^2$.

Definisi 2.4 Jika $X \sim GAM(\alpha, \beta)$ dengan $\alpha = \frac{n}{2}$ dan $\beta = 2$, maka variabel random X disebut berdistribusi khi-kuadrat dengan derajat kebebasan n ditulis $\chi_{(n)}^2$. Artinya, jika $X \sim \chi_{(n)}^2$ maka $E(X) = n$, $Var(X) = 2n$, dan $M_X(t) = \frac{1}{(1-2t)^{\frac{n}{2}}}$

Teorema 2.3 Jika $X \sim GAM(\alpha, \beta)$, maka $Y = \frac{2X}{\beta} \sim \chi^2(2\alpha)$.

Bukti. Perhatikan bahwa

$$\begin{aligned} M_Y(t) &= M_{\frac{2X}{\beta}}(t) \\ &= M_X\left(\frac{2t}{\beta}\right) \\ &= (1 - 2t)^{-\frac{2\alpha}{2}} \end{aligned}$$

yang merupakan fungsi pembangkit momen distribusi khi-kuadrat dengan derajat kebebasan sama dengan 2α . $\square$

Teorema 2.4 Diberikan $X \sim \chi^2(r)$. Jika $k > -\frac{r}{2}$, maka $E(X^k)$ ada, yaitu

$$E(X^k) = \frac{2^k \Gamma(\frac{r}{2} + k)}{\Gamma(\frac{r}{2})}, \quad k > -\frac{r}{2}$$

Untuk mempermudah pemahaman, perhatikan contoh berikut.

Contoh 2.3 Diberikan X berdistribusi Gamma dengan $\alpha = \frac{r}{2}$, dengan r bilangan bulat positif, dan $\beta > 0$. Didefinisikan variabel random $Y = \frac{2X}{\beta}$. Untuk mencari PDF dari Y , digunakan teknik MGF sebagai berikut.

$$\begin{aligned} M_Y(t) &= E(e^{ty}) \\ &= E(e^{\frac{2t}{\beta}x}) \\ &= \left[1 - \frac{2t}{\beta}\right]^{-\frac{r}{2}} \\ &= [1 - 2t]^{-\frac{r}{2}} \end{aligned}$$

Diperoleh Y berdistribusi *chi-square* dengan derajat bebas r , atau dengan kata lain, $Y \sim \chi^2(r)$.

Teorema berikut menunjukkan sifat penting yang menyatakan bahwa jumlahan variabel random berdistribusi khi-kuadrat yang saling independen juga berdistribusi khi-kuadrat.

Teorema 2.5 Jika $X_i \sim \chi^2(n_i), i = 1, 2, \dots, m$ merupakan variabel random khi-kuadrat yang saling independen maka

$$V = \sum_{i=1}^m X_i \sim \chi^2\left(\sum_{i=1}^m n_i\right)$$

Bukti. Diketahui $X_i \sim \chi^2(n_i), i = 1, 2, \dots, m$ merupakan variabel random khi-kuadrat yang saling independen. Maka

$$\begin{aligned}
 M_V(t) &= (1-2t)^{-\frac{n_1}{2}} (1-2t)^{-\frac{n_2}{2}} \dots (1-2t)^{-\frac{n_m}{2}} \\
 &= (1-2t)^{-\frac{\sum_{i=1}^m n_i}{2}}
 \end{aligned}$$

yang merupakan fungsi pembangkit momen distribusi khi-kuadrat dengan derajat kebebasan $\sum_{i=1}^m n_i$. $\square$

Teorema 2.6 Jika $Z \sim N(0, 1)$, maka $Z^2 \sim \chi^2(1)$.

Bukti.

$$\begin{aligned}
 M_{Z^2}(t) &= E(e^{tz^2}) \\
 &= \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{tz^2 - \frac{z^2}{2}} dz \\
 &= \frac{1}{(1-2t)^{\frac{1}{2}}} \int_{-\infty}^{\infty} \frac{(1-2t)^{\frac{1}{2}} e^{-\frac{z^2}{2}(1-2t)}}{\sqrt{2\pi}} dz \\
 &= \frac{1}{(1-2t)^{\frac{1}{2}}}
 \end{aligned}$$

yang merupakan fungsi pembangkit momen distribusi khi-kuadrat dengan derajat kebebasan satu. $\square$

Akibat 2.2 Jika $X_1, X_2, \dots, X_n$ menyatakan sampel random dari $N(\mu, \sigma^2)$, maka

$$\begin{aligned}
 \sum_{i=1}^n \frac{(x_i - \mu)^2}{\sigma^2} &\sim \chi^2_{(n)} \\
 \frac{n(\bar{x} - \mu)^2}{\sigma^2} &\sim \chi^2_{(1)}
 \end{aligned}$$

Dari akibat diatas, telah diketahui jika $X_1, X_2, \dots, X_n$ menyatakan sampel random dari $N(\mu, \sigma^2)$, maka $\bar{X} \sim N(\mu, \frac{\sigma^2}{n})$. Perhatian berikutnya adalah distribusi dari variansi sampel $s^2 = \sum_{i=1}^n \frac{(x_i - \bar{x})^2}{n-1}$. Distribusi dari s^2 tidak bisa mengikuti secara langsung dari akibat diatas karena $X_i - \bar{X}$ tidak independen. Secara fungsional bentuk tersebut dependen karena $\sum_{i=1}^n (x_i - \bar{x}) = 0$.

Teorema 2.7 Jika $X_1, X_2, \dots, X_n$ menyatakan sampel random dari $N(\mu, \sigma^2)$, maka

1. $\bar{x}$ dan suku-suku $x_i - \bar{x}, i = 1, 2, \dots, n$ independen.
2. $\bar{x}$ dan s^2 independen.
3. $\frac{(n-1)s^2}{\sigma^2} \sim \chi^2_{(n-1)}$

2.2.3 Distribusi t dan F

Subbab ini akan menjelaskan secara detail tentang distribusi t dan F beserta dengan teorema yang berkaitan dengan kedua distribusi tersebut.

Teorema 2.8 Jika Z variabel random $N(0, 1)$, dan U variabel random $\chi^2_{(r)}$, Z dan U independen, maka

$$T = \frac{z}{\sqrt{\frac{u}{r}}}$$

mempunyai distribusi t dengan derajat kebebasan r , dengan PDF

$$f(t) = \frac{\Gamma\left[\frac{(r+1)}{2}\right]}{\sqrt{\pi r} \Gamma\left(\frac{r}{2}\right) \left(1 + \frac{t^2}{r}\right)^{\frac{(r+1)}{2}}}$$

Teorema 2.9 Jika $X_1, X_2, \dots, X_n$ menyatakan sampel random dari $N(\mu, \sigma^2)$, maka

$$\frac{\bar{x} - \mu}{\frac{s}{\sqrt{n}}} \sim t_{(n-1)}$$

Bukti. Karena $z = \sqrt{n}(\frac{\bar{x}-\mu}{\sigma}) \sim N(0, 1)$, dari teorema di atas diperoleh $v = \frac{(n-1)s^2}{\sigma^2} \sim \chi^2_{(n-1)}$. Selanjutnya, $\bar{x}$ dan s independen sehingga $\frac{\bar{x}-\mu}{\frac{s}{\sqrt{n}}} = \frac{\frac{\bar{x}-\mu}{\sigma}}{\frac{s/\sigma}{\sqrt{n}}}$ menurut teorema di atas mempunyai distribusi t dengan derajat kebebasan $n - 1$. □

Teorema 2.10 Jika U dan V variabel random independen yang masing-masing berdistribusi khikuadrat dengan derajat kebebasan r_1 dan r_2 , maka

$$F = \frac{\frac{U}{r_1}}{\frac{V}{r_2}}$$

mempunyai distribusi F dengan derajat kebebasan r_1 dan r_2 . PDF yang bersesuaian adalah

$$f(w) = \frac{\Gamma\left[\frac{(r_1+r_2)}{2}\right] \left(\frac{r_1}{r_2}\right)^{\frac{r_1}{2}} w^{\frac{r_1}{2}-1}}{\Gamma\left(\frac{r_1}{2}\right)\Gamma\left(\frac{r_2}{2}\right)\left(1 + \frac{r_1 w}{r_2}\right)^{\frac{(r_1+r_2)}{2}}}, 0 < w < \infty$$

2.2.4 Distribusi Beta

Berikut dijelaskan teorema yang menjelaskan karakteristik dari distribusi Beta.

Teorema 2.11 Jika X variabel random berdistribusi F , yaitu $X \sim F(r_1, r_2)$, maka variabel random $Y = \frac{\binom{r_1}{2}X}{1 + \binom{r_1}{2}X}$ mempunyai PDF

$$f(y|\alpha, \beta) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} y^{\alpha-1} (1-y)^{\beta-1} \quad 0 < y < 1$$

dengan $\alpha = \frac{r_1}{2}$ dan $\beta = \frac{r_2}{2}$. Selanjutnya, Y dikatakan berdistribusi Beta dengan parameter $\alpha > 0$ dan $\beta > 0$ - atau dapat dinotasikan dengan $Y \sim \text{Beta}(\alpha, \beta)$ - dengan $E(Y) = \frac{\alpha}{\alpha+\beta}$ dan $\text{Var}(Y) = \frac{\alpha\beta}{(\alpha+\beta+1)(\alpha+\beta)^2}$.

Cara lain untuk mengkonstruksi distribusi Beta adalah dengan menggunakan dua variabel random berdistribusi Gamma yang independen. Misalkan X_1 dan X_2 adalah dua variabel random independen yang memiliki distribusi Gamma dengan PDF bersama

$$h(x_1, x_2) = \frac{1}{\Gamma(\alpha)\Gamma(\beta)} x_1^{\alpha-1} x_2^{\beta-1} e^{-x_1-x_2}, \quad 0 < x_1 < \infty, \quad 0 < x_2 < \infty,$$

dan bernilai nol untuk x_1, x_2 lainnya, dengan $\alpha > 0$ dan $\beta > 0$. Misalkan $Y_1 = X_1 + X_2$ dan $Y_2 = \frac{X_1}{X_1 + X_2}$. Selanjutnya akan ditunjukkan bahwa Y_1 dan Y_2 saling independen. Ruang *support* $\mathcal{S}$, dengan mengecualikan titik-titik pada sumbu koordinat, adalah kuadran pertama dari bidang $x_1 x_2$. Selanjutnya,

$$y_1 = u_1(x_1, x_2) = x_1 + x_2$$

dan

$$y_2 = u_2(x_1, x_2) = \frac{x_1}{x_1 + x_2}$$

dapat dituliskan sebagai

$$x_1 = y_1 y_2, \quad x_2 = y_1 (1 - y_2),$$

sehingga

$$J = \begin{vmatrix} y_2 & y_1 \\ 1 - y_2 & -y_1 \end{vmatrix} = -y_1 \neq 0.$$

Transformasi tersebut bersifat satu-ke-satu dan memetakan $\mathcal{S}$ ke

$$T = \{(y_1, y_2) : 0 < y_1 < \infty, \quad 0 < y_2 < 1\}$$

pada bidang $y_1 y_2$. PDF bersama dari Y_1 dan Y_2 pada $\mathcal{S}$ adalah

$$\begin{aligned}
g(y_1, y_2) &= |y_1| \frac{1}{\Gamma(\alpha)\Gamma(\beta)} (y_1 y_2)^{\alpha-1} [y_1(1-y_2)]^{\beta-1} e^{-y_1} \\
&= \frac{y_2^{\alpha-1} (1-y_2)^{\beta-1}}{\Gamma(\alpha)\Gamma(\beta)} y_1^{\alpha+\beta-1} e^{-y_1}, \quad 0 < y_1 < \infty, \quad 0 < y_2 < 1,
\end{aligned}$$

dan bernilai nol untuk y_1, y_2 lainnya. Perhatikan bahwa variabel random Y_1 dan Y_2 independen, dengan PDF marginal dari Y_2 adalah

$$\begin{aligned}
g_2(y_2) &= \frac{y_2^{\alpha-1} (1-y_2)^{\beta-1}}{\Gamma(\alpha)\Gamma(\beta)} \int_0^\infty y_1^{\alpha+\beta-1} e^{-y_1} dy_1 \\
&= \begin{cases} \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} y_2^{\alpha-1} (1-y_2)^{\beta-1}, & 0 < y_2 < 1, \\ 0, & \text{lainnya.} \end{cases}
\end{aligned}$$

PDF marginal dari Y_2 ini adalah PDF dari distribusi Beta dengan parameter α dan β . Karena

$$g(y_1, y_2) \equiv g_1(y_1)g_2(y_2),$$

maka PDF marginal dari Y_1 adalah

$$g_1(y_1) = \begin{cases} \frac{1}{\Gamma(\alpha+\beta)} y_1^{\alpha+\beta-1} e^{-y_1}, & 0 < y_1 < \infty, \\ 0, & \text{lainnya,} \end{cases}$$

yang merupakan PDF dari distribusi Gamma dengan parameter $\alpha + \beta$ dan 1.

2.3 Aproksimasi Sampel Besar

Distribusi sampling yang telah dijelaskan pada bagian sebelumnya memiliki aproksimasi yang berlaku untuk sampel yang cukup besar.

Teorema 2.12 Jika $Y_n \sim \chi^2(n)$, maka untuk $n \rightarrow \infty$ berlaku

$$Z_n = \frac{Y_n - n}{\sqrt{2n}} \xrightarrow{d} Z \sim N(0, 1)$$

Bukti. Menggunakan Teorema Limit Pusat, karena Y_n dapat dinyatakan dalam $\sum_{i=1}^n X_i$, dengan $X_1, \dots, X_n$ iid berdistribusi *chi-square* dengan $X_i \sim \chi^2(1)$, maka diperoleh $E(X_i) = 1$ dan $Var(X_i) = 2$. $\square$

Latihan Soal

2.1 Suatu perusahaan elektronik mempunyai 10 komponen elektronik yang diuji satu per satu secara independen. Misalkan T_i adalah variabel random iid yang menyatakan lama waktu dalam hari sampai komponen elektronik ke- i gagal berfungsi, dengan $T_1 \sim EXP(100)$.

- Tentukan distribusi dari $\sum_{i=1}^1 0T_i$.
- Gunakan sifat dari distribusi *chi-square* untuk menghitung probabilitas komponen elektronik masih berfungsi sampai 1 tahun sejak pengujian dimulai.
- Hitunglah jumlah minimum komponen elektronik yang dibutuhkan jika probabilitas komponen elektronik masih berfungsi sampai 1000 hari sejak pengujian dimulai adalah 0.95.

2.2 Diberikan $X_1, \dots, X_{15}$ sampel random iid berdistribusi eksponensial, yaitu $X_i \sim EXP(\theta)$. Hitunglah c agar

$$P(c\bar{X} < \theta) = 0.95$$

dengan $\bar{X}$ adalah mean sampel.

2.3 Diberikan X variabel random sedemikian sehingga $E(X^m) = (m+1)!2^m$, $m = 1, 2, 3, \dots$. Carilah MGF dan distribusi dari X .

Petunjuk: Tuliskan deret Taylor dari MGF yang diperoleh.

2.4 Diberikan $Y_n \sim \chi^2(n)$. Gunakan MGF untuk mencari distribusi terbatas dari

$$\frac{Y_n - n}{\sqrt{2n}}$$

untuk $n \rightarrow \infty$.

2.5 Diberikan X_1, X_2, X_3 variabel random iid dengan PDF $f(x) = e^{-x}$, $0 < x < \infty$.

- Carilah distribusi dari $Y = \min\{X_1, X_2, X_3\}$.
- Carilah distribusi dari $Y = \max\{X_1, X_2, X_3\}$.

2.6 Didefinisikan D sebagai jarak (dalam meter) peluru kendali gagal mengenai target, yaitu $D = \sqrt{X_1^2 + X_2^2}$, dengan X_1, X_2 variabel random iid, $X_i \sim N(0, 25)$. Hitung $P(D \leq 12.25)$.

2.7 Diberikan $Z_1, \dots, Z_{16}$ sampel random iid berdistribusi normal standar. Misalkan $\bar{Z}$ adalah mean sampel. Hitunglah

- $P(\bar{Z} < \frac{1}{2})$
- $P(Z_1 - Z_2 < 2)$
- $P(Z_1 + Z_2 < 2)$
- $P(\sum_{i=1}^{16} Z_i^2 < 24)$
- $P(\sum_{i=1}^{16} (Z_i - \bar{Z})^2 < 24)$

2.8 Diberikan X_1 dan X_2 variabel random independen dengan $X_1 \sim \chi^2(r_1)$ dan $Y = X_1 + X_2 \sim \chi^2(r)$. Tunjukkan bahwa $X_2 \sim \chi^2(r - r_1)$.

2.9 Diberikan $X \sim BETA(a, b)$. Tentukan nilai dari $E(X^n)$.

2.10 Tentukan nilai c agar masing-masing fungsi dibawah ini merupakan PDF dari distribusi Beta.

(a) $f(x) = cx(1-x)^3, 0 < x < 1.$

(b) $f(x) = cx^4(1-x)^5, 0 < x < 1.$

(c) $f(x) = cx^2(1-x)^8, 0 < x < 1.$

2.11 Tunjukkan bahwa

$$\int_{\mu}^{\infty} \frac{1}{\Gamma(k)} z^{k-1} e^{-z} dz = \sum_{x=0}^{k-1} \frac{\mu^x e^{-\mu}}{x!}, \quad k = 1, 2, 3, \dots$$

Hasil ini menunjukkan hubungan antara CDF dari distribusi Gamma dan distribusi Poisson.

Petunjuk: Lakukan integrasi parsial sebanyak $k - 1$ kali atau peroleh anti-turunan dengan menunjukkan bahwa

$$\frac{d}{dz} \left[-e^{-z} \sum_{j=0}^{k-1} \frac{\Gamma(k)}{(k-j-1)!} z^{k-j-1} \right] = z^{k-1} e^{-z}.$$

Bab 3

Estimasi Titik

Abstrak Bab ini akan menjelaskan metode dari estimasi titik, yang terdiri dari metode momen dan metode *maximum likelihood* (MLE). Selanjutnya, pada bab ini juga akan dijelaskan ukuran kebaikan estimator seperti estimator takbias, *Mean Square Error* (MSE), dan estimator takbias terbaik, yang dilanjutkan dengan teori sampel besar dan sifat asimtotik dari MLE.

3.1 Motivasi

Jika sampling berasal dari populasi yang digambarkan melalui densitas $f(x|\theta)$, pengetahuan tentang θ menghasilkan karakteristik populasi. Oleh karenanya sangat masuk akal untuk mencari metode untuk mendapatkan estimator yang baik untuk θ .

Definisi 3.1 Suatu estimator titik adalah sebarang fungsi $T(X_1, X_2, \dots, X_n)$ dari sampel. Ini berarti sebarang statistik adalah estimator titik.

3.2 Metode Momen

Metode momen adalah metode tertua dalam menentukan estimator titik. Misalkan $X_1, X_2, \dots, X_n$ adalah sampel dari populasi dengan densitas $f(x|\theta_1, \theta_2, \dots, \theta_k)$, estimator metode momen didapat dengan menyamakan k momen sampel pertama pada k momen sampel populasi dan menyelesaikan sistem persamaan simultan yang dihasilkan. Lebih tepatnya, untuk $j = 1, \dots, k$ definisikan

$$\begin{aligned} m_1 &= \frac{1}{n} \sum_{i=1}^n X_i^1, \mu_1 = E(X^1) \\ m_2 &= \frac{1}{n} \sum_{i=1}^n X_i^2, \mu_2 = E(X^2) \\ &\vdots \\ m_k &= \frac{1}{n} \sum_{i=1}^n X_i^k, \mu_k = E(X^k) \end{aligned}$$

Momen populasi μ_j biasanya merupakan fungsi dari $\theta_1, \theta_2, \dots, \theta_k$ katakanlah $\mu_j(\theta_1, \theta_2, \dots, \theta_k)$. Estimator metode momen $(\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k)$ dari $(\theta_1, \theta_2, \dots, \theta_k)$ didapat dengan menyelesaikan sistem $(\theta_1, \theta_2, \dots, \theta_k)$ dalam bentuk $(m_1, m_2, \dots, m_k)$

$$m_1 = \mu_1(\theta_1, \theta_2, \dots, \theta_k)$$

$$m_2 = \mu_2(\theta_1, \theta_2, \dots, \theta_k)$$

$$\vdots$$

$$m_k = \mu_k(\theta_1, \theta_2, \dots, \theta_k)$$

Contoh 3.1 Misalkan $X_1, X_2, \dots, X_n$ iid $N(\mu, \sigma^2)$. Dalam hal ini, $\theta_1 = \mu$ dan $\theta_2 = \sigma^2$. Diperoleh $m_1 = \bar{x}$, $m_2 = \frac{1}{n} \sum_{i=1}^n x_i^2$, $\mu_1 = \theta$, $\mu_2 = \theta^2 + \sigma^2$. Selanjutnya, dengan menyelesaikan persamaan

$$\bar{x} = \theta \text{ dan } \frac{1}{n} \sum_{i=1}^n x_i^2 = \theta^2 + \sigma^2$$

Maka diperoleh estimator metode momen adalah

$$\hat{\theta} = \bar{x} \text{ dan } \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

Contoh 3.2 Misalkan $X_1, X_2, \dots, X_n$ iid $BIN(k, p)$, yaitu

$$P(X_i = x|p) = \binom{k}{x} p^x (1-p)^{k-x}, \quad x = 0, 1, \dots, k$$

Di sini diandaikan bahwa k dan p kedua-duanya tidak diketahui. Dengan menyamakan dua momen sampel pertama dan momen populasi didapat sistem persamaan

$$\begin{aligned} \bar{X} &= kp \\ \frac{1}{n} \sum_{i=1}^n x_i^2 &= kp(1-p) + k^2 p^2 \end{aligned}$$

yang harus diselesaikan untuk k dan p . Hasilnya $\hat{k} = \frac{\bar{x}^2}{\bar{x} - \sum \frac{(x_i - \bar{x})^2}{n}}$ dan $\hat{p} = \frac{\bar{x}}{\hat{k}}$.

Contoh 3.3 Misalkan $X_1, X_2, \dots, X_n$ adalah sampel random dari distribusi dengan PDF $f(x|\theta) = \theta x^{\theta-1}$, $0 < x < 1$. Diperoleh

$$\begin{aligned} E(x) &= \int_0^1 x \theta x^{\theta-1} dx = \theta \int_0^1 x^{\theta} dx \\ &= \frac{\theta}{\theta+1} x^{\theta+1} \Big|_0^1 = \frac{\theta}{\theta+1} \end{aligned}$$

Dengan menyamakan $E(X) = \bar{x}$, maka diperoleh $\frac{\theta}{\theta+1} = \bar{x}$ sehingga $\hat{\theta} = \frac{\bar{x}}{1-\bar{x}}$

Contoh 3.4 Misalkan $X_1, X_2, \dots, X_n$ adalah sampel random dari distribusi dengan PDF $f(x|\theta) = \theta e^{\theta x}, x > 0$. Karena $E(X) = \frac{1}{\theta}$, maka estimator metode momen adalah $\hat{\theta} = \frac{1}{\bar{x}}$.

Contoh 3.5 Misalkan observasi sampel random berasal dari distribusi seragam $(-\theta, \theta)$. Karena $E(x) = 0$, maka momen pertama tidak mempunyai informasi tentang θ . Oleh karena itu, digunakan momen kedua

$$E(X^2) = \int_{-\theta}^{\theta} \frac{x^2}{2\theta} dx = \frac{x^3}{6\theta} \Big|_{-\theta}^{\theta} = \frac{\theta^3}{3}$$

Dengan menyamakan

$$\frac{1}{n} \sum_{i=1}^n x_i^2 = \frac{\theta^3}{3}$$

Diperoleh estimator metode momen

$$\hat{\theta} = \sqrt{\frac{3}{n} \sum_{i=1}^n x_i^2}$$

3.3 Metode *Maximum Likelihood Estimator* (MLE)

Metode *maximum likelihood* adalah metode yang paling populer dalam menghasilkan estimator. Misalkan $X_1, X_2, \dots, X_n$ adalah iid sampel dari populasi dengan densitas $f(x|\theta_1, \dots, \theta_k)$. Fungsi kemungkinan (*likelihood*) didefinisikan sebagai

$$L(\underline{\theta}|\underline{x}) = L(\theta_1, \dots, \theta_k | x_1, \dots, x_n) = \prod_{i=1}^n f(x_i | \theta_1, \dots, \theta_k)$$

Definisi 3.2 Untuk setiap titik sampel $\underline{x}$ misalkan $\hat{\theta}(\underline{x})$ adalah harga parameter dimana $L(\underline{\theta}|\underline{x})$ sebagai fungsi $\underline{\theta}$ dengan menganggap $\underline{x}$ konstan mencapai maksimumnya. Estimator maksimum likelihood (MLE) dari parameter θ berdasarkan sampel $\underline{X}$ adalah $\hat{\theta}(\underline{X})$. Artinya,

$$\hat{\theta}(\underline{x}) = \arg \max L(\underline{\theta}|\underline{x})$$

Atau dengan kata lain, $\hat{\theta}(\underline{x})$ adalah nilai θ yang memaksimumkan fungsi (*likelihood*). Perhatikan bahwa dari konstruksinya, jelajah dari MLE berimpit dengan jelajah dari parameter. Secara intuitif, MLE adalah estimator yang masuk akal, karena MLE adalah titik parameter dengan sampel terobservasi yang paling mungkin terjadi. Meskipun demikian, perhatikan juga sensitivitas perubahan data. Jika fungsi *likelihood* terdiferensialkan (dalam θ_i), maka calon MLE yang mungkin adalah harga-harga $(\theta_1, \dots, \theta_k)$ sedemikian hingga

$$\frac{\partial L(\theta|\underline{x})}{\partial \theta_i} = 0, i = 1, 2, \dots, k \quad (3.1)$$

Perhatikan bahwa Persamaan 3.1 hanyalah syarat perlu untuk terjadinya maksimum. Langkah-langkah untuk mencari MLE dari suatu sampel random yang iid adalah sebagai berikut.

1. Mencari fungsi *likelihood* berdasarkan PDF dari distribusi yang diberikan.
2. Mencari bentuk natural dari fungsi *likelihood*, yaitu fungsi *log-likelihood*.
3. Mencari turunan pertama dari fungsi *log-likelihood* dan menyamakan hasil turunan pertama dengan 0 untuk mencari calon MLE $\hat{\theta}$.
4. Berdasarkan calon MLE yang diperoleh, selanjutnya dicari turunan kedua dari fungsi *log-likelihood* untuk memastikan bahwa calon MLE tersebut memaksimumkan fungsi *likelihood*.

Contoh 3.6 Misalkan $X_1, \dots, X_n$ adalah sampel random i.i.d. $N(\theta, 1)$ dan misalkan $L(\theta|\underline{x})$ menyatakan fungsi *likelihood*. Maka

$$L(\theta|\underline{x}) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(x_i - \theta)^2} = \frac{1}{(2\pi)^{n/2}} e^{-\frac{1}{2} \sum (x_i - \theta)^2}$$

Persamaan $\frac{dL(\theta|\underline{x})}{d\theta} = 0$ menghasilkan

$$\sum_{i=1}^n (x_i - \theta) = 0.$$

Karena $\hat{\theta} = \bar{x}$, maka $\bar{x}$ adalah calon MLE. Untuk membuktikan bahwa $\bar{x}$ benar-benar maksimum global, harus ditunjukkan bahwa

$$\left. \frac{d^2 L(\theta|\underline{x})}{d\theta^2} \right|_{\theta=\bar{x}} < 0$$

Selanjutnya,

$$\frac{d^2 L}{d\theta^2} = -\frac{n}{(2\pi)^{n/2}} e^{-\frac{1}{2} \sum (x_i - \theta)^2} + \frac{1}{(2\pi)^{n/2}} e^{-\frac{1}{2} \sum (x_i - \theta)^2} \left[\sum (x_i - \theta) \right]^2$$

karena

$$\left. \frac{d^2 L(\theta|\underline{x})}{d\theta^2} \right|_{\theta=\bar{x}} = -\frac{n}{(2\pi)^{n/2}} e^{-\frac{1}{2} \sum (x_i - \bar{x})^2} < 0$$

maka $\bar{x}$ adalah MLE dari θ .

Dalam banyak kasus, diferensiasi yang digunakan akan lebih mudah bekerja pada logaritma natural dari $L(\theta|\underline{x})$, yaitu $\log L(\theta|\underline{x})$ (dikenal sebagai *log-likelihood*) daripada $L(\theta|\underline{x})$ nya sendiri. Hal ini dimungkinkan karena fungsi log naik tegas pada $(0, \infty)$, yang berarti $L(\theta|\underline{x})$ dan $\log L(\theta|\underline{x})$ mempunyai ekstrim yang sama.

Catatan 3.1 Dalam beberapa referensi, penulisan $\log L(\theta|\underline{x})$ pada log-likelihood terkadang dituliskan dengan $\ln L(\theta|\underline{x})$.

Contoh 3.7 Misalkan $X_1, \dots, X_n$ adalah sampel random i.i.d. *Bernoulli*(p). Maka fungsi likelihoodnya adalah

$$L(p|\underline{x}) = \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i} = p^y (1-p)^{n-y}$$

dengan $y = \sum_{i=1}^n x_i$. Walaupun fungsi ini tidak sukar untuk diambil derivatifnya, namun akan lebih mudah untuk mengambil derivatif log likelihoodnya, yaitu

$$\log L(p|\underline{x}) = y \log p + (n-y) \log(1-p)$$

Jika $0 < y < n$, menurunkan $\log L(p|\underline{x})$ dan menyamakan dengan nol akan memberikan hasil $\hat{p} = \frac{y}{n}$. Selanjutnya, mudah dibuktikan bahwa $\frac{y}{n}$ adalah maksimum global. Untuk $y = 0$ atau $y = n$ maka

$$\log L(p|\underline{x}) = \begin{cases} n \log(1-p), & \text{jika } y = 0 \\ n \log p, & \text{jika } y = n \end{cases}$$

Dalam keadaan bagaimanapun $\log L(p|\underline{x})$ fungsi monoton dari p dan mudah dilihat bahwa $\hat{p} = \frac{y}{n} = \bar{x}$.

Hal penting yang perlu diperhatikan dalam mendapatkan MLE adalah jelajah ruang parameter, seperti yang akan ditunjukkan pada contoh berikut.

Contoh 3.8 Misalkan $X_1, \dots, X_n$ adalah sampel random i.i.d. $N(\theta, 1)$ tetapi diketahui bahwa $\theta \geq 0$. Jika tidak ada batasan pada θ , telah diketahui dari contoh sebelumnya bahwa $\bar{x}$ adalah MLE untuk θ . Tetapi jika $\bar{x} < 0$, maka harga tersebut berada di luar ruang parameter. Jika $\bar{x} < 0$, maka $L(\theta|\underline{x})$ fungsi turun dari θ untuk $\theta \geq 0$ dan mencapai maksimum untuk $\hat{\theta} = 0$. Oleh karena itu, $\hat{\theta} = \bar{x}$ jika $\bar{x} \geq 0$, dan $\hat{\theta} = 0$ jika $\bar{x} < 0$.

Contoh 3.9 Misalkan $X_1, \dots, X_n$ adalah sampel random i.i.d. distribusi seragam pada $(0, \theta)$. Diperoleh fungsi likelihoodnya adalah

$$L(\theta|\underline{x}) = \begin{cases} 0, & \text{untuk } \theta < \max_i x_i \\ \theta^{-n}, & \text{untuk } \theta \geq \max_i x_i \end{cases}$$

Karena θ^{-n} monoton turun, maka $\hat{\theta} = \max_i x_i$ adalah MLE untuk θ .

Dalam beberapa kasus, MLE belum tentu tunggal. Perhatikan contoh berikut.

Contoh 3.10 Misalkan $X_1, \dots, X_n$ adalah sampel random i.i.d. distribusi seragam pada $(\theta - \frac{1}{2}, \theta + \frac{1}{2})$.

$$f(x|\theta) = \begin{cases} 1, & \text{untuk } \theta - \frac{1}{2} \leq x \leq \theta + \frac{1}{2} \\ 0, & \text{untuk } x \text{ lainnya} \end{cases}$$

$$L(\theta|\underline{x}) = \begin{cases} 1, & \text{untuk } \max_i x_i - \frac{1}{2} \leq \theta \leq \min_i x_i + \frac{1}{2} \\ 0, & \text{untuk } x \text{ lainnya} \end{cases}$$

Jadi, setiap $\hat{\theta}$ diantara $\max_i x_i - \frac{1}{2}$ dan $\min_i x_i + \frac{1}{2}$ adalah MLE untuk θ .

Contoh 3.11 Jika $f(x|\theta) = \frac{1}{\theta} e^{-\frac{x}{\theta}}, x > 0, \theta > 0$, maka berdasarkan sampel random $X_1, X_2, \dots, X_n$, $L(\theta)$ berbentuk

$$L(\theta) = \prod_{i=1}^n \frac{1}{\theta} e^{-\frac{x_i}{\theta}}$$

$$= \frac{1}{\theta^n} e^{-\frac{\sum x_i}{\theta}}$$

$$\log L(\theta) = -n \log \theta - \frac{\sum x_i}{\theta}$$

$$\frac{d \log L(\theta)}{d\theta} = -\frac{n}{\theta} + \frac{\sum x_i}{\theta^2} = 0 \text{ memberikan } \hat{\theta} = \bar{x}$$

Selanjutnya,

$$\left. \frac{d^2 \log L(\theta)}{d\theta^2} \right|_{\hat{\theta}=\bar{x}} = -\frac{n}{\theta^2} - 2 \frac{\sum x_i}{\theta^3} \Big|_{\hat{\theta}} < 0$$

karena $\bar{x} > 0$. Jadi, $\hat{\theta} = \bar{x}$ adalah MLE untuk θ .

Contoh 3.12 Misalkan $X_1, \dots, X_n$ adalah sampel random i.i.d. dengan PDF

$$f(x|\theta) = \frac{1}{2} e^{-|x-\theta|}, -\infty < x < \infty, -\infty < \theta < \infty$$

Densitas ini dikenal sebagai distribusi Laplace atau distribusi eksponensial dobel. Log likelihood yang bersesuaian adalah

$$\log L(\theta) = -n \log 2 - \sum_{i=1}^n |x_i - \theta|$$

$$\frac{d \log L(\theta)}{d\theta} = \sum_{i=1}^n \text{sign}(x_i - \theta)$$

dengan

$$\text{sign}(t) = \begin{cases} 1, & \text{jika } t > 0 \\ 0, & \text{jika } t = 0 \\ -1, & \text{jika } t < 0 \end{cases}$$

Di sini digunakan $\frac{d}{dt}|t| = \text{sign}(t)$ yang berlaku untuk semua t , kecuali $t = 0$. Dengan menyamakan $\frac{d \log L(\theta)}{d\theta} = 0$, didapat $\hat{\theta} = \text{median}\{x_1, x_2, \dots, x_n\}$ karena median akan membuat separuh pernyataan $\sum_{i=1}^n \text{sign}(x_i - \theta)$ non positif dan separuh lainnya non negatif. Jadi, $\hat{\theta} = \text{median}\{x_1, x_2, \dots, x_n\}$ adalah MLE untuk θ .

Contoh 3.13 Misalkan $X_1 = 3$; $X_2 = 2$; $X_3 = 1$ dan $X_4 = 3$ adalah hasil pengamatan dari sampel random ukuran empat dari populasi dengan distribusi geometrik

$$p(x|\theta) = (1 - \theta)^{x-1}\theta, \quad x = 1, 2, 3, \dots$$

Tentukanlah MLE dari θ .

Solusi: Fungsi likelihood dari distribusi tersebut adalah

$$\begin{aligned} L(\theta) &= [(1 - \theta)^{3-1}\theta][(1 - \theta)^{2-1}\theta][(1 - \theta)^{1-1}\theta][(1 - \theta)^{3-1}\theta] \\ &= (1 - \theta)^5\theta^4 \\ \log L(\theta) &= 5 \log(1 - \theta) + 4 \log \theta \\ \frac{d \log L(\theta)}{d\theta} &= -\frac{5}{1 - \theta} + \frac{4}{\theta} \\ 0 &= -5\theta + 4(1 - \theta) \\ \hat{\theta} &= \frac{4}{9} \end{aligned}$$

Karena $\frac{d^2 \log L(\theta)}{d\theta^2} = -\frac{5}{(1-\theta)^2} - \frac{4}{\theta^2} \Big|_{\hat{\theta}=\frac{4}{9}} < 0$, maka $\hat{\theta} = \frac{4}{9}$ adalah MLE dari θ .

Salah satu sifat yang paling berguna dari MLE adalah sifat invariannya. Misalkan dalam hal ini kita tertarik pada estimasi $g(\theta)$ dengan $\theta \rightarrow g(\theta)$ fungsi satu-satu. Sifat invarian menyatakan bahwa jika $\hat{\theta}$ adalah MLE dari θ , maka $g(\hat{\theta})$ juga MLE dari $g(\theta)$. Misalkan $\eta = g(\theta)$, maka $g^{-1}(\eta) = \theta$. Selanjutnya,

$$\begin{aligned} L^*(\eta|\underline{x}) &= \prod_{i=1}^n f(x_i|g^{-1}(\eta)) \\ &= L(g^{-1}(\eta)|\underline{x}) \end{aligned}$$

dan $\sup_{\eta} L^*(\eta|\underline{x}) = \sup_{\eta} L(g^{-1}(\eta)|\underline{x}) = \sup_{\theta} L(\theta|\underline{x})$. Jadi, maksimum dari $\sup_{\eta} L^*(\eta|\underline{x})$ dicapai pada $\eta = g(\theta)$, yaitu $g(\hat{\theta})$ yang menunjukkan bahwa MLE dari $g(\theta)$ adalah $g(\hat{\theta})$. Secara matematis, dapat dituliskan teorema sebagai berikut.

Teorema 3.1 (Sifat Invarian MLE) Jika $\hat{\theta}$ adalah MLE dari θ , maka $g(\hat{\theta})$ adalah MLE dari $g(\theta)$.

Contoh 3.14 Diberikan $X_1, \dots, X_n$ sampel random iid dari suatu distribusi dengan PMF $p(x|p) = p(1-p)^x$, $x = 0, 1, \dots$. MLE dari p adalah $\hat{p} = \frac{1}{1+\bar{x}}$ (**Buktikan!**). Selanjutnya, jika didefinisikan $\theta = \frac{1-p}{p}$, maka menggunakan sifat invarian dari MLE, MLE dari θ adalah $\hat{\theta} = \frac{1-\hat{p}}{\hat{p}} = \bar{x}$.

3.4 Ukuran Kebaikan Estimator

Metode-metode yang dibahas pada bagian sebelumnya telah menguraikan teknik-teknik untuk memperoleh estimator titik bagi parameter. Akan tetapi, kesulitan yang muncul adalah bahwa karena biasanya kita dapat menerapkan lebih dari satu metode pada situasi tertentu, kita sering dihadapkan pada tugas untuk memilih di antara beberapa estimator. Tentu saja, mungkin saja metode-metode yang berbeda dalam memperoleh estimator dapat menghasilkan jawaban yang sama, sehingga evaluasi menjadi lebih mudah. Namun, dalam banyak kasus, metode yang berbeda akan menghasilkan estimator yang berbeda pula. Pada bagian ini akan diperkenalkan beberapa kriteria dasar untuk mengevaluasi estimator, serta ditinjau beberapa estimator berdasarkan kriteria-kriteria tersebut.

3.4.1 Estimator Takbias

Berikut adalah definisi dari estimator takbias.

Definisi 3.3 Suatu estimator dari θ - namakan $\hat{\theta}$ - disebut estimator takbias jika $E(\hat{\theta}) = \theta$.

Contoh 3.15 Diberikan $X_1, \dots, X_n$ sampel random iid berdistribusi Bernoulli dengan $X_i \sim \text{BIN}(1, p)$. Berdasarkan Contoh 3.7, telah diketahui bahwa MLE dari p adalah $\hat{p} = \bar{x}$. Selanjutnya, karena $E(X_i) = p$, maka

$$\begin{aligned} E(\hat{p}) &= E(\bar{X}) \\ &= \frac{1}{n} E\left(\sum X_i\right) \\ &= p \end{aligned}$$

Jadi, $\hat{p} = \bar{x}$ adalah estimator takbias.

3.4.2 Mean Square Error

Selanjutnya, kita definisikan *Mean Square Error* sebagai berikut.

Definisi 3.4 Kesalahan Kuadrat Rata-rata (MSE) dari estimator $T(\underline{X})$ dari parameter θ adalah fungsi θ yang didefinisikan dengan $E_{\theta}(T(\underline{X}) - \theta)^2$.

Dengan mudah dapat dilihat bahwa $E_{\theta}(T(\underline{X}) - \theta)^2 = \text{Var}(T(\underline{X})) + (\text{Bias}(T(\underline{X})))^2$ dengan $\text{Bias}(T(\underline{X})) = E_{\theta}(T(\underline{X}) - \theta)$.

Contoh 3.16 Misalkan $X_1, X_2, \dots, X_n$ adalah iid $N(\mu, \sigma^2)$ dengan $\bar{X}$ dan S^2 keduanya adalah estimator takbias untuk μ dan σ^2 . Karena

$$E(\bar{X}) = \mu \text{ dan } E(S^2) = \sigma^2$$

Maka

$$E[(\bar{X} - \mu)^2] = \text{Var}(\bar{X}) = \frac{\sigma^2}{n}$$

$$E[(S^2 - \sigma^2)^2] = \text{Var}(S^2) = \frac{2\sigma^4}{n-1}$$

Meskipun banyak estimator takbias yang masuk akal dari pandangan MSE, kita harus berhati-hati bahwa pengontrolan bias tidak otomatis menjadi pengontrolan MSE. Pada khususnya, sering terjadi timbal balik (*trade-off*) antara variansi dan bias sedemikian hingga sedikit kenaikan bias dapat ditukarkan dengan penurunan yang lebih besar pada variansi, yang hasilnya adalah perbaikan pada MSE.

Contoh 3.17 Kembali ke contoh sebelumnya, estimator alternatif dari σ^2 adalah estimator maximum likelihood $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{n-1}{n} S^2$. Dapat dilihat bahwa

$$E(\hat{\sigma}^2) = E\left(\frac{n-1}{n} S^2\right) = \frac{n-1}{n} \sigma^2$$

sehingga $\hat{\sigma}^2$ adalah estimator yang bias untuk σ^2 . Variansi $\hat{\sigma}^2$ dapat dihitung sebagai

$$\text{Var}(\hat{\sigma}^2) = \text{Var}\left(\frac{n-1}{n} S^2\right) = \left(\frac{n-1}{n}\right)^2 \text{Var}(S^2) = \frac{2(n-1)\sigma^4}{n^2}$$

Oleh karena itu, MSE dari $\hat{\sigma}^2$ adalah

$$E(\hat{\sigma}^2 - \sigma^2)^2 = \frac{2(n-1)\sigma^4}{n^2} + \left(\frac{n-1}{n}\sigma^2 - \sigma^2\right)^2 = \left(\frac{2n-1}{n^2}\right)\sigma^4$$

Sehingga diperoleh

$$E(\hat{\sigma}^2 - \sigma^2)^2 = \left(\frac{2n-1}{n^2}\right)\sigma^4 < \left(\frac{2}{n-1}\right)\sigma^4 = E(S^2 - \sigma^2)^2$$

Yang menunjukkan bahwa MSE $\hat{\sigma}^2$ lebih kecil dibandingkan dengan MSE S^2 . Jadi, dengan melakukan *trade-off* antara bias dan variansi, MSE dapat diperbaiki.

3.4.3 Estimator Takbias Terbaik

Berikut adalah definisi dari estimator takbias terbaik.

Definisi 3.5 Estimator T^* disebut estimator takbias terbaik untuk $g(\theta)$ jika $E(T^*) = g(\theta)$ dan untuk sebarang estimator lain T yang memenuhi $E(T) = g(\theta)$ maka berlaku $Var(T^*) < Var(T)$ untuk setiap θ . T^* disebut "estimator takbias variansi minimum seragam" atau *uniform minimum variance unbiased estimator* (UMVUE) dari $g(\theta)$.

Contoh 3.18 Misalkan $X_1, X_2, \dots, X_n$ adalah iid $POI(\lambda)$ dan misalkan $\bar{X}$ dan S^2 masing-masing adalah mean dan variansi sampel. Telah diketahui bahwa

$$E(\bar{X}) = E(S^2) = \lambda$$

Jadi, keduanya adalah estimator takbias untuk λ . Untuk kasus ini, tidak cukup hanya membandingkan $Var(\bar{X})$ dan $Var(S^2)$ karena untuk setiap konstanta a , $T(\bar{X}, S^2) = a\bar{X} + (1-a)S^2$ adalah estimator takbias untuk λ . Jadi dalam hal ini ada tidak terhingga estimator takbias.

Contoh ini menunjukkan bahwa untuk menentukan UMVUE, diperlukan penanganan yang menyeluruh (*comprehensive approach*). Salah satunya adalah melalui batas bawah Cramer-Rao (CRLB) sebagai berikut.

Misalkan dalam melakukan estimasi $g(\theta)$ dari densitas $f(x|\theta)$ kita dapat menentukan batas bawah variansi dari setiap estimator takbias, katakanlah $B(\theta)$. Bila kemudian kita dapat menemukan estimator takbias T^* sedemikian hingga $Var(T^*) = B(\theta)$, maka berarti didapatkan UMVUE.

Teorema 3.2 Misalkan $X_1, X_2, \dots, X_n$ adalah sampel dengan densitas $f(x|\theta)$ dan misalkan $T(\underline{X}) = T(X_1, \dots, X_n)$ adalah sebarang estimator dengan $E(T(\underline{X}))$ terdiferensialkan dalam θ . Andaikan PDF bersama $f(\underline{x}|\theta) = f(x_1, \dots, x_n|\theta)$ memenuhi

$$\frac{d}{d\theta} \int \cdots \int h(\underline{x}) f(\underline{x}|\theta) d\mathbf{x} = \int \cdots \int h(\underline{x}) \frac{d}{d\theta} f(\underline{x}|\theta) d\mathbf{x} \quad (3.2)$$

untuk setiap fungsi $h(\underline{x})$ dengan $E|h(\underline{x})| < \infty$, maka

$$Var(T(\underline{X})) \geq \frac{\left(\frac{d}{d\theta} E_\theta(T(\underline{X}))\right)^2}{E_\theta\left(\left(\frac{\partial \log f(\underline{x}|\theta)}{\partial \theta}\right)^2\right)}$$

Akibat 3.1 (CRLB kasus iid) Misalkan $X_1, X_2, \dots, X_n$ adalah sampel iid dengan densitas $f(x|\theta)$, dan misalkan $T(\underline{X}) = T(X_1, \dots, X_n)$ adalah sebarang estimator dengan $E(T(\underline{X}))$ fungsi θ yang terdiferensialkan. Jika PDF bersama $f(\underline{x}|\theta) = \prod f(x_i|\theta)$ memenuhi Persamaan 3.2, maka

$$\text{Var}(T(\underline{X})) \geq \frac{\left(\frac{d}{d\theta} E_{\theta}(T(\underline{X}))\right)^2}{n E_{\theta} \left(\left(\frac{\partial \log f(x|\theta)}{\partial \theta} \right)^2 \right)}$$

Salah satu alternatif dalam mencari CRLB adalah dengan menyelidiki apakah distribusi variabel random tersebut merupakan keluarga eksponensial atau bukan. Terlebih dahulu dijelaskan definisi dari keluarga eksponensial sebagai berikut.

Definisi 3.6 (Keluarga Eksponensial) Keluarga PDF (atau PMF) $f(x|\theta)$ (atau $p(x|\theta)$) disebut keluarga eksponensial jika PDF dapat dituliskan dalam bentuk

$$f(x|\theta) = h(x)c(\theta) \exp\left(\sum_{i=1}^k w_i(\theta)t_i(x)\right), x \in S$$

dengan $h(x) \geq 0$, $t_1(x), \dots, t_k(x)$ adalah fungsi real dari x yang tidak bergantung pada θ , $c(\theta)$ dan $w_1(\theta), \dots, w_k(\theta)$ adalah fungsi real dari parameter θ (bisa berupa vektor), dan S adalah support dari X .

Catatan 3.2 Dalam beberapa referensi, terkadang digunakan istilah kelas eksponensial reguler (*regular exponential class* - REC) untuk menyatakan keluarga eksponensial.

Untuk menunjukkan bahwa suatu PDF (atau PMF) merupakan keluarga eksponensial, maka kita perlu mengidentifikasi fungsi-fungsi $h(x)$, $t_i(x)$, $c(\theta)$, $w_i(\theta)$ yang memenuhi bentuk fungsi seperti pada Definisi 3.6.

Contoh 3.19 Diketahui $X \sim \text{BIN}(n, \theta)$. Maka

$$\begin{aligned} f(x|\theta) &= \binom{n}{x} \theta^x (1-\theta)^{n-x}, x = 0, 1, \dots, n \\ &= \binom{n}{x} (1-\theta)^n \left(\frac{\theta}{1-\theta}\right)^x \\ f(x|\theta) &= \binom{n}{x} (1-\theta)^n \exp\left[x \log\left(\frac{\theta}{1-\theta}\right)\right] \end{aligned}$$

Perhatikan bahwa $h(x) = \binom{n}{x}$, $c(\theta) = (1-\theta)^n$, $t_1(x) = x$, dan $w_1(\theta) = \log\left(\frac{\theta}{1-\theta}\right)$. Jadi, X adalah keluarga eksponensial.

Contoh 3.20 Diketahui $X \sim N(\mu, \sigma^2)$. Maka

$$\begin{aligned}
 f(x|\mu, \sigma^2) &= \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), -\infty < x < \infty \\
 &= \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{\mu^2}{2\sigma^2}\right) \exp\left(-\frac{x^2}{2\sigma^2} + \frac{\mu x}{\sigma^2}\right)
 \end{aligned}$$

Perhatikan bahwa $h(x) = 1$, $c(\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp(-\frac{\mu^2}{2\sigma^2})$, $t_1(x) = -\frac{x^2}{2}$, $w_1(\mu, \sigma^2) = \frac{1}{\sigma^2}$, $t_2(x) = x$, dan $w_2(\mu, \sigma^2) = \frac{\mu}{\sigma^2}$. Jadi, X adalah keluarga eksponensial.

Contoh 3.21 Diketahui $X \sim POI(\lambda)$. Dapat ditunjukkan bahwa X adalah keluarga eksponensial. **(Bukti diserahkan kepada pembaca!)**

Dari penjelasan mengenai keluarga eksponensial diatas, diperoleh lemma untuk mencari CRLB untuk kasus keluarga eksponensial sebagai berikut.

Lema 3.1 Jika $f(x|\theta)$ memenuhi

$$\frac{d}{d\theta} E_{\theta} \left(\frac{d}{d\theta} \log f(x|\theta) \right) = \int \frac{d}{d\theta} \left[\left(\frac{d}{d\theta} \log f(x|\theta) \right) f(x|\theta) \right] dx$$

(benar untuk kasus keluarga eksponensial), maka

$$E \left(\left(\frac{\partial \log f(x|\theta)}{\partial \theta} \right)^2 \right) = -E \left(\frac{d^2 \log f(x|\theta)}{d\theta^2} \right) \quad (3.3)$$

Persamaan 3.3 biasa disebut sebagai Informasi Fischer.

Contoh 3.22 Misalkan $X_1, X_2, \dots, X_n$ sampel random iid berdistribusi Poisson dengan $\lambda > 0$. Telah diketahui bahwa $T(\underline{X}) = \bar{X}$ adalah MLE dari λ , sehingga $T'(\underline{X}) = 1$. Lebih lanjut, distribusi Poisson adalah keluarga eksponensial, maka diperoleh

$$\begin{aligned}
 -nE \left(\frac{d^2 \log f(x|\theta)}{d\lambda^2} \right) &= -nE \left(\frac{d^2}{d\lambda^2} \log \left(\frac{e^{-\lambda} \lambda^x}{x!} \right) \right) \\
 &= -nE \left(\frac{d^2}{d\lambda^2} (-\lambda + x \log \lambda - \log x!) \right) \\
 &= -nE \left(-\frac{x}{\lambda^2} \right) \\
 &= \frac{n}{\lambda}
 \end{aligned}$$

Dengan demikian, untuk sebarang estimator takbias $T(\underline{X})$ harus berlaku $Var(T(\underline{X})) \geq \frac{1}{n}$. Karena $Var(\bar{X}) = \frac{1}{n}$, maka $\bar{X}$ adalah UMVUE dari λ .

Contoh 3.23 Misalkan $X_1, X_2, \dots, X_n$ sampel random iid berdistribusi Uniform dengan PDF $f(x|\theta) = \frac{1}{\theta}$, $0 < x < \theta$. Karena $\frac{d \log f(x|\theta)}{d\theta} = -\frac{1}{\theta}$, maka

$$E\left(\left(\frac{\partial \log f(x|\theta)}{\partial \theta}\right)^2\right) = \frac{1}{\theta^2}$$

Teorema Cramer-Rao mengindikasikan bahwa bila T adalah sebarang estimator takbias dari θ , maka

$$\text{Var}(T) \geq \frac{\theta^2}{n}$$

Selanjutnya, akan dicari estimator yang takbias dan variansinya lebih kecil. Sebagai dugaan pertama pandang statistik cukup $Y = \max(X_1, \dots, X_n)$. PDF dari Y adalah $f(y|\theta) = \frac{ny^{n-1}}{\theta^n}, 0 < y < \theta$, sehingga $E(Y) = \int_0^\theta \frac{ny^{n-1}}{\theta^n} dy = \frac{n}{n+1}\theta$. Ini menunjukkan bahwa $\frac{n+1}{n}Y$ adalah estimator takbias untuk θ . Selanjutnya,

$$\begin{aligned} \text{Var}\left(\frac{n+1}{n}Y\right) &= \left(\frac{n+1}{n}\right)^2 \text{Var}(Y) \\ &= \left(\frac{n+1}{n}\right)^2 \left[E(Y^2) - \left(\frac{n}{n+1}\theta\right)^2 \right] \\ &= \left(\frac{n+1}{n}\right)^2 \left[\frac{n}{n+2}\theta^2 - \left(\frac{n}{n+1}\theta\right)^2 \right] \\ &= \frac{\theta^2}{n(n+2)} < \frac{\theta^2}{n} \end{aligned}$$

Artinya, estimator tersebut tidak memenuhi CRLB.

Contoh 3.24 Misalkan $X_1, X_2, \dots, X_n$ sampel random iid berdistribusi $N(\mu, \sigma^2)$ dan pandang estimasi σ^2 dengan μ tidak diketahui. PDF Normal memenuhi teorema Cramer-Rao dan termasuk keluarga eksponensial, sehingga

$$\frac{d^2}{d(\sigma^2)^2} \log \left(\frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2} \frac{(x-\mu)^2}{\sigma^2}} \right) = \frac{1}{2\sigma^4} - \frac{(x-\mu)^2}{\sigma^6}$$

dan

$$-E \left(\frac{\partial^2}{\partial(\sigma^2)^2} \log f(x|\mu, \sigma^2) \right) = -E \left(\frac{1}{2\sigma^4} - \frac{(x-\mu)^2}{\sigma^6} \right) = \frac{1}{2\sigma^4}.$$

Jadi, setiap estimator takbias T dari σ^2 harus memenuhi

$$\text{Var}(T) \geq \frac{2\sigma^4}{n}$$

Telah diketahui bahwa $\text{Var}(S) = \frac{2\sigma^4}{n-1}$, sehingga S^2 tidak memenuhi CRLB.

Syarat pencapaian CRLB sebenarnya cukup sederhana. Mengingat bahwa batas bawah terjadi dari pemakaian ketaksamaan Cauchy-Schwarz, maka syarat pencapaian batas bawah tersebut adalah syarat kesamaan dalam ketaksamaan Cauchy-Schwarz. Perhatikan juga bahwa akibat berikut merupakan alat berguna, karena secara implisit memberikan cara untuk mendapatkan estimator takbias terbaik.

Akibat 3.2 Misalkan $X_1, X_2, \dots, X_n$ adalah iid dengan $f(x|\theta)$ memenuhi syarat-syarat Teorema Cramer-Rao. Misalkan $L(\theta|\underline{x}) = \prod_{i=1}^n f(x_i|\theta)$ adalah fungsi likelihood. Jika $T(\underline{X}) = T(X_1, \dots, X_n)$ adalah sebarang estimator takbias dari $g(\theta)$, maka $T(\underline{X})$ memenuhi CRLB jika hanya jika

$$a(\theta)[T(\underline{x}) - g(\theta)] = \frac{d \log L(\theta|\underline{x})}{d\theta}$$

untuk suatu fungsi $a(\theta)$.

3.5 Teori Sampel Besar

Pada bagian sebelumnya telah dipelajari terkait dengan metode estimasi titik menggunakan metode Momen dan MLE. Selanjutnya, pada bagian ini akan dipelajari Teori Sampel Besar dari Estimasi Titik, yaitu konsistensi estimator.

Definisi 3.7 (Estimator Konsisten) Barisan estimator $T_n = T_n(X_1, \dots, X_n)$ adalah barisan estimator konsisten untuk parameter θ , jika untuk setiap $\epsilon > 0$ dan untuk setiap $\theta \in \Omega$,

$$\lim_{n \rightarrow \infty} P(|T_n - \theta| < \epsilon) = 1$$

yang ekuivalen dengan

$$\lim_{n \rightarrow \infty} P(|T_n - \theta| > \epsilon) = 0.$$

Contoh 3.25 Misalkan $X_1, \dots, X_n$ i.i.d. $N(\theta, 1)$ dan pandang barisan $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$. Perhatikan bahwa $\bar{X}_n \sim N(\theta, \frac{1}{n})$, sehingga

$$P(|\bar{X}_n - \theta| < \epsilon) = \int_{\theta-\epsilon}^{\theta+\epsilon} \left(\frac{n}{2\pi}\right)^{1/2} e^{-\frac{n}{2}(\bar{x}_n - \theta)^2} d\bar{x}_n.$$

Dengan transformasi, didapatkan

$$P(-\epsilon\sqrt{n} < Z < \epsilon\sqrt{n}) \rightarrow 1 \text{ untuk } n \rightarrow \infty.$$

Jadi, $\bar{X}_n$ adalah barisan estimator konsisten untuk θ .

Secara umum, perhitungan mendetail seperti di atas tidak perlu dilakukan untuk membuktikan konsistensi. Untuk suatu estimator T_n , pertidaksamaan Chebychev menyatakan

$$P(|T_n - \theta| > \epsilon) \leq \frac{E[(T_n - \theta)^2]}{\epsilon^2},$$

sehingga syarat cukup agar T_n konsisten adalah

$$\lim_{n \rightarrow \infty} E[(T_n - \theta)^2] = 0.$$

Berdasarkan hasil tersebut, dapat didefinisikan Konsisten dalam MSE sebagai berikut.

Definisi 3.8 (Konsisten dalam MSE) Barisan estimator $T_n = T_n(X_1, \dots, X_n)$ adalah barisan estimator konsisten dalam MSE untuk parameter θ , jika untuk setiap $\epsilon > 0$ dan untuk setiap $\theta \in \Omega$,

$$\lim_{n \rightarrow \infty} E[(T_n - \theta)^2] = 0.$$

Definisi 3.9 (Ketakbiasan Asimtotik) Barisan estimator $T_n = T_n(X_1, \dots, X_n)$ adalah barisan estimator yang takbias secara asimtotik (*asymptotically unbiased*) untuk parameter θ , jika untuk setiap $\theta \in \Omega$

$$\lim_{n \rightarrow \infty} E(T_n) = \theta$$

Selanjutnya, perhatikan bahwa

$$\begin{aligned} E[(T_n - \theta)^2] &= E[(T_n - E(T_n) + E(T_n) - \theta)^2] \\ &= E[(T_n - E(T_n))^2] + [E(T_n) - \theta]^2 \\ &= \text{Var}(T_n) + [\text{Bias}(T_n)]^2 \end{aligned}$$

Sehingga diperoleh teorema sebagai berikut.

Teorema 3.3 Jika T_n adalah barisan estimator untuk parameter θ yang memenuhi:

1. $\lim_{n \rightarrow \infty} \text{Var}(T_n) = 0$,
2. $\lim_{n \rightarrow \infty} \text{Bias}(T_n) = 0$,

maka T_n adalah barisan estimator konsisten untuk θ .

Teorema 3.4 Barisan estimator $T_n = T_n(X_1, \dots, X_n)$ untuk parameter θ adalah estimator yang konsisten dalam MSE jika dan hanya jika estimator tersebut takbias secara asimtotik dan $\lim_{n \rightarrow \infty} \text{Var}(T_n) = 0$.

Bukti. Perhatikan bahwa

$$MSE(T_n) = \text{Var}(T_n) + [E(T_n) - \theta]^2$$

Karena $\text{Var}(T_n)$ dan $[E(T_n) - \theta]^2$ nonnegatif, jika $MSE(T_n) \rightarrow 0$ maka $\text{Var}(T_n) \rightarrow 0$ dan $E(T_n) \rightarrow \theta$ ketika $n \rightarrow \infty$. Sebaliknya cukup jelas. $\square$

Contoh 3.26 Kembali ke contoh sebelumnya dimana $\bar{X}_n \sim N(\theta, \frac{1}{n})$. Karena $E(\bar{X}_n) = \theta$ dan $\text{Var}(\bar{X}_n) = \frac{1}{n}$, maka $\bar{X}_n$ barisan estimator yang konsisten.

Teorema 3.5 Misalkan $T_n = T_n(X_1, \dots, X_n)$ adalah barisan estimator yang konsisten dari θ . Misalkan $a_1, a_2, \dots$ dan $b_1, b_2, \dots$ barisan konstanta yang memenuhi

1. $\lim_{n \rightarrow \infty} a_n = 1$
2. $\lim_{n \rightarrow \infty} b_n = 0$

Maka barisan $U_n = a_n T_n + b_n$ adalah barisan estimator yang konsisten.

Teorema 3.6 Misalkan $X_1, \dots, X_n$ sampel random iid dari $f(x|\theta)$ dan misalkan $L(\theta) = \prod_{i=1}^n f(x_i|\theta)$ adalah fungsi likelihood. Misalkan $\hat{\theta}$ adalah MLE dari θ dan $g(\theta)$ adalah fungsi kontinu dari θ . Dengan syarat-syarat reguler tertentu pada $f(x|\theta)$, maka untuk setiap $\epsilon > 0$ berlaku

$$\lim_{n \rightarrow \infty} P(|g(\hat{\theta}) - g(\theta)| \geq \epsilon) = 0$$

Artinya, $g(\hat{\theta})$ estimator konsisten untuk $g(\theta)$.

Hasil ini menunjukkan bahwa MLE adalah estimator konsisten dari parameternya dan ini adalah kasus yang dapat dilihat bahwa metode untuk mendapatkan estimator menjamin sifat optimal.

3.6 Sifat Asimtotik MLE

Dalam keadaan tertentu, dapat ditunjukkan bahwa estimator kemungkinan maksimum atau MLE mempunyai sifat-sifat yang diinginkan. Secara spesifik, bila syarat-syarat reguler tertentu dipenuhi, maka penyelesaian persamaan likelihood $\hat{\theta}_n$ mempunyai sifat-sifat sebagai berikut.

1. $\hat{\theta}_n$ eksis dan unik,
2. $\hat{\theta}_n$ konsisten untuk θ ,
3. $\hat{\theta}_n$ berdistribusi normal asimtotis dengan mean asimtotis θ dan variansi

$$\frac{1}{n E \left[\left(\frac{\partial}{\partial \theta} \log f(x|\theta) \right)^2 \right]}$$

4. $\hat{\theta}_n$ efisien secara asimtotis. Artinya, $Var(\hat{\theta}_n)$ secara asimtotis sama dengan CRLB dari θ .

Jadi, untuk n besar, dapat diperoleh aproksimasi

$$\hat{\theta}_n \sim N(\theta, CRLB)$$

Selanjutnya, perhatikan teorema berikut.

Teorema 3.7 Jika $\frac{\sqrt{n}(Y_n - m)}{c} \xrightarrow{d} N(0, 1)$ dan jika $g(y)$ fungsi dengan derivatif tak nol di $y = m$, yaitu $g'(m) \neq 0$, maka

$$\frac{\sqrt{n}(g(Y_n) - g(m))}{|cg'(m)|} \xrightarrow{d} N(0, 1)$$

Berdasarkan Teorema 3.7, jika $g(\theta)$ fungsi θ dengan derivatif tidak nol, maka $g(\hat{\theta}_n)$ juga berdistribusi normal asimtotis dengan mean $g(\theta)$ dan variansi $(g'(\theta))^2$ CRLB. Perhatikan juga bahwa variansi asimtotis dari $g(\hat{\theta}_n)$ sama dengan CRLB untuk variansi estimator takbias dari $g(\theta)$, yang berarti $g(\hat{\theta}_n)$ juga efisien secara asimtotis.

Contoh 3.27 Misalkan $X_1, X_2, \dots, X_n$ sampel random berukuran n dari populasi dengan fungsi kepadatan probabilitas

$$f(x|\theta) = \frac{1}{\theta} e^{-\frac{x}{\theta}}, x > 0, \theta > 0.$$

Telah diketahui bahwa MLE dari θ adalah $\hat{\theta} = \bar{x}$. Hasil asimtotis yang sama bisa didapatkan dari sifat-sifat di atas atau dari Teorema Limit Pusat. Berdasarkan Teorema Limit Pusat, $\hat{\theta} = \bar{x}$ berdistribusi normal asimtotis dengan mean θ dan variansi $\frac{\theta^2}{n}$. Hasil ini sesuai dengan sifat asimtotis MLE dengan CRLB $\frac{\theta^2}{n}$.

Dalam hal ini, telah diketahui pula distribusi eksak dari $\hat{\theta} = \bar{x}$ karena

$$\frac{2n\hat{\theta}}{\theta} \sim \chi^2_{(2n)}$$

yang konsisten dengan normal asimtotis

$$\frac{\sqrt{n}(\hat{\theta} - \theta)}{\theta} \sim N(0, 1)$$

karena variabel khi-kuadrat terstandarisasi mempunyai distribusi limit normal standar. Misalkan kita tertarik untuk mengestimasi

$$R = R(t, \theta) = P(X > t) = \exp\left(-\frac{t}{\theta}\right)$$

Hampiran variansi $\hat{R} = \exp\left(-\frac{t}{\theta}\right)$ diberikan oleh variansi asimtotik

$$\begin{aligned} \text{Var}(\hat{R}) &= \left[\frac{\partial}{\partial \theta} R(t, \theta) \right]^2 \left(\frac{\theta^2}{n} \right) \\ &= \left[\exp\left(-\frac{t}{\theta}\right) \cdot \left(\frac{t}{\theta^2} \right) \right]^2 \left(\frac{\theta^2}{n} \right) \\ &= \frac{\left[\exp\left(-\frac{t}{\theta}\right) \cdot \left(\frac{t}{\theta} \right) \right]^2}{n} \\ &= \frac{[R(\log R)]^2}{n} \end{aligned}$$

Jadi, untuk n besar, secara hampiran

$$\hat{R} \sim N\left(R, \frac{[R(\log R)]^2}{n}\right).$$

Contoh 3.28 Misalkan $X_1, X_2, \dots, X_n$ sampel random berdistribusi Pareto $(1, \theta)$.

$$f(x|\theta) = \theta(1+x)^{-\theta-1}, x > 0, \theta > 0$$

$$L(\theta) = \prod_{i=1}^n \theta(1+x)^{-\theta-1}$$

$$= \theta^n \prod_{i=1}^n (1+x)^{-\theta-1}$$

$$\log L(\theta) = n \log \theta - (\theta + 1) \sum_{i=1}^n \log(1+x_i)$$

dari persamaan *log-likelihood* tersebut, diperoleh

$$\frac{d}{d\theta} \log L(\theta) = \frac{n}{\theta} - \sum_{i=1}^n \log(1+x_i)$$

$$0 = \frac{n}{\theta} - \sum_{i=1}^n \log(1+x_i)$$

$$\hat{\theta} = \frac{n}{\sum_{i=1}^n \log(1+x_i)}$$

Untuk mendapatkan CRLB, perhatikan bahwa

$$\begin{aligned} \log f(x|\theta) &= \log \theta - (\theta + 1) \log(1+x) \\ \frac{\partial \log f(x|\theta)}{\partial \theta} &= \frac{1}{\theta} - \log(1+x) \end{aligned}$$

sehingga

$$CRLB = \frac{1}{nE\left(\frac{1}{\theta} - \log(1+x)\right)^2}$$

Untuk menghitung pernyataan terakhir, akan lebih mudah bila dilakukan transformasi

$$y = \log(1+x) \sim EXP\left(\frac{1}{\theta}\right)$$

Akibatnya,

$$\begin{aligned} E(\log(1+x)) &= \frac{1}{\theta} \\ E\left(\frac{1}{\theta} - \log(1+x)\right)^2 &= Var(\log(1+x)) = \frac{1}{\theta^2} \\ Var(\hat{\theta}) &= CRLB = \frac{\theta^2}{n} \end{aligned}$$

dan secara hampiran, $\hat{\theta} \sim N(\theta, \frac{\theta^2}{n})$

3.7 Pojok Komputasi: MLE menggunakan Newton-Raphson

Selain menggunakan pendekatan analitik, MLE dapat pula dicari dengan menggunakan pendekatan numerik, salah satunya adalah dengan menggunakan Newton-Raphson, dimana metode ini mengaproksimasi suatu fungsi f dengan diberikan sebarang titik x_k . Menggunakan deret Taylor, aproksimasi kuadratik dari f - namakan q - dapat dituliskan dalam persamaan berikut.

$$q(x) = f(x_k) + f'(x_k)(x - x_k) + \frac{1}{2}f''(x_k)(x - x_k)^2 \quad (3.4)$$

Titik x_{k+1} diambil ketika turunan pertama dari q bernilai nol, maka diperoleh $f'(x_k) + \frac{1}{2}f''(x_k)(x_{k+1} - x_k) = 0$, sehingga

$$x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)} \quad (3.5)$$

dengan x_k adalah iterasi ke- k dari metode Newton-Raphson, $f'(x_k)$ adalah turunan pertama fungsi f dengan $x = x_k$, dan $f''(x_k)$ adalah turunan kedua fungsi f dengan $x = x_k$. Secara umum, untuk fungsi multivariabel, metode Newton-Raphson dapat dituliskan dalam persamaan

$$\mathbf{x}_{k+1} = \mathbf{x}_k - H^{-1}(\mathbf{x})\Delta(\mathbf{x}) \quad (3.6)$$

dengan $\mathbf{x} = (x_1, x_2, \dots, x_n)$ adalah vektor dari nilai x_i , $\Delta(\mathbf{x})$ adalah vektor gradien dari $\mathbf{x}$, dan $H(\mathbf{x})$ adalah matriks Hessian dari $\mathbf{x}$.

Perlu diperhatikan bahwa metode ini hanya dapat digunakan pada fungsi yang diferensiabel dua kali (*twice differentiable*). Teorema berikut menjamin konvergensi dari metode Newton-Raphson jika titik awal yang dipilih cukup dekat dengan nilai optimum dari fungsi tersebut.

Teorema 3.8 Diberikan fungsi $f : \mathbb{R} \rightarrow \mathbb{R}$ yang diferensiabel dua kali. Dimisalkan metode Newton-Raphson yang didefinisikan sebagai

$$x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)}. \quad (3.7)$$

Misalkan $\bar{x}$ sedemikian sehingga $f'(\bar{x}) = 0$ dan $f''(\bar{x}) \neq 0$. Misalkan pula x_1 adalah titik awal yang cukup dekat dengan $\bar{x}$ sehingga terdapat konstanta $k_1, k_2 > 0$ dengan $k_1 k_2 < 1$. Maka metode Newton-Raphson akan konvergen ke $\bar{x}$ jika untuk setiap x yang memenuhi $|x - \bar{x}| \leq |x_1 - \bar{x}|$ berlaku

1. $\frac{1}{|f''(x)|} \leq k_1$
2. $\frac{|f(\bar{x}) - f'(x) - f''(x)(\bar{x} - x)|}{(\bar{x} - x)} \leq k_2$

Untuk mempermudah pemahaman, perhatikan contoh berikut.

Contoh 3.29 Diberikan $X_1, \dots, X_n$ sampel random iid berdistribusi Poisson dengan mean λ . Secara analitik, telah diketahui bahwa MLE dari λ adalah $\hat{\lambda} = \bar{x}$ (**Buktikan!**). Sekarang, untuk mencari MLE dari λ secara numerik, misalkan kita mempunyai data bilangan random berdistribusi Poisson sebanyak n dengan mean λ , kemudian dilakukan pencarian MLE dengan metode Newton-Raphson dengan nilai awal λ_0 . Kode R berikut mengimplementasikan pencarian MLE dari λ dengan menggunakan Newton-Raphson.

```
#MLE Poisson
#PDF : f(x|theta) = (exp(-theta)*(theta^(x))/factorial(x))

#theta=t
loglik=expression(log((exp(-t)*(t^(x))/factorial(x))))
dbt=D(loglik,"t") #Turunan pertama dari loglik - vektor gradien
dbtt=D(dbt,"t") #Turunan kedua dari loglik - matriks hessian

nr.poi=function(n,t_asli,t,iter=100)
{
  #n = Jumlah data random berdistribusi Poisson
  #t_asli = nilai theta (lambda) yang sesungguhnya
  #t = nilai iterasi awal
  #iter = jumlah iterasi

  x=rpois(n,t_asli)
  x.mean=mean(x)
  par.hat=matrix(0,1,1)
  estimasi=c(rep(NULL,iter+1))
  selisih=c(rep(NULL,iter+1))
  estimasi[1]=t
  selisih[1]=abs(t-x.mean)
  for(i in 1:iter)
  {
    dbt=(exp(-t) * (t^((x) - 1) * (x)) - exp(-t) *
      ↪ (t^(x)))/factorial(x)/(exp(-t) * (t^(x))/factorial(x))
```

```

dbtt=(exp(-t) * (t^(((x) - 1) - 1) * ((x) - 1) * (x)) - exp(-t) *
↳ (t^((x) - 1) * (x)) - (exp(-t) * (t^((x) - 1) * (x)) - exp(-t) *
↳ (t^(x))))/factorial(x)/(exp(-t) * (t^(x))/factorial(x)) - (exp(-t)
↳ * (t^((x) - 1) * (x)) - exp(-t) * (t^(x)))/factorial(x) * ((exp(-t)
↳ * (t^((x) - 1) * (x)) - exp(-t) * (t^(x)))/factorial(x))/(exp(-t) *
↳ (t^(x))/factorial(x))^2

sdbt=sum(dbt)
sdbtt=sum(dbtt)

#matriks hessian
h=matrix(sdbtt,1,1)

#vektor gradien
g=matrix(sdbt,1,1)

#parameter
par=matrix(t,1,1)
par.hat=par-solve(h)%*%g
t=par.hat[1,]
estimasi[i+1]=t
selisih[i+1]=t-x.mean
}
cat("Data ini dibangkitkan dengan distribusi Poisson dengan
↳ mean",t_asli,"\n")
tabel=data.frame(estimasi,selisih)
rownames(tabel)=(c("Inisiasi",1:iter))
print(x)
print(tabel)
cat("Nilai MLE sesungguhnya adalah :",x.mean,"\n")
cat("Nilai estimator untuk teta adalah",t,"\n")
}

nr.poi(n=100,t_asli=6,t=8,iter=10)

```

Sebagai contoh, misalkan dibangkitkan 100 data berdistribusi Poisson dengan mean 6, nilai iterasi awal 8, dan jumlah iterasi sebanyak 10, diperoleh MLE dari λ secara numerik dengan menggunakan Newton-Raphson sebagai berikut.

```
## Data ini dibangkitkan dengan distribusi Poisson dengan mean 6
## [1] 5 8 5 9 10 2 6 9 6 6 10 6 7 6 3 9 4 2 5 10 9 7 7 13 7
## [26] 7 6 6 5 3 11 9 7 8 2 6 8 4 5 4 3 5 5 5 4 3 4 6 4 9
## [51] 2 5 8 3 6 4 3 8 9 5 7 3 5 4 8 6 8 8 8 5 8 7 7 0 6
## [76] 4 5 7 5 3 4 7 5 8 3 5 12 9 9 4 3 7 5 7 5 4 8 3 6 6
##      estimasi      selisih
## Inisiasi 8.000000 2.030000e+00
## 1        5.279732 -6.902680e-01
## 2        5.890189 -7.981071e-02
## 3        5.968933 -1.066960e-03
## 4        5.970000 -1.906872e-07
## 5        5.970000 -5.329071e-15
## 6        5.970000 0.000000e+00
## 7        5.970000 0.000000e+00
## 8        5.970000 0.000000e+00
## 9        5.970000 0.000000e+00
## 10       5.970000 0.000000e+00
## Nilai MLE sesungguhnya adalah : 5.97
## Nilai estimator untuk teta adalah 5.97
```

Latihan Soal

3.1 Diberikan X_i sampel random berukuran n dari suatu distribusi dengan PDF $f(x|\theta) = \frac{1}{\theta}$, $0 < x \leq \theta$ dan 0 untuk x lainnya.

- Carilah MLE dari θ (namakan $\hat{\theta}$). Apakah $\hat{\theta}$ merupakan estimator takbias?
- Carilah estimator momen dari θ (namakan $\tilde{\theta}$). Apakah $\tilde{\theta}$ merupakan estimator takbias?
- Bandingkan MSE dari $\hat{\theta}$ dan $\tilde{\theta}$. Mana estimator yang lebih baik?
- Berdasarkan hasil dari bagian (a) dan (b), apakah estimator tersebut konsisten dalam MSE?

3.2 Diberikan X_i sampel random iid berukuran 9 dari distribusi normal dengan mean μ dan standar deviasi 3.

- Carilah CRLB untuk estimator takbias μ .
- Apakah MLE dari μ , yaitu $\hat{\mu} = \bar{X}$ adalah UMVUE?
- Apakah MLE dari persentil ke-95 adalah UMVUE?

3.3 Diberikan $X_1, \dots, X_n$ sampel random berdistribusi Poisson, yaitu $X_i \sim POI(\mu)$.

- Carilah CRLB untuk estimator takbias μ .
- Carilah CRLB untuk estimator takbias $\theta = e^{-\mu}$.
- Carilah UMVUE untuk μ .
- Carilah MLE dari θ (namakan $\hat{\theta}$). Apakah $\hat{\theta}$ merupakan estimator takbias?
- Berdasarkan hasil dari bagian (d), apakah $\hat{\theta}$ takbias secara asimtotik?
- Tunjukkan bahwa $\tilde{\theta} = \left[\frac{n-1}{n} \right]^{\sum X_i}$ adalah estimator yang takbias. Apakah estimator tersebut takbias secara asimtotik?

3.4 Diberikan $X_1, \dots, X_n$ sampel random iid berdistribusi Bernoulli dengan $X_i \sim BIN(1, p)$.

- (a) Tunjukkan bahwa Variansi dari MLE, yaitu $Var(\hat{p})$ memenuhi CRLB.
 (b) Untuk $n \geq 4$, tunjukkan bahwa $X_1 X_2 X_3 X_4$ adalah estimator takbias untuk p^4 , kemudian gunakan fakta ini untuk mencari UMVUE untuk p^4 .

3.5 Diberikan X_1, X_2, X_3 sampel random berdistribusi Uniform dengan $X_i \sim UNIF(\theta, 2\theta)$ dengan $\theta > 0$.

- (a) Carilah estimator momen dari θ .
 (b) Carilah MLE dari θ , yaitu $\hat{\theta}$, kemudian cari nilai k sedemikian sehingga $k\hat{\theta}$ merupakan estimator takbias.
 (c) Berdasarkan hasil dari bagian (a) dan (b), apakah estimator tersebut konsisten dalam MSE?

3.6 Diberikan $X_1, \dots, X_n$ sampel random iid dari suatu distribusi dengan PMF $p(x|p) = p(1-p)^x$, $x = 0, 1, \dots$.

- (a) Carilah MLE dari p .
 (b) Carilah MLE dari $\theta = \frac{1-p}{p}$
 (c) Carilah CRLB untuk estimator takbias θ .
 (d) Apakah MLE dari θ merupakan UMVUE?
 (e) Apakah MLE dari θ konsisten dalam MSE?
 (f) Carilah distribusi asimtotik untuk MLE dari θ .

3.7 Diberikan $X_1, \dots, X_n$ sampel random iid berdistribusi Normal dengan mean θ dan variansi σ^2 diketahui, tetapi $-\infty < \theta < \infty$.

- (a) Tunjukkan bahwa MLE dari θ adalah $\bar{X}$.
 (b) Jika nilai θ dibatasi menjadi $0 \leq \theta < \infty$, tunjukkan bahwa MLE dari θ adalah $\hat{\theta} = \max\{0, \bar{X}\}$.

3.8 Diberikan $X_1, \dots, X_n$ sampel random iid berdistribusi Poisson, $X_i \sim POI(\lambda)$ dengan $0 < \lambda \leq 2$. Tunjukkan bahwa MLE dari λ adalah $\hat{\lambda} = \min\{\bar{X}, 2\}$.

3.9 Diberikan $X_1, \dots, X_n$ sampel random iid dari suatu distribusi dengan salah satu dari dua PDF berikut:

$$f(x|\theta) = \begin{cases} \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}, & -\infty < x < \infty, \theta = 1 \\ \frac{1}{[\pi(1+x^2)]}, & -\infty < x < \infty, \theta = 2 \end{cases}$$

Carilah MLE dari θ .

3.10 Diberikan $X_1, \dots, X_n$ sampel random iid dari suatu distribusi dengan PDF

$$f(x|\theta) = \frac{1}{\pi[1 + (x - \theta)^2]}, \quad -\infty < x < \infty, \quad -\infty < \theta < \infty$$

- (a) Carilah MLE dari $\theta = \hat{\theta}$. Apakah estimator tersebut takbias?
 (b) Tunjukkan bahwa CRLB untuk estimator takbias θ adalah $\frac{2}{n}$, dengan n adalah jumlah sampel.
 (c) Carilah distribusi asimtotik dari $\sqrt{n}(\hat{\theta} - \theta)$.

Bab 4

Statistik Cukup

Abstrak Bab ini akan menjelaskan prinsip kecukupan dari suatu statistik, seperti statistik cukup, statistik cukup minimal, statistik *ancillary*, statistik lengkap, dan Teorema Rao-Blackwell.

4.1 Statistik Cukup

Jika dua estimator θ takbias, tentunya akan dipilih estimator dengan variansi yang lebih kecil. Hal ini berlaku jika keduanya mendekati normal asimtotik karena estimator dengan variansi asimtotik yang lebih kecil cenderung menghasilkan interval konfidensi asimtotik yang lebih pendek untuk θ . Dari motivasi ini, diperoleh definisi berikut:

Definisi 4.1 Untuk bilangan bulat positif n , statistik $Y = u(X_1, X_2, \dots, X_n)$ adalah *minimum variance unbiased estimator* (MVUE) dari θ jika Y takbias dan variansi dari Y lebih kecil atau sama dengan variansi estimator takbias lainnya dari θ .

Selanjutnya, diberikan definisi dari fungsi indikator sebagai berikut.

Definisi 4.2 Fungsi indikator $I : A \rightarrow \mathbb{R}$ adalah fungsi yang didefinisikan sebagai

$$I_A(x) = \begin{cases} 1, & x \in A \\ 0, & x \notin A \end{cases}$$

Berdasarkan motivasi diatas, berikut adalah definisi dari statistik cukup.

Definisi 4.3 Statistik $T(\underline{X})$ disebut statistik cukup untuk θ jika distribusi bersyarat sampel $\underline{X}$ diketahui harga $T(\underline{X})$ tidak bergantung pada θ .

Teorema 4.1 Jika $f(\underline{x}|\theta)$ PDF dari $\underline{X}$ dan $q(t|\theta)$ adalah PDF dari $T(\underline{X})$, maka $T(\underline{X})$ adalah statistik cukup untuk θ jika dan hanya jika untuk setiap $\underline{x}$ dalam ruang sampel, rasio $\frac{f(\underline{x}|\theta)}{q(t|\theta)}$ tidak bergantung pada θ .

Contoh 4.1 Diberikan $X_1, X_2, \dots, X_n$ sampel random iid berdistribusi Eksponensial, $X_i \sim EXP(\theta)$. Diperoleh

$$f(\underline{x}|\theta) = \frac{1}{\theta^n} e^{-\frac{\sum x_i}{\theta}}, \quad x_i > 0$$

Selanjutnya, misalkan $S = \sum X_i$. Diperoleh $S \sim GAM(n, \theta)$, yaitu

$$f(s|\theta) = \frac{1}{\Gamma(n)\theta^n} s^{n-1} e^{-\frac{s}{\theta}}, s > 0$$

jika $s = \sum x_i$, maka diperoleh

$$\frac{f(\underline{x}|\theta)}{f(s|\theta)} = \frac{\Gamma(n)}{s^{n-1}}$$

dengan $\frac{\Gamma(n)}{s^{n-1}}$ tidak bergantung pada θ . Jadi, $S = \sum X_i$ statistik cukup untuk θ .

Teorema 4.2 (Teorema Faktorisasi) Misalkan $f(\underline{x}|\theta)$ adalah PDF bersama dari sampel $\underline{X}$. $T(\underline{X})$ adalah statistik cukup untuk θ jika dan hanya jika terdapat fungsi $g(T(\underline{x}|\theta))$ dan $h(\underline{x})$ sedemikian hingga untuk semua titik sampel $\underline{X}$ dan semua titik parameter θ berlaku

$$f(\underline{x}|\theta) = g(T(\underline{x}|\theta))h(\underline{x})$$

Contoh 4.2 Diberikan $X_1, X_2, \dots, X_n$ sampel random iid berdistribusi Uniform $(0, \theta)$. Akan diselidiki apakah $T(\underline{X}) = \max X_i$ statistik cukup untuk θ . **Solusi:** Diketahui $T(\underline{X}) = \max X_i = X_{n:n}$, maka:

$$\begin{aligned} f(\underline{x}|\theta) &= \prod_{i=1}^n f(x_i|\theta) \\ &= \prod_{i=1}^n \frac{1}{\theta} I_{(0,\theta)}(x_i) \\ &= \frac{1}{\theta^n} I_{(0,\theta)}(\max x_i) \end{aligned}$$

Perhatikan bahwa $f(\underline{x}|\theta) = g(T(\underline{x}|\theta))h(\underline{x})$, dengan $h(\underline{x}) = 1$ dan $g(T(\underline{x}|\theta)) = \frac{1}{\theta^n} I_{(0,\theta)}(\max x_i)$, sehingga $T(\underline{X}) = \max X_i$ adalah statistik cukup untuk θ .

Sifat keluarga eksponensial dapat digunakan untuk mengetahui apakah suatu statistik merupakan statistik cukup atau bukan.

Teorema 4.3 Misalkan $X_1, X_2, \dots, X_n$ iid dengan PDF $f(x|\theta)$. Jika $f(x|\theta)$ adalah keluarga eksponensial, yaitu $f(x|\theta)$ dapat dituliskan dalam bentuk

$$f(x|\theta) = h(x)c(\theta) \exp\left(\sum_{i=1}^k w_i(\theta)t_i(x)\right), x \in S$$

maka $T(\underline{X}) = (\sum_{j=1}^n t_1(X_j), \dots, \sum_{j=1}^n t_k(X_j))$ adalah statistik cukup untuk θ .

Sebagian besar PDF (atau PMF) yang tidak termasuk dalam keluarga eksponensial tergolong dalam kelas umum lainnya, yang memungkinkan range dari X , yang dinyatakan oleh $A = \{x | f(x|\theta) > 0\}$, bergantung pada θ .

Definisi 4.4 (*Range-dependent exponential class (RDEC)*) Suatu PDF (atau PMF) $f(x|\theta)$ (atau $p(x|\theta)$) dikatakan termasuk dalam kelas eksponensial yang bergantung pada *range* (*range-dependent exponential class* - RDEC), dinotasikan dengan $RDEC(w_1, \dots, w_k)$, jika

1. Fungsi $w_j(\theta)$ nontrivial, independen, dan kontinu dari θ ,
2. Fungsi $t'_j(x)$ kontinu dan bebas linear terhadap A (jika kontinu), dan
3. Fungsi $t_j(x)$ adalah fungsi nontrivial pada A (jika diskrit),

untuk $j = 3, 4, \dots, k$.

Beberapa kasus khusus yang perlu diperhatikan dalam RDEC adalah sebagai berikut.

1. Kasus satu parameter, di mana

$$f(x|\theta) = c(\theta)h(x),$$

dengan $A = \{x | w_1(\theta) < x < w_2(\theta)\}$.

2. Kasus dua parameter, di mana

$$f(x|\theta_1, \theta_2) = c(\theta_1, \theta_2)h(x),$$

dengan $A = \{x | w_1(\theta_1, \theta_2) < x < w_2(\theta_1, \theta_2)\}$.

Teorema berikut dapat membantu kita untuk mengidentifikasi statistik cukup untuk kasus RDEC.

Teorema 4.4 Diberikan $X_1, \dots, X_n$ sampel random iid dari $RDEC(w_1, \dots, w_k)$.

1. Jika $k > 2$, maka $S_1 = X_{1:n}$, $S_2 = X_{n:n}$, dan $S_3, \dots, S_k$ adalah statistik cukup bersama untuk $\theta = (\theta_1, \dots, \theta_k)$.
2. Untuk kasus dua parameter, $S_1 = X_{1:n}$ dan $S_2 = X_{n:n}$ adalah statistik cukup bersama untuk $\theta = (\theta_1, \theta_2)$.
3. Untuk kasus satu parameter, $S_1 = X_{1:n}$ dan $S_2 = X_{n:n}$ adalah statistik cukup bersama untuk θ .
Lebih lanjut,
 - Jika $w_1(\theta)$ fungsi naik dan $w_2(\theta)$ fungsi turun, maka $T_1 = \min(w_1^{-1}(X_{1:n}), w_2^{-1}(X_{n:n}))$ statistik cukup tunggal untuk θ .
 - Jika $w_1(\theta)$ fungsi turun dan $w_2(\theta)$ fungsi naik, maka $T_2 = \max(w_1^{-1}(X_{1:n}), w_2^{-1}(X_{n:n}))$ statistik cukup tunggal untuk θ .

Teorema 4.5 Diberikan $X_1, \dots, X_n$ sampel random iid dari $RDEC(w_1, \dots, w_k)$.

1. Misalkan diketahui $k > 2$.

- Jika limit batas bawah berupa konstanta, yaitu $w_1(\theta) = a$, maka $X_{n:n}$ dan statistik $\sum_{i=1}^n t_j(X_i)$ adalah statistik cukup bersama untuk θ dan θ_j , $j = 3, \dots, k$.

- Jika limit batas atas berupa konstanta, yaitu $w_2(\theta) = b$, maka $X_{1:n}$ dan statistik $\sum_{i=1}^n t_j(X_i)$ adalah statistik cukup bersama untuk θ dan θ_j , $j = 3, \dots, k$.
2. Untuk kasus satu parameter, jika $w_1(\theta)$ tidak bergantung pada θ , maka $S_2 = X_{n:n}$ adalah statistik cukup untuk θ , sedangkan jika $w_2(\theta)$ tidak bergantung pada θ , maka $S_1 = X_{1:n}$ adalah statistik cukup untuk θ .

4.2 Statistik Cukup Minimal

Statistik cukup tidak tunggal. Setiap fungsi satu-satu dari statistik cukup juga merupakan statistik cukup. Misalkan $T(\underline{X})$ statistik cukup dan $T^*(x) = r(T(x))$ dengan r fungsi satu-satu dengan invers r^{-1} . Menggunakan teorema faktorisasi

$$\begin{aligned} f(\underline{x}|\theta) &= g(T(\underline{x}|\theta)h(\underline{x})) \\ &= g(r^{-1}(T(x))|\theta)h(\underline{x}) \end{aligned}$$

Dengan mendefinisikan $g^*(t|\theta) = g(r^{-1}(t)|\theta)$, diperoleh $f(\underline{x}|\theta) = g^*(T^*(\underline{x}|\theta)h(\underline{x}))$.

Definisi 4.5 Statistik cukup $T(\underline{X})$ disebut statistik cukup minimal jika untuk statistik cukup yang lain $T'(\underline{X})$, maka $T(\underline{X})$ adalah fungsi dari $T'(\underline{X})$.

Teorema 4.6 Misalkan $f(x|\theta)$ adalah PDF dari sampel X . Misalkan terdapat fungsi $T(\underline{X})$ sedemikian hingga untuk dua titik sampel x dan y , rasio $f(\underline{x}|\theta)$ dan $f(\underline{y}|\theta)$ tidak tergantung pada θ jika dan hanya jika $T(\underline{x}) = T(\underline{y})$, maka $T(\underline{X})$ adalah statistik cukup minimal untuk θ .

Contoh 4.3 Misalkan $X_1, X_2, \dots, X_n$ iid $N(\mu, \sigma^2)$ dengan μ dan σ^2 keduanya tidak diketahui. Misalkan $\underline{x}$ dan $\underline{y}$ menyatakan dua titik sampel dan misalkan $(\bar{x}, s_x^2)$ dan $(\bar{y}, s_y^2)$ masing-masing adalah mean sampel dan variansi yang bersesuaian dengan sampel $\underline{x}$ dan $\underline{y}$. Diperoleh

$$\begin{aligned} \frac{f(\underline{x}|\mu, \sigma^2)}{f(\underline{y}|\mu, \sigma^2)} &= \frac{(2\pi\sigma^2)^{-\frac{n}{2}} \exp\left(\frac{-[n(\bar{x}-\mu)^2 + (n-1)s_x^2]}{2\sigma^2}\right)}{(2\pi\sigma^2)^{-\frac{n}{2}} \exp\left(\frac{-[n(\bar{y}-\mu)^2 + (n-1)s_y^2]}{2\sigma^2}\right)} \\ &= \exp\left(\frac{-[n(\bar{x}-\mu)^2 + (n-1)s_x^2] + [n(\bar{y}-\mu)^2 + (n-1)s_y^2]}{2\sigma^2}\right) \end{aligned}$$

Untuk $\bar{x} = \bar{y}$ dan $s_x^2 = s_y^2$, diperoleh $\frac{f(\underline{x}|\mu, \sigma^2)}{f(\underline{y}|\mu, \sigma^2)} = 1$ dan tidak dipengaruhi oleh μ dan σ^2 . Jadi, $(\bar{x}, s^2)$ statistik cukup minimal untuk (μ, σ^2) .

4.3 Statistik Ancillary dan Statistik Lengkap

Berikut adalah definisi dari statistik ancillary.

Definisi 4.6 Statistik $S(\underline{X})$ disebut statistik penyokong (*ancillary*) jika distribusinya tidak tergantung pada parameter θ .

Statistik ancillary sendiri tidak memuat informasi tentang θ , tetapi jika digunakan dengan statistik yang lain, terkadang statistik ancillary memuat informasi yang sangat berharga untuk melakukan inferensi tentang θ .

Contoh 4.4 Misalkan $X_1, X_2, \dots, X_n$ adalah observasi iid dari keluarga parameter lokasi dengan CDF $F(x - \theta)$, $-\infty < \theta < \infty$. Akan ditunjukkan bahwa jelajah (*range*) $R = X_{(n)} - X_{(1)}$ adalah statistik ancillary. Andaikan $Z_1, Z_2, \dots, Z_n$ adalah observasi iid dari $F(x)$ (bersesuaian dengan $\theta = 0$) dengan $X_i = Z_i + \theta$, $i = 1, 2, \dots, n$. Maka CDF dari R adalah

$$\begin{aligned} F_R(r|\theta) &= P_\theta(R \leq r) \\ &= P_\theta(\max_i X_i - \min_i X_i \leq r) \\ &= P_\theta(\max_i (Z_i + \theta) - \min_i (Z_i + \theta) \leq r) \\ &= P_\theta(\max_i Z_i - \min_i Z_i + \theta - \theta \leq r) \\ &= P_\theta(\max_i Z_i - \min_i Z_i \leq r) \end{aligned}$$

Probabilitas terakhir tidak tergantung θ karena $Z_1, Z_2, \dots, Z_n$ tidak tergantung θ . Jadi CDF dari R juga tidak bergantung pada θ . Oleh karena itu, R adalah statistik ancillary.

Contoh 4.5 Keluarga parameter skala (*scale parameter family*) juga memiliki jenis statistik *ancillary* tertentu. Misalkan $X_1, \dots, X_n$ adalah sampel random iid dari suatu keluarga parameter skala dengan CDF

$$F(x/\sigma), \quad \sigma > 0.$$

Maka, setiap statistik yang bergantung pada sampel hanya melalui $n - 1$ nilai $X_1/X_n, \dots, X_{n-1}/X_n$ merupakan statistik *ancillary*. Sebagai contoh,

$$\frac{X_1 + \dots + X_n}{X_n} = \frac{X_1}{X_n} + \dots + \frac{X_{n-1}}{X_n} + 1$$

merupakan statistik *ancillary*. Untuk melihat fakta ini, misalkan $Z_1, \dots, Z_n$ adalah sampel random iid dari $F(x)$ (yang bersesuaian dengan $\sigma = 1$) dengan $X_i = \sigma Z_i$. CDF bersama dari $X_1/X_n, \dots, X_{n-1}/X_n$ adalah

$$\begin{aligned}
 F(y_1, \dots, y_{n-1} \mid \sigma) &= P_\sigma \left(\frac{X_1}{X_n} \leq y_1, \dots, \frac{X_{n-1}}{X_n} \leq y_{n-1} \right) \\
 &= P_\sigma \left(\frac{\sigma Z_1}{\sigma Z_n} \leq y_1, \dots, \frac{\sigma Z_{n-1}}{\sigma Z_n} \leq y_{n-1} \right) \\
 &= P_\sigma \left(\frac{Z_1}{Z_n} \leq y_1, \dots, \frac{Z_{n-1}}{Z_n} \leq y_{n-1} \right).
 \end{aligned}$$

Probabilitas terakhir tidak bergantung pada σ karena distribusi dari $Z_1, \dots, Z_n$ tidak bergantung pada σ . Oleh karena itu, distribusi dari $X_1/X_n, \dots, X_{n-1}/X_n$ tidak bergantung pada σ , demikian pula distribusi dari setiap fungsi dari besaran-besaran tersebut.

Definisi 4.7 Misalkan $f(t|\theta)$ adalah keluarga densitas dari statistik $T(\underline{X})$. Keluarga densitas tersebut disebut lengkap jika $E_\theta g(T) = 0$ untuk semua θ maka $P_\theta(g(T) = 0) = 1$ untuk semua θ . Secara ekuivalen, $T(\underline{X})$ disebut statistik lengkap.

Untuk menunjukkan bahwa keluarga tertentu dari fungsi kepadatan peluang bertipe kontinu bersifat lengkap, kita harus menggunakan jenis teorema dalam analisis yang sama seperti yang digunakan ketika menyatakan bahwa fungsi pembangkit momen menentukan suatu distribusi secara unik. Hal ini diilustrasikan pada contoh berikut.

Contoh 4.6 Diberikan keluarga PDF $\{h(z; \theta) : 0 < \theta < \infty\}$. Misalkan Z memiliki fungsi kepadatan peluang dalam keluarga tersebut yang diberikan oleh

$$h(z; \theta) = \begin{cases} \frac{1}{\theta} e^{-z/\theta}, & 0 < z < \infty, \\ 0, & \text{di tempat lain.} \end{cases}$$

Misalkan pula bahwa

$$E[u(Z)] = 0$$

untuk setiap $\theta > 0$. Artinya,

$$\frac{1}{\theta} \int_0^\infty u(z) e^{-z/\theta} dz = 0, \quad \theta > 0.$$

Perhatikan bahwa integral pada ruas kiri pada dasarnya merupakan transformasi Laplace dari $u(z)$. Dengan menggunakan pengetahuan dari transformasi Laplace tersebut, diketahui bahwa satu-satunya fungsi $u(z)$ yang transformasinya menjadi fungsi dari θ yang identik sama dengan nol adalah

$$u(z) = 0,$$

kecuali (dalam terminologi Matematika Statistika) pada suatu himpunan titik yang memiliki probabilitas nol untuk setiap $h(z; \theta)$, $\theta > 0$. Dengan demikian, keluarga

$$\{h(z; \theta) : 0 < \theta < \infty\}$$

merupakan keluarga statistik lengkap.

Teorema 4.7 Misalkan $X_1, X_2, \dots, X_n$ adalah iid dengan densitas dari keluarga eksponensial

$$f(x|\theta) = h(x)c(\theta) \exp\left(\sum_{i=1}^k w_i(\theta)t_i(x)\right), x \in S$$

Maka statistik

$$T(\underline{X}) = \sum_{i=1}^n t_i(X_i)$$

adalah lengkap.

4.4 Teorema Rao-Blackwell

Teorema berikut merupakan alternatif untuk mencari estimator takbias terbaik menggunakan sifat dari statistik cukup.

Teorema 4.8 Misalkan W adalah estimator takbias untuk $g(\theta)$, dan T adalah statistik cukup untuk θ . Definisikan $\phi(T) = E(W | T)$. Maka $E\phi(T) = g(\theta)$ dan $Var(\phi(T)) \leq Var(W)$ untuk setiap θ , yaitu $\phi(T)$, secara seragam merupakan estimator $g(\theta)$ takbias yang lebih baik.

Bukti. Ingat sifat ekspektasi bersyarat dari distribusi bersyarat $X|Y$

$$\begin{aligned} E(X) &= E[E(X|Y)] \\ Var(X) &= Var[E(X|Y)] + E[Var(X|Y)] \end{aligned}$$

Dari sifat diatas, diperoleh

$$g(\theta) = E_{\theta}(W) = E_{\theta}[(W|T)] = E_{\theta}(\phi(T))$$

sehingga $\phi(T)$ takbias untuk $g(\theta)$. Lebih lanjut,

$$\begin{aligned} Var_{\theta}(W) &= Var_{\theta}[E(W|T)] + E_{\theta}[Var(W|T)] \\ &= Var_{\theta}(\phi(T)) + E_{\theta}[Var(W|T)] \\ &\geq Var_{\theta}(\phi(T)) \end{aligned}$$

Oleh karena itu, $\phi(T)$ secara seragam lebih baik dibandingkan dengan W . Selanjutnya, tinggal ditunjukkan bahwa $\phi(T)$ adalah estimator. Atau dengan kata lain, $\phi(T) = E(W|T)$ adalah fungsi sampel yang independen terhadap θ . Berdasarkan definisi kecukupan, dan fakta bahwa W adalah

fungsi dari sampel dimana $W|T$ independen terhadap θ . Jadi, $\phi(T)$ secara seragam merupakan estimator $g(\theta)$ takbias yang lebih baik. $\square$

Teorema 4.9 *Jika W adalah estimator takbias terbaik dari $g(\theta)$, maka W tunggal.*

Teorema 4.10 *Jika $E(T) = g(\theta)$; T adalah estimator takbias terbaik dari $g(\theta)$ jika dan hanya jika T tak berkorelasi dengan semua estimator takbias dari 0.*

Teorema 4.11 (Teorema Lehmann-Scheffe) *Misalkan T adalah statistik cukup lengkap untuk parameter θ dan misalkan $\phi(T)$ adalah sebarang estimator yang hanya berdasarkan pada T , maka $\phi(T)$ adalah estimator takbias terbaik tunggal (UMVUE) dari harga harapannya.*

Contoh 4.7 Untuk $X_1, \dots, X_n$ sampel random iid. seragam $(0, \theta)$, telah diketahui bahwa $\frac{n+1}{n} Y_n$ adalah estimator takbias untuk θ , dengan $Y_n = \max\{X_1, \dots, X_n\}$. Dalam hal ini syarat Teorema Cramer Rao tidak dipenuhi, sehingga tidak dapat ditentukan apakah estimator ini terbaik atau tidak, tetapi telah ditunjukkan bahwa Y_n adalah statistik cukup (buktikan di Latihan 4.7).

Selanjutnya, dapat dibuktikan bahwa PDF dari Y_n adalah

$$g(y_n|\theta) = \begin{cases} \frac{ny_n^{n-1}}{\theta^n}, & 0 < y_n < \theta \\ 0, & \text{lainnya} \end{cases}$$

Untuk membuktikan bahwa Y_n lengkap, misalkan sebarang fungsi $u(t)$ dan θ dengan $E[u(Y_n)] = 0$. Dengan kata lain,

$$0 = \int_0^\theta u(t) \frac{nt_n^{n-1}}{\theta^n} dt. \quad (4.1)$$

Karena $\theta > 0$, persamaan 4.1 dapat ditulis ulang menjadi

$$0 = \int_0^\theta u(t) t^n dt.$$

Kenakan turunan parsial pada kedua ruas terhadap θ , dan dengan memanfaatkan Teorema Fundamental Kalkulus, diperoleh

$$0 = u(\theta) \theta^{n-1}.$$

Karena $\theta > 0$, $u(\theta) = 0$ untuk setiap $\theta > 0$, maka keluarga densitas Y_n lengkap dan tidak ada estimator takbias untuk nol yang berdasarkan Y_n . Selanjutnya, dapat ditunjukkan bahwa

$$E(Y_n) = \int_0^\theta y \frac{ny^{n-1}}{\theta^n} dy = \frac{n}{n+1} \theta.$$

Oleh karena itu, $\frac{n+1}{n}Y$ tak berkorelasi dengan semua estimator takbias dari nol. Akibatnya, $\frac{n+1}{n}Y$ adalah estimator takbias terbaik dari θ .

Contoh 4.8 Untuk $X_1, \dots, X_n$ sampel random iid. binomial (k, θ)

$$g(\theta) = P(X = 1) = k\theta(1 - \theta)^{k-1}$$

Sekarang $\sum X_i \sim \text{BIN}(kn, \theta)$ adalah statistik cukup yang lengkap, tetapi 'calon' estimator terbaik takbias belum kelihatan. Pandang estimator sederhana

$$h(\underline{X}) = \begin{cases} 1 & \text{jika } X = 1 \\ 0 & \text{lainnya} \end{cases}$$

Estimator di atas memenuhi

$$\begin{aligned} E(h(\underline{X})) &= \sum_{x_1=0}^k h(\underline{X}) \binom{k}{x_1} \theta^{x_1} (1 - \theta)^{k-x_1} \\ &= k\theta(1 - \theta)^{k-1} \end{aligned}$$

Jadi, $h(\underline{X})$ merupakan estimator takbias untuk $k\theta(1 - \theta)^{k-1}$. Teori di atas mengatakan bahwa estimator

$$\phi\left(\sum_{i=1}^n X_i\right) = E\left(h(\underline{X}) \mid \sum_{i=1}^n X_i\right)$$

adalah estimator takbias 'terbaik' dari $k\theta(1 - \theta)^{k-1}$. Misalkan kita observasi $\sum X_i = t$, maka

$$\begin{aligned} \phi(t) &= E(h(\underline{X}) \mid \sum_{i=1}^n X_i = t) \\ &= P(X_1 = 1 \mid \sum_{i=1}^n X_i = t) \\ &= \frac{P(X_1 = 1, \sum_{i=1}^n X_i = t)}{P(\sum_{i=1}^n X_i = t)} \\ &= \frac{P(X_1 = 1, \sum_{i=2}^n X_i = t - 1)}{P(\sum_{i=1}^n X_i = t)} \end{aligned}$$

Karena $X_i \sim \text{BIN}(k, \theta)$, $\sum_{i=2}^n X_i \sim \text{BIN}(k(n-1), \theta)$, dan $\sum_{i=1}^n X_i \sim \text{BIN}(kn, \theta)$, maka

$$\begin{aligned}
\phi(t) &= \frac{P(X_1 = 1)P(\sum_{i=2}^n X_i = t-1)}{P(\sum_{i=1}^n X_i = t)} \\
&= \frac{[k\theta(1-\theta)^{k-1} \left[\binom{k(n-1)}{t-1} \theta^{t-1} (1-\theta)^{k(n-1)-(t-1)} \right]]}{\binom{kn}{t} \theta^t (1-\theta)^{kn-t}} \\
&= k \frac{\binom{k(n-1)}{t-1}}{\binom{kn}{t}}
\end{aligned}$$

Teorema berikut menggunakan sifat dari statistik lengkap untuk menunjukkan bahwa statistik cukup minimal bersifat independen dari setiap statistik *ancillary*.

Teorema 4.12 (Teorema Basu) *Jika T adalah statistik lengkap dan cukup minimal, maka T independen dari setiap statistik *ancillary*.*

Bukti. Hanya akan dibuktikan untuk kasus distribusi variabel random diskrit. Misalkan $S(X)$ adalah sebarang statistik *ancillary*. Maka,

$$P(S(X) = s)$$

tidak bergantung pada θ karena $S(X)$ merupakan statistik *ancillary*. Selain itu, probabilitas bersyarat

$$P(S(X) = s \mid T(X) = t) = P(X \in \{x : S(x) = s\} \mid T(X) = t)$$

juga tidak bergantung pada θ karena $T(X)$ merupakan statistik cukup. Dengan demikian, untuk menunjukkan bahwa $S(X)$ dan $T(X)$ saling independen, cukup ditunjukkan bahwa

$$P(S(X) = s \mid T(X) = t) = P(S(X) = s)$$

untuk semua kemungkinan nilai $t \in \mathcal{T}$. Selanjutnya,

$$P(S(X) = s) = \sum_{t \in \mathcal{T}} P(S(X) = s \mid T(X) = t) P_\theta(T(X) = t).$$

Lebih lanjut, karena

$$\sum_{t \in \mathcal{T}} P_\theta(T(X) = t) = 1,$$

maka kita dapat menuliskan

$$P(S(X) = s) = \sum_{t \in \mathcal{T}} P(S(X) = s \mid T(X) = t) P_\theta(T(X) = t).$$

Oleh karena itu, jika didefinisikan statistik

$$g(t) = P(S(X) = s \mid T(X) = t) - P(S(X) = s),$$

maka dua persamaan di atas menunjukkan bahwa

$$\begin{aligned} E_{\theta}[g(T)] &= \sum_{t \in \mathcal{T}} g(t) P_{\theta}(T(X) = t) \\ &= 0 \quad \text{untuk semua } \theta. \end{aligned}$$

Karena $T(X)$ merupakan statistik lengkap, maka hal ini mengakibatkan bahwa

$$g(t) = 0$$

untuk semua kemungkinan nilai $t \in \mathcal{T}$. □

Teorema Basu berguna karena memungkinkan kita menyimpulkan sifat independen dari dua statistik tanpa harus terlebih dahulu menentukan distribusi bersama dari kedua statistik tersebut. Untuk menggunakan Teorema Basu, kita perlu menunjukkan bahwa suatu statistik bersifat lengkap, yang terkadang merupakan permasalahan analisis yang cukup sulit. Untungnya, permasalahan ini dapat diatasi dengan memanfaatkan Teorema 4.7. Selanjutnya, kita berikan contoh penggunaan dari Teorema Basu, sebagai berikut.

Contoh 4.9 Misalkan $X_1, \dots, X_n$ adalah pengamatan eksponensial *iid* dengan parameter θ . Perhatikan perhitungan nilai harapan dari

$$g(X) = \frac{X_n}{X_1 + \dots + X_n}.$$

Pertama, diperhatikan bahwa distribusi eksponensial membentuk keluarga parameter skala (*scale parameter family*) dan dengan demikian, berdasarkan Contoh 4.5, $g(X)$ merupakan statistik *ancillary*. Distribusi eksponensial juga membentuk keluarga eksponensial dengan $t(x) = x$, sehingga berdasarkan Teorema 4.3 dan 4.7, $T(X) = \sum_{i=1}^n X_i$ merupakan statistik cukup yang sekaligus lengkap. Oleh karena itu, berdasarkan Teorema Basu, $T(X)$ dan $g(X)$ saling independen. Dengan demikian,

$$\begin{aligned} \theta &= E_{\theta}[X_n] \\ &= E_{\theta}[T(X)g(X)] \\ &= (E_{\theta}[T(X)])(E_{\theta}[g(X)]) \\ &= n\theta E_{\theta}[g(X)]. \end{aligned}$$

Akibatnya, untuk setiap θ ,

$$E_{\theta}[g(X)] = \frac{1}{n}.$$

Latihan Soal

4.1 Diberikan variabel random X berdistribusi normal dengan mean 0 dan standar deviasi σ , dengan $0 < \sigma < \infty$. Selidiki apakah $|X|$ merupakan statistik cukup untuk σ .

4.2 Diberikan $X_1, X_2, \dots, X_n$ sampel random iid normal dengan $X_i \sim N(0, \sigma), i = 1, 2, \dots, n$ dan $0 < \sigma < \infty$. Tunjukkan bahwa

$$\sum_{i=1}^n X_i^2$$

adalah statistik cukup untuk σ .

4.3 Diberikan $X_1, X_2, \dots, X_n$ sampel random iid Poisson dengan parameter $\lambda, 0 < \lambda < \infty$. Tunjukkan bahwa $\sum_{i=1}^n X_i$ adalah statistik cukup untuk λ .

4.4 Buktikan Teorema 4.3.

4.5 Diberikan $X_1, X_2, \dots, X_n$ sampel random iid Beta dengan parameter $\alpha = \theta > 0$ dan $\beta = 8$. Dapatkan statistik cukup untuk θ .

4.6 Kerjakan ulang Soal 4.5, jika parameter $\alpha = \beta = \theta > 0$.

4.7 Diberikan $X_1, X_2, \dots, X_n$ sampel random iid berdistribusi binomial negatif, yaitu $X_i \sim NB(r_i, p)$. Dapatkan statistik cukup untuk p .

4.8 Tunjukkan bahwa *order statistic* ke- n dari sampel random berukuran n berdistribusi Uniform dengan PDF $f(x|\theta) = 1/\theta, 0 < x < \theta, 0 < \theta < \infty$, nol lainnya, adalah statistik cukup untuk θ .

4.9 Diberikan $X_1, X_2, \dots, X_n$ sampel random iid berdistribusi Weibull, yaitu $X_i \sim WEI(\theta, \beta)$.

(a) Dapatkan statistik cukup untuk θ jika β diketahui.

(b) Selidiki apakah statistik cukup untuk θ dapat diperoleh jika β tidak diketahui.

4.10 Diberikan $Y_1 < Y_2 < Y_3 < Y_4 < Y_5$ adalah *order statistics* dari sampel random berukuran 5 yang mengikuti distribusi Uniform dengan PDF $f(x|\theta) = 1/\theta, 0 < x < \theta, 0 < \theta < \infty$, nol lainnya.

(a) Buktikan bahwa $2Y_3$ adalah estimator takbias dari θ .

(b) Dapatkan PDF bersama dari Y_3 dan statistik cukup Y_5 untuk θ .

(c) Dapatkan ekspektasi bersyarat $E(2Y_3|y_5) = \varphi(y_5)$.

(d) Bandingkan hasil yang diperoleh dari bagian (a) dan (c).

4.11 Diberikan sampel random berukuran n dari suatu distribusi diskrit dengan PMF $p(x|\theta) = 1/\theta, x = 1, 2, \dots, \theta$, nol lainnya, dengan θ tidak diketahui.

(a) Tunjukkan bahwa *order statistic* terbesar dari sampel random, yaitu Y_n , adalah statistik lengkap untuk θ .

(b) Buktikan bahwa

$$\frac{Y_n^{n+1} - (Y_n - 1)^{n+1}}{Y_n^n - (Y_n - 1)^n}$$

adalah UMVUE dari θ .

4.12 Diberikan $X_1, X_2, \dots, X_n$ sampel random iid dari suatu distribusi dengan PDF

$$f(x|\theta) = \frac{2\theta^3}{x^2} \exp\left(-\frac{\theta^2}{x^2}\right), \quad x > 0, \theta > 0.$$

- (a) Tentukan statistik cukup untuk θ .
 (b) Apakah statistik cukup tersebut juga merupakan statistik lengkap?

4.13 Diberikan $X_1, \dots, X_n$ sampel random iid berdistribusi Poisson dengan $X_1 \sim POI(\mu)$.

- (a) Carilah MLE dari μ .
 (b) Berdasarkan hasil pada bagian (a), selidiki apakah MLE tersebut merupakan UMVUE untuk μ .
 (c) Selidiki apakah $\sum X_i$ merupakan statistik cukup sekaligus statistik lengkap.

4.14 Diberikan $X_1, \dots, X_n$ sampel random iid berdistribusi Gamma dengan PDF

$$f(x|\alpha, \beta) = \frac{\beta^\alpha x^{\alpha-1} e^{-\beta x}}{\Gamma(\alpha)}$$

Tentukan statistik cukup untuk α dan β . Apakah statistik cukup tersebut juga merupakan statistik lengkap?

4.15 Diberikan variabel random X dengan PDF $f_X(x|\theta) = 1/(2\theta)$, $-\theta < x < \theta$, nol lainnya, dengan $\theta > 0$.

- (a) Selidiki apakah $Y = |X|$ adalah statistik cukup untuk θ .
 (b) Dimisalkan $f_Y(y|\theta)$ adalah PDF dari variabel random Y . Selidiki apakah keluarga $\{f_Y(y|\theta) : \theta > 0\}$ merupakan keluarga lengkap.

4.16 Diberikan $X_1, \dots, X_n$ sampel random iid dari suatu distribusi dengan PDF

$$f(x|\theta) = \frac{1}{6\theta^4} x^3 e^{-\frac{x}{\theta}}, \quad 0 < x < \infty, \quad 0 < \theta < \infty,$$

nol lainnya.

- (a) Tunjukkan bahwa PDF tersebut merupakan keluarga eksponensial. Selanjutnya, tuliskan ulang PDF tersebut dalam bentuk keluarga eksponensial.
 (b) Dapatkan statistik cukup lengkap dari Y_1 untuk θ .
 (c) Berdasarkan hasil dari bagian (b), dapatkan suatu fungsi $\phi(Y_1)$ sedemikian hingga $\phi(Y_1)$ adalah UMVUE untuk θ .

4.17 Diberikan $X_1, \dots, X_n$ sampel random iid dari suatu distribusi dengan PDF $f(x|\theta) = \theta e^{-\theta x}$, $0 < x < \infty$, nol lainnya, dan $\theta > 0$. Diketahui bahwa $Y = \sum_{i=1}^n X_i$ adalah statistik cukup untuk θ . Buktikan bahwa $(n-1)/Y$ adalah UMVUE untuk θ .

4.18 Jika diketahui variabel random X berdistribusi Poisson dengan parameter $\mu > 0$, tunjukkan bahwa $S = (-1)^X$ adalah UMVUE dari $e^{-2\mu}$.

4.19 Diberikan sampel random berukuran n dari suatu distribusi dengan PDF $f(x|\theta) = \theta x^{\theta-1}$, $0 < x < 1$, $\theta > 0$, nol lainnya.

- (a) Dapatkan UMVUE dari $1/\theta$. [**Petunjuk:** $E[-\ln X] = 1/\theta$].
 (b) Dapatkan UMVUE dari θ .

4.20 Diberikan $X_1, \dots, X_n$ sampel random iid dari suatu distribusi dengan PDF

$$f(x|\theta) = \begin{cases} \frac{(\ln \theta)^x}{\theta x!}, & x = 0, 1, \dots; \theta > 1 \\ 0, & \text{lainnya} \end{cases}.$$

Berdasarkan informasi diatas, dapatkan:

- (a) Statistik lengkap untuk θ .
- (b) MLE dari θ .
- (c) CRLB untuk θ .
- (d) UMVUE dari $\ln \theta$.
- (e) UMVUE dari $(\ln \theta)^2$.
- (f) CRLB dari $(\ln \theta)^2$.

Bab 5

Estimasi Interval

Abstrak Bab ini akan menjelaskan estimasi interval, dimulai dari interval konfidensi dan metode pencarian estimator interval yang terdiri dari metode pivot dan metode umum.

5.1 Interval Konfidensi

Pada Bab 3, telah dibahas permasalahan tentang estimasi titik, dimana selain membahas tentang bagaimana cara memperoleh estimator titik dari suatu parameter, kita juga telah mempelajari mengenai seberapa "dekat" estimator tersebut terhadap nilai parameter yang sebenarnya. Sebagian informasi mengenai hal ini dapat diperoleh dengan mengetahui variansi atau MSE dari estimator tersebut.

Pendekatan lain adalah dengan mempertimbangkan estimasi interval (*interval estimation*); dengan demikian, kita dapat mempertimbangkan probabilitas bahwa suatu interval memuat nilai parameter yang sebenarnya. Bahkan, interval tersebut dapat disesuaikan untuk mencapai tingkat probabilitas tertentu yang telah ditetapkan, sehingga ukuran ketepatannya secara otomatis tercakup di dalam estimasi interval tersebut.

Definisi 5.1 Diberikan $X_1, X_2, \dots, X_n$ sampel random dari X dengan PDF $f(x|\theta)$, $\theta \in \Omega$, dengan Ω adalah interval. Estimasi interval dari parameter θ adalah pasangan statistik $L = L(x_1, x_2, \dots, x_n)$ dan $U = U(x_1, x_2, \dots, x_n)$ yang memenuhi $L(\mathbf{x}) \leq U(\mathbf{x})$. Jika $\mathbf{X} = \mathbf{x}$ terobservasi, maka dapat dibentuk inferensi $L(\mathbf{x}) \leq \theta \leq U(\mathbf{x})$. Selanjutnya, interval random $[L(\mathbf{X}), U(\mathbf{X})]$ disebut estimator interval.

Beberapa kesepakatan yang digunakan:

- $[L(\mathbf{X}), U(\mathbf{X})]$ adalah estimator interval dari θ berdasarkan sampel random $X = (X_1, X_2, \dots, X_n)$;
- $[L(\mathbf{x}), U(\mathbf{x})]$ adalah nilai interval yang sesungguhnya.

Definisi 5.2 Diberikan $X_1, X_2, \dots, X_n$ sampel random dari X dengan PDF $f(x|\theta)$, $\theta \in \Omega$. Misalkan ditentukan nilai α dengan $0 < \alpha < 1$. Interval $[L(\mathbf{x}), U(\mathbf{x})]$ disebut interval konfidensi $(1 - \alpha)100\%$ untuk θ jika

$$1 - \alpha = P_\theta[\theta \in [L(\mathbf{x}), U(\mathbf{x})]]$$

Selanjutnya, $L(\mathbf{x})$ disebut batas bawah konfidensi dan $U(\mathbf{x})$ disebut batas atas konfidensi.

Contoh 5.1 Diketahui X_1, X_2, X_3, X_4 sampel random berdistribusi Normal dengan $X_i \sim N(\mu, 1)$. Estimator interval dari μ adalah $[\bar{X} - 1, \bar{X} + 1]$.

Jika kita estimasi θ menggunakan $\bar{X}$, maka $P(\bar{X} = \mu) = 0$. Namun, dengan estimator interval, kita dapat menghitung probabilitas μ berada di interval $[\bar{X} - 1, \bar{X} + 1]$, yaitu

$$\begin{aligned}
P(\mu \in [\bar{X} - 1, \bar{X} + 1]) &= P(\bar{X} - 1 \leq \mu \leq \bar{X} + 1) \\
&= P(-1 \leq \bar{X} - \mu \leq 1) \\
&= P(-2 \leq \frac{\bar{X} - \mu}{\sqrt{\frac{1}{4}}} \leq 2) \\
&= P(-2 \leq Z \leq 2) \\
&= 0.9544
\end{aligned}$$

Artinya, terdapat probabilitas sebesar 0.9544 bahwa μ akan berada di interval $[\bar{X} - 1, \bar{X} + 1]$.

Definisi 5.3 1. Jika

$$P[L(\mathbf{x}) < \theta] = 1 - \alpha$$

maka $L(\mathbf{x}) = L(x_1, x_2, \dots, x_n)$ disebut batas bawah satu sisi interval konfidensi $(1 - \alpha)100\%$ untuk θ .

2. Jika

$$P[\theta < U(\mathbf{x})] = 1 - \alpha$$

maka $U(\mathbf{x}) = U(x_1, x_2, \dots, x_n)$ disebut batas atas satu sisi interval konfidensi $(1 - \alpha)100\%$ untuk θ .

Contoh 5.2 Dimisalkan sampel random berdistribusi normal, $X_i \sim N(\mu, \sigma^2)$, dengan σ^2 diketahui. Ingat bahwa $\bar{X}$ merupakan statistik cukup untuk μ , dan $Z = \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \sim N(0, 1)$. Secara simetri, diketahui pula bahwa $z_{\alpha/2} = -z_{1-\alpha/2}$, sehingga

$$\begin{aligned}
1 - \alpha &= P[-z_{1-\alpha/2} < \sqrt{n}(\bar{X} - \mu)/\sigma < z_{1-\alpha/2}] \\
&= P\left[\bar{X} - z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} < \mu < \bar{X} + z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}\right].
\end{aligned}$$

Diperoleh interval konfidensi $100(1 - \alpha)\%$ untuk μ adalah

$$\left(\bar{X} - z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{X} + z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}\right)$$

Sebagai contoh, untuk interval konfidensi 95%, $1 - \alpha/2 = 0.975$ dan batas atas dan bawah dari interval konfidensi tersebut adalah $\bar{X} \pm 1.96 \frac{\sigma}{\sqrt{n}}$.

Contoh 5.3 Diberikan $X_1, X_2, \dots, X_n$ sampel random berdistribusi uniform dengan $X_i \sim UNIF(0, \theta)$ dan misalkan $Y = \max\{X_1, \dots, X_n\}$. Dimisalkan dua kandidat estimator, yaitu $[aY, bY]$, $1 \leq a \leq b$ dan $[Y + c, Y + d]$, $0 \leq c \leq d$, dengan a, b, c, d adalah konstanta (**Catatan:** $\theta > y$).

Untuk interval pertama diperoleh

$$\begin{aligned}
P_{\theta}(\theta \in [aY, bY]) &= P_{\theta}(aY \leq \theta \leq bY) \\
&= P_{\theta}\left(\frac{1}{b} \leq \frac{Y}{\theta} \leq \frac{1}{a}\right) \\
&= P_{\theta}\left(\frac{1}{b} \leq T \leq \frac{1}{a}\right)
\end{aligned}$$

Ingat bahwa PDF dari Y adalah $f_Y(y) = \frac{ny^{n-1}}{\theta^n}$, $0 \leq y \leq \theta$, maka PDF dari T adalah $f_T(t) = nt^{n-1}$, $0 \leq t \leq 1$. Sehingga diperoleh

$$P_{\theta}\left(\frac{1}{b} \leq T \leq \frac{1}{a}\right) = \int_{1/b}^{1/a} nt^{n-1} dt = \left(\frac{1}{a}\right)^n - \left(\frac{1}{b}\right)^n$$

Perhatikan bahwa probabilitas *coverage* diatas tidak bergantung pada θ , oleh karena itu $\left(\frac{1}{a}\right)^n - \left(\frac{1}{b}\right)^n$ adalah koefisien konfidensi dari interval tersebut.

Dengan cara yang sama, untuk $\theta \geq d$ diperoleh hasil untuk interval kedua yaitu

$$\begin{aligned}
P_{\theta}(\theta \in [Y + c, Y + d]) &= P_{\theta}(Y + c \leq \theta \leq Y + d) \\
&= P_{\theta}\left(1 - \frac{d}{\theta} \leq T \leq 1 - \frac{c}{\theta}\right) \\
&= \int_{1-d/\theta}^{1-c/\theta} nt^{n-1} dt \\
&= \left(1 - \frac{c}{\theta}\right)^n - \left(1 - \frac{d}{\theta}\right)^n
\end{aligned}$$

Perhatikan bahwa probabilitas *coverage* diatas bergantung pada θ . Lebih lanjut, mudah ditunjukkan bahwa untuk sebarang konstanta c dan d ,

$$\lim_{\theta \rightarrow \infty} \left(1 - \frac{c}{\theta}\right)^n - \left(1 - \frac{d}{\theta}\right)^n = 0$$

yang menunjukkan bahwa koefisien konfidensi untuk interval ini adalah 0.

5.2 Metode Pencarian Estimator Interval

Pada contoh sebelumnya, kedua interval konfidensi memiliki perbedaan di banyak aspek. Satu perbedaan penting yang muncul adalah probabilitas *coverage* dari interval $[aY, bY]$ tidak bergantung pada θ , sedangkan probabilitas *coverage* dari interval $[Y + c, Y + d]$ bergantung pada θ . Ini terjadi karena probabilitas *coverage* dari interval $[aY, bY]$ dapat dinyatakan dalam bentuk $\frac{Y}{\theta}$, yaitu variabel random yang distribusinya tidak bergantung pada parameter, yang selanjutnya dikenal sebagai **pivotal quantity**, atau **pivot**.

5.2.1 Metode Pivot

Definisi 5.4 Variabel random $Q(\mathbf{X}, \theta) = Q(X_1, X_2, \dots, X_n, \theta)$ adalah **pivotal quantity** atau **pivot** jika distribusi $Q(\mathbf{X}, \theta)$ independen terhadap semua parameter. Atau dengan kata lain, jika $\mathbf{X} \sim F(\mathbf{x}|\theta)$, maka $Q(\mathbf{X}, \theta)$ mempunyai distribusi yang sama untuk semua nilai θ .

Umumnya fungsi $Q(\mathbf{x}, \theta)$ terdiri dari parameter dan statistik secara eksplisit, tetapi untuk sebarang himpunan $\mathcal{A}$, $P_\theta(\theta : Q(\mathbf{x}, \theta) \in \mathcal{A})$ tidak bisa bergantung pada θ . Teknik untuk membangun himpunan konfidensi dari pivot bergantung pada kemampuan mencari pivot dan himpunan $\mathcal{A}$ sehingga himpunan $\{\theta : Q(\mathbf{x}, \theta) \in \mathcal{A}\}$ adalah estimasi dari θ . Dua teorema berikut akan menggunakan sifat dari parameter lokasi dan parameter skala dari distribusi, oleh karena itu terlebih dahulu diberikan definisi terkait dengan parameter skala dan parameter lokasi sebagai berikut.

Definisi 5.5 (Parameter Lokasi) Koefisien η adalah parameter lokasi dari distribusi X jika CDF dari X berbentuk

$$F(x|\eta) = F(x - \eta)$$

dengan kata lain, PDF dari X berbentuk

$$f(x|\eta) = f(x - \eta)$$

Definisi 5.6 (Parameter Skala) Koefisien $\theta > 0$ adalah parameter skala dari distribusi X jika CDF dari X berbentuk

$$F(x|\theta) = F\left(\frac{x}{\theta}\right)$$

dengan kata lain, PDF dari X berbentuk

$$f(x|\theta) = \frac{1}{\theta} f\left(\frac{x}{\theta}\right)$$

Definisi 5.7 (Parameter Lokasi-Skala) Koefisien η dan $\theta > 0$ adalah parameter lokasi-skala dari distribusi X jika CDF dari X berbentuk

$$F(x|\eta, \theta) = F\left(\frac{x - \eta}{\theta}\right)$$

dengan kata lain, PDF dari X berbentuk

$$f(x|\eta, \theta) = \frac{1}{\theta} f\left(\frac{x - \eta}{\theta}\right)$$

Selanjutnya, dari definisi parameter lokasi dan parameter skala, dapat dituliskan teorema berikut.

Teorema 5.1 Diberikan $X_1, X_2, \dots, X_n$ sampel random dari suatu distribusi dengan PDF $f(x|\theta)$, $\theta \in \Omega$ dan diasumsikan MLE dari θ , yaitu $\hat{\theta}$ ada.

1. Jika θ adalah parameter lokasi (location parameter), maka $Q = \hat{\theta} - \theta$ adalah pivot.
2. Jika θ adalah parameter skala (scale parameter), maka $Q = \frac{\hat{\theta}}{\theta}$ adalah pivot.

Teorema 5.2 Diberikan $X_1, X_2, \dots, X_n$ sampel random dari suatu distribusi dengan PDF

$$f(x|\theta_1, \theta_2) = \frac{1}{\theta_2} f\left(\frac{x - \theta_1}{\theta_2}\right)$$

Jika MLE dari θ_1 dan θ_2 , masing-masing yaitu $\hat{\theta}_1$ dan $\hat{\theta}_2$ ada, maka $\frac{\hat{\theta}_1 - \theta_1}{\hat{\theta}_2}$ dan $\frac{\hat{\theta}_2}{\theta_2}$ masing-masing adalah pivot untuk θ_1 dan θ_2 .

Hubungan antara bentuk parameter dari PDF dan pivot yang digunakan dapat dilihat pada Tabel 5.1.

Tabel 5.1 Location-Scale Pivot

Bentuk PDF	Jenis PDF	Pivot
$f(x - \eta)$	Location	$\bar{X} - \eta$
$\frac{1}{\sigma} f\left(\frac{x}{\sigma}\right)$	Scale	$\frac{\bar{X}}{\sigma}$
$\frac{1}{\sigma} f\left(\frac{x - \eta}{\sigma}\right)$	Location-Scale	$\frac{\bar{X} - \eta}{\sigma}$

Contoh 5.4 Diberikan $X_1, X_2, \dots, X_n$ sampel random iid berdistribusi $EXP(\lambda)$. Maka $T = \sum X_i$ adalah statistik cukup untuk λ dan $T \sim GAM(n, \lambda)$.

Perhatikan bahwa pada PDF dari T , t dan λ muncul bersama dalam bentuk $\frac{t}{\lambda}$, dan bentuk PDF dari T adalah

$$f(t|\lambda) = \frac{t^{n-1} e^{-t/\lambda}}{\Gamma(n) \lambda^n}$$

yang merupakan keluarga *scale*. Sehingga jika dimisalkan $Q(T, \lambda) = 2T/\lambda$, diperoleh

$$Q(T, \lambda) \sim GAM(n, \lambda(2/\lambda)) = GAM(n, 2)$$

yang tidak bergantung pada λ . Jadi, $Q(T, \lambda) = 2T/\lambda$ adalah pivot dengan distribusi $GAM(n, 2)$ atau $\chi^2_{(2n)}$. Setelah mendapatkan pivot, langkah selanjutnya adalah mencari nilai a dan b yang tidak bergantung pada θ yang memenuhi

$$P_\lambda(a \leq Q(T, \lambda) \leq b) = 1 - \alpha$$

Maka untuk setiap $\lambda_0 \in \Theta$ diperoleh

$$A(\lambda_0) = \{t : a \leq Q(T, \lambda) \leq b\}$$

yaitu daerah penerimaan untuk uji hipotesis dengan $H_0 : \lambda = \lambda_0$ dan tingkat signifikansi sebesar α .

Teorema 5.3 Untuk setiap $\theta_0 \in \Theta$, misalkan $A(\theta_0)$ adalah daerah penerimaan untuk uji hipotesis dengan $H_0 : \lambda = \lambda_0$ dan tingkat signifikansi sebesar α . Untuk setiap $\mathbf{x} \in X$, definisikan himpunan $C(\mathbf{x})$ di himpunan parameter dengan

$$C(\mathbf{x}) = \{\theta_0 : \mathbf{x} \in A(\theta_0)\}.$$

Maka himpunan random $C(\mathbf{X})$ adalah himpunan konfidensi $1 - \alpha$. Sebaliknya, misalkan $C(\mathbf{X})$ adalah himpunan konfidensi $1 - \alpha$. Untuk sebarang $\theta_0 \in \Theta$, didefinisikan

$$A(\theta_0) = \{\mathbf{x} : \theta_0 \in C(\mathbf{x})\}$$

Maka $A(\theta_0)$ adalah daerah penerimaan untuk uji hipotesis dengan $H_0 : \lambda = \lambda_0$ dan tingkat signifikansi sebesar α .

Menggunakan teorema tersebut, jika dipilih konstanta a dan b sedemikian sehingga memenuhi $P_\lambda(a \leq \chi_{(2n)}^2 \leq b) = 1 - \alpha$, maka

$$P_\lambda\left(a \leq \frac{2T}{\lambda} \leq b\right) = P_\lambda(a \leq Q(T, \lambda) \leq b) = P_\lambda(a \leq \chi_{(2n)}^2 \leq b) = 1 - \alpha$$

Dengan melakukan invers pada himpunan $A(\lambda_0) = \{t : a \leq \frac{2t}{\lambda} \leq b\}$, diperoleh $C(t) = \{\lambda : \frac{2t}{b} \leq \lambda \leq \frac{2t}{a}\}$, yang merupakan interval konfidensi $1 - \alpha$. Selanjutnya, jika $\chi_{2n, \alpha/2}^2$ dan $\chi_{2n, 1-\alpha/2}^2$ masing-masing menyatakan persentil ke- $\frac{\alpha}{2}$ dan ke- $1 - \frac{\alpha}{2}$ dari distribusi chi-square dengan derajat kebebasan $2n$, maka interval konfidensi $1 - \alpha$ nya adalah $C(t) = \{\lambda : \frac{2t}{\chi_{2n, 1-\alpha/2}^2} \leq \lambda \leq \frac{2t}{\chi_{2n, \alpha/2}^2}\}$.

5.2.2 Metode Umum

Jika pivot tidak tersedia, maka masih dimungkinkan untuk mencari daerah konfidensi untuk parameter θ jika sebuah statistik eksis dengan suatu distribusi yang bergantung pada θ namun tidak pada parameter lainnya yang tidak diketahui. Secara spesifik, misalkan $X_1, X_2, \dots, X_n$ mempunyai PDF bersama $f(x_1, \dots, x_n | \theta)$ dan $S = s(X_1, \dots, X_n) \sim g(s | \theta)$. Umumnya S statistik cukup untuk θ , atau estimator seperti MLE, tetapi hal ini tidak diperlukan. Untuk setiap nilai θ yang mungkin, asumsikan dapat dicari nilai $h_1(\theta)$ dan $h_2(\theta)$ sehingga

$$P(h_1(\theta) < S < h_2(\theta)) = 1 - \alpha.$$

Jika diobservasi $S = s$, maka himpunan $\theta \in \Omega$ yang memenuhi $h_1(\theta) < S < h_2(\theta)$ akan membentuk interval konfidensi $(1 - \alpha)100\%$. Dengan kata lain, jika θ_0 adalah nilai kebenaran untuk θ , maka θ_0 akan berada di daerah konfidensi jika dan hanya jika $h_1(\theta_0) < S < h_2(\theta_0)$, yang mempunyai level konfidensi $(1 - \alpha)100\%$, karena $P(h_1(\theta) < S < h_2(\theta)) = 1 - \alpha$ berlaku ketika $\theta = \theta_0$. Umumnya, $h_1(\theta)$ dan $h_2(\theta)$ merupakan fungsi monoton naik (atau turun) dari θ , dan daerah konfidensi yang dihasilkan akan berupa interval.

Definisi 5.8 Suatu keluarga fungsi distribusi kumulatif $F(t|\theta)$ dikatakan *meningkat secara stokastik* terhadap θ (atau *menurun secara stokastik* terhadap θ) apabila, untuk setiap $t \in T$, fungsi $F(t|\theta)$ merupakan fungsi turun (atau naik) terhadap θ .

Teorema 5.4 (Pivot untuk CDF Kontinu) Diberikan T adalah statistik dengan CDF kontinu $F_T(t|\theta)$. Misalkan $\alpha_1 + \alpha_2 = \alpha$ dengan $0 < \alpha < 1$ merupakan nilai tetap. Dimisalkan untuk setiap $t \in \mathcal{T}$, didefinisikan fungsi $\theta_L(t)$ dan $\theta_U(t)$ sebagai berikut.

1. Jika $F_T(t|\theta)$ fungsi turun dari θ untuk setiap t , definisikan $\theta_L(t)$ dan $\theta_U(t)$ sebagai

$$F_T(t|\theta_U(t)) = \alpha_1 \text{ dan } F_T(t|\theta_L(t)) = 1 - \alpha_2$$

2. Jika $F_T(t|\theta)$ fungsi naik dari θ untuk setiap t , definisikan $\theta_L(t)$ dan $\theta_U(t)$ sebagai

$$F_T(t|\theta_U(t)) = 1 - \alpha_2 \text{ dan } F_T(t|\theta_L(t)) = \alpha_1$$

Maka interval random $[\theta_L(T), \theta_U(T)]$ adalah interval konfidensi $1 - \alpha$ untuk θ .

Perhatikan bahwa pada kasus (1) dari Teorema 5.4, Persamaan-persamaan untuk kasus meningkat secara stokastik, yaitu

$$F_T(t | \theta_U(t)) = \alpha_1, \quad F_T(t | \theta_L(t)) = 1 - \alpha_2,$$

juga dapat dinyatakan dalam bentuk PDF dari statistik T . Fungsi-fungsi $\theta_U(t)$ dan $\theta_L(t)$ dapat didefinisikan sedemikian sehingga memenuhi

$$\int_{-\infty}^t f_T(u | \theta_U(t)) du = \alpha_1, \\ \int_t^{\infty} f_T(u | \theta_L(t)) du = \alpha_2.$$

Sistem persamaan yang serupa juga berlaku untuk kasus menurun secara stokastik.

Teorema 5.5 (Pivot untuk CDF Diskrit) Diberikan T adalah statistik dengan CDF diskrit $F_T(t|\theta) = P(T \leq t|\theta)$. Misalkan $\alpha_1 + \alpha_2 = \alpha$ dengan $0 < \alpha < 1$ merupakan nilai tetap. Dimisalkan untuk setiap $t \in \mathcal{T}$, didefinisikan fungsi $\theta_L(t)$ dan $\theta_U(t)$ sebagai berikut.

1. Jika $F_T(t|\theta)$ fungsi turun dari θ untuk setiap t , definisikan $\theta_L(t)$ dan $\theta_U(t)$ sebagai

$$P(T \leq t|\theta_U(t)) = \alpha_1 \text{ dan } P(T \geq t|\theta_L(t)) = \alpha_2$$

2. Jika $F_T(t|\theta)$ fungsi naik dari θ untuk setiap t , definisikan $\theta_L(t)$ dan $\theta_U(t)$ sebagai

$$P(T \leq t|\theta_U(t)) = \alpha_1 \text{ dan } P(T \geq t|\theta_L(t)) = \alpha_2$$

Maka interval random $[\theta_L(T), \theta_U(T)]$ adalah interval konfidensi $1 - \alpha$ untuk θ .

Untuk mempermudah pemahaman, perhatikan contoh berikut.

Contoh 5.5 Jika $X_1, \dots, X_n$ merupakan sampel random iid dengan PDF

$$f(x | \mu) = e^{-(x-\mu)} I_{[\mu, \infty)}(x),$$

dengan $I(x)$ adalah fungsi indikator (lihat Catatan 5.1), maka $Y = \min\{X_1, \dots, X_n\}$ merupakan statistik cukup untuk μ dengan PDF

$$f_Y(y | \mu) = ne^{-n(y-\mu)} I_{[\mu, \infty)}(y).$$

Selanjutnya, ambil suatu nilai α dan definisikan $\mu_L(y)$ dan $\mu_U(y)$ sedemikian sehingga

$$\begin{aligned} \int_{\mu_U(y)}^y ne^{-n(y-u)} du &= \frac{\alpha}{2}, \\ \int_y^\infty ne^{-n(u-\mu_L(y))} du &= \frac{\alpha}{2}. \end{aligned}$$

Integral-integral tersebut dapat dihitung sedemikian sehingga diperoleh persamaan

$$\begin{aligned} 1 - e^{-n(y-\mu_U(y))} &= \frac{\alpha}{2}, \\ e^{-n(y-\mu_L(y))} &= \frac{\alpha}{2}, \end{aligned}$$

yang memberikan solusi

$$\begin{aligned} \mu_U(y) &= y + \frac{1}{n} \log\left(1 - \frac{\alpha}{2}\right), \\ \mu_L(y) &= y + \frac{1}{n} \log\left(\frac{\alpha}{2}\right). \end{aligned}$$

Dengan demikian, interval random

$$C(Y) = \left\{ \mu : Y + \frac{1}{n} \log\left(\frac{\alpha}{2}\right) \leq \mu \leq Y + \frac{1}{n} \log\left(1 - \frac{\alpha}{2}\right) \right\},$$

adalah interval konfidensi $1 - \alpha$ untuk parameter μ .

Catatan 5.1 Dalam beberapa referensi (seperti pada Contoh 5.5), penulisan PDF terkadang menggunakan notasi fungsi indikator $I_{(a,b)}(x)$, yang didefinisikan sebagai

$$I_{(a,b)}(x) = \begin{cases} 1, & x \in (a, b) \\ 0, & \text{lainnya} \end{cases}.$$

Latihan Soal

5.1 Diberikan sampel random berukuran n berdistribusi normal, yaitu $X_i \sim N(\mu, \sigma^2)$.

- (a) Jika diketahui bahwa $\sigma^2 = 16$, dapatkan interval konfidensi 90% untuk μ berdasarkan estimasi $\bar{x} = 24.7$ dengan $n = 25$.
- (b) Berdasarkan informasi dari bagian (a), dapatkan batas bawah dan batas atas interval konfidensi 90% untuk μ .
- (c) Misalkan sekarang σ^2 tidak diketahui. Dapatkan interval konfidensi 90% untuk μ berdasarkan estimasi $\bar{x} = 24.7$ dan $s^2 = 13.8$ dengan $n = 25$.
- (d) Berdasarkan informasi dari bagian (c), dapatkan interval konfidensi 99% untuk σ^2 .

5.2 Diberikan $X_1, X_2, \dots, X_n$ sampel random iid berdistribusi Eksponensial, yaitu $X_i \sim EXP(\theta)$.

- (a) Jika $\bar{x} = 19.3$ dengan $n = 50$, dapatkan batas bawah interval konfidensi 95% untuk θ .
- (b) Dapatkan batas bawah interval konfidensi 95% untuk $P(X > t) = e^{-t/\theta}$, dengan t sebarang konstanta real.

5.3 Diberikan $X_1, X_2, \dots, X_n$ sampel random iid berdistribusi Weibull, yaitu $X_i \sim WEI(\theta, 2)$.

- (a) Tunjukkan bahwa $Q = 2 \sum_{i=1}^n X_i^2 / \theta^2 \sim \chi^2(2n)$.
- (b) Gunakan informasi dari bagian (a) untuk mendapatkan estimasi interval $100(1 - \alpha)\%$ untuk θ .
- (c) Dapatkan batas bawah interval konfidensi $100(1 - \alpha)\%$ untuk $P(X > t) = \exp[-(t/\theta)^2]$.
- (d) Dapatkan batas atas interval konfidensi $100(1 - \alpha)\%$ untuk persentil ke- p dari distribusi tersebut.

Bab 6

Uji Hipotesis

Abstrak Bab ini akan menjelaskan konsep dari uji hipotesis, yang terdiri dari tipe kesalahan, fungsi kuasa, dan metode uji hipotesis yang terdiri dari Uji rasio likelihood dan uji paling kuasa (*uniformly most powerful test/ UMP test*).

6.1 Pengertian Uji Hipotesis

Pada bagian sebelumnya, telah dipelajari metode inferensi dalam statistika menggunakan metode estimasi titik dan estimasi interval. Pada bagian ini, akan dibahas metode inferensi lain, yaitu uji hipotesis. Kita mulai dengan definisi hipotesis statistik.

Definisi 6.1 (Hipotesis) Hipotesis adalah pernyataan tentang parameter populasi.

Definisi hipotesis tersebut agak umum, tetapi hal penting yang harus diketahui adalah hipotesis membuat pernyataan tentang populasi. Tujuan dari uji hipotesis adalah untuk memutuskan apakah menerima atau menolak suatu hipotesis berdasarkan informasi sampel yang diberikan.

Definisi 6.2 (Hipotesis nol dan hipotesis alternatif) Dua hipotesis yang saling asing dalam persoalan uji hipotesis disebut hipotesis nol dan hipotesis alternatif. Mereka masing-masing dinyatakan dengan H_0 dan H_1 , yang didefinisikan sebagai berikut

$$H_0 : \theta \in \Omega_0$$

$$H_1 : \theta \in \Omega_0^C$$

dengan θ adalah parameter populasi, Ω_0 adalah himpunan bagian dari ruang parameter dan Ω_0^C adalah komplementnya.

Dalam persoalan uji hipotesis, sesudah mengobservasi sampel kita harus menentukan apakah menerima H_0 yang berarti menolak H_1 atau menerima H_1 yang berarti menolak H_0 . Himpunan bagian ruang sampel dimana H_0 ditolak disebut daerah penolakan atau daerah kritik (*critical region*). Komplemen daerah penolakan disebut daerah penerimaan.

Definisi 6.3 Daerah kritik (*critical region*) dari suatu uji hipotesis adalah himpunan bagian dari ruang sampel yang sesuai dengan menolak hipotesis awal (H_0). Secara matematis, daerah kritik C mempunyai ukuran α jika

$$\alpha = \max_{\theta \in \Omega_0} P_{\theta}[(X_1, \dots, X_n) \in C]$$

Selanjutnya, α disebut tingkat signifikansi.

Umumnya, uji hipotesis dinyatakan dalam bentuk uji statistik $T(X_1, \dots, X_n) = T(\underline{X})$, yaitu fungsi dari sampel. Sebagai contoh, sebuah uji mungkin menentukan bahwa H_0 akan ditolak jika $\bar{X}$, mean sampel, lebih besar dari 3. Dalam hal ini, $T(\underline{X}) = \bar{X}$ adalah uji statistik dan daerah penolakannya adalah $\{(x_1, \dots, x_n) : \bar{x} > 3\}$. Proses penerimaan H_0 atau H_1 mempunyai kemiripan dengan seorang hakim yang memutus perkara dalam pengadilan. Hipotesis nol analog dengan pernyataan terdakwa tak bersalah. Menggunakan asas praduga tak bersalah, seseorang diandaikan tak bersalah sampai ada fakta-fakta yang menunjukkan kebalikannya. Jika dalam pengadilan fakta-fakta dikumpulkan dari saksi-saksi, maka dalam hipotesis statistik pemilihan diantara H_0 dan H_1 dilakukan berdasarkan pengamatan pada sampel random.

6.2 Tipe Kesalahan dan Fungsi Kuasa

Uji hipotesis

$$H_0 : \theta \in \Omega_0 \text{ lawan } H_1 : \theta \in \Omega_0^C$$

dapat membuat dua tipe kesalahan. Dua tipe kesalahan tersebut diberi nama kesalahan tipe I (α) dan kesalahan tipe II (β). Jika $\theta \in \Omega_0$ tetapi uji hipotesis menolak H_0 , maka uji hipotesis tersebut melakukan kesalahan tipe I. Sebaliknya, jika $\theta \in \Omega_0^C$ tetapi uji hipotesis tidak menolak H_0 , maka uji hipotesis tersebut melakukan kesalahan tipe II. Misalkan C adalah daerah kritik untuk suatu uji hipotesis, maka

		Keputusan	
		H0 benar (tidak menolak H0)	H0 salah (menolak H0)
Aktual	H0 benar	True Negative Keputusan tepat: Tingkat konfidensi dengan probabilitas $1 - \alpha$	False Positive Kesalahan Tipe I: Tingkat signifikansi dengan probabilitas α
	H0 salah	False Negative Kesalahan Tipe II dengan probabilitas β	True Positive Keputusan tepat: Fungsi kuasa dengan probabilitas $1 - \beta$

Gambar 6.1 Tabel jenis kesalahan dalam uji hipotesis

untuk $\theta \in \Omega_0$, probabilitas kesalahan tipe I adalah $P(\underline{X} \in C) = \alpha$. Kemudian, untuk $\theta \in \Omega_0^C$, probabilitas kesalahan tipe II adalah $P(\underline{X} \in C^c) = \beta$. Selanjutnya, perhatikan bahwa $P(X \in C) = 1 - P(X \in C^c)$, sehingga untuk fungsi θ , $P(X \in C)$ memuat semua informasi tentang uji dengan daerah kritik C , dengan

$$P(X \in C) = \begin{cases} \alpha & \text{jika } \theta \in \Omega_0 \\ 1 - \beta & \text{jika } \theta \in \Omega_0^C \end{cases}$$

sehingga diperoleh definisi sebagai berikut.

Definisi 6.4 Fungsi kuasa (*power function*) dari uji hipotesis dengan daerah kritik C adalah fungsi θ yang didefinisikan sebagai

$$\beta(\theta) = P(\underline{X} \in C)$$

Fungsi kuasa yang ideal adalah 0 untuk $\theta \in \Omega_0$ dan 1 untuk $\theta \in \Omega_0^C$. Secara umum, bentuk ideal ini tidak dapat dicapai, kecuali untuk kasus trivial. Secara kualitatif, uji yang baik mempunyai fungsi kuasa mendekati 1 untuk $\theta \in \Omega_0^C$ dan mendekati 0 untuk $\theta \in \Omega_0$.

Contoh 6.1 Diberikan $X_1, \dots, X_n$ sampel random iid dari populasi berdistribusi normal yaitu $X_i \sim N(\mu, \sigma^2)$, dengan σ^2 diketahui. Misalkan diketahui uji hipotesis

$$H_0 : \theta \leq \theta_0 \text{ lawan } H_1 : \theta > \theta_0$$

dengan daerah kritik: Tolak H_0 jika $\frac{(\bar{X} - \theta_0)}{\frac{\sigma}{\sqrt{n}}} > c$. Fungsi kuasa dari uji ini adalah

$$\begin{aligned} \beta(\theta) &= P\left(\frac{(\bar{X} - \theta_0)}{\frac{\sigma}{\sqrt{n}}} > c\right) \\ &= P\left(\frac{(\bar{X} - \theta)}{\frac{\sigma}{\sqrt{n}}} > c + \frac{(\theta - \theta_0)}{\frac{\sigma}{\sqrt{n}}}\right) \\ &= P\left(Z > c + \frac{(\theta - \theta_0)}{\frac{\sigma}{\sqrt{n}}}\right) \end{aligned}$$

dengan Z adalah variabel random normal standar.

Contoh 6.2 Diberikan X variabel random berdistribusi Bernoulli dengan probabilitas sukses p . Misalkan diketahui uji hipotesis

$$H_0 : p = p_0 \text{ lawan } H_1 : p < p_0$$

dengan nilai p_0 diketahui. Sebagai ilustrasi, misalkan p adalah probabilitas pasien meninggal karena kanker dan p_0 adalah probabilitas pasien meninggal karena kanker dengan diberikan pengobatan standar. Misalkan dikembangkan suatu teknik pengobatan baru yang diharapkan probabilitas pasien meninggal akan lebih kecil dari p_0 . Selanjutnya, misalkan $X_1, \dots, X_n$ sampel random dari variabel random X dan misalkan $S = \sum_{i=1}^n X_i$ adalah total sukses dari sampel random. Secara intuitif, daerah kritiknya adalah

$$\text{Tolak } H_0 \text{ jika } S \leq k$$

dengan k konstanta sedemikian sehingga $\alpha = P(S \leq k)$. Karena $S \sim \text{BIN}(n, p_0)$ terhadap H_0 , maka k ditentukan dari $\alpha = P(S \leq k)$. Tetapi, distribusi binomial merupakan distribusi diskrit,

sehingga tidak dapat dicari nilai k yang eksak untuk menyelesaikan persamaan diatas. Sebagai contoh, misalkan $n = 20$, $p_0 = 0.7$, $\alpha = 0.15$. Maka berdasarkan H_0 , diperoleh $P(S \leq 11) = 0.1133$ dan $P(S \leq 12) = 0.2277$. Secara umum, fungsi kuasa dari uji hipotesis ini adalah


$$\beta(p) = P(S \leq k), p < p_0$$

Berdasarkan Gambar 6.2, perhatikan bahwa fungsi kuasa yang terbentuk bersifat monoton (dalam hal ini, monoton turun). Secara umum, fungsi kuasa bersifat monoton (bukti dapat dibaca pada Gilat (1977)). Menggunakan sifat kemonotonan tersebut, uji hipotesis dapat diperluas menjadi

$$H_0 : p \geq p_0 \text{ lawan } H_1 : p < p_0$$

sehingga diperoleh

$$\max_{p \geq p_0} P(S \leq k) = \alpha$$



Gambar 6.2 Kurva Fungsi Kuasa pada Contoh 6.2

Selanjutnya, diberikan definisi dari P-value sebagai berikut.

Definisi 6.5 (P-value) P-value $p(\mathbf{X})$ adalah uji statistik yang memenuhi $0 \leq p(\mathbf{x}) \leq 1$ untuk setiap titik sampel $\mathbf{x}$. Nilai kecil dari $p(\mathbf{X})$ memberikan bukti bahwa H_0 ditolak. Sebuah p-value dikatakan valid jika untuk setiap $\theta \in \Omega_0$ dan $0 \leq \alpha \leq 1$ berlaku

$$P_\theta(p(\mathbf{X}) \leq \alpha) \leq \alpha$$

Teorema 6.1 Misalkan $W(\mathbf{X})$ adalah uji statistik sedemikian sehingga nilai W memberikan bukti bahwa H_0 ditolak. Untuk setiap titik sampel $\mathbf{x}$, definisikan

$$p(\mathbf{x}) = \sup_{\theta \in \Omega_0} P_\theta(W(\mathbf{X}) \geq W(\mathbf{x}))$$

maka $p(\mathbf{X})$ adalah p -value yang valid.

Definisi 6.6 Untuk $0 \leq \alpha \leq 1$, uji dengan fungsi kuasa $\beta(\theta)$ disebut uji dengan ukuran α jika $\sup_{\theta \in \Omega_0} \beta(\theta) = \alpha$.

Contoh 6.3 (Uji rata-rata sampel besar untuk mean) Diberikan X variabel random dengan mean μ dan variansi $\sigma^2 < \infty$. Diketahui uji hipotesis

$$H_0 : \mu = \mu_0 \text{ lawan } H_1 : \mu > \mu_0$$

dengan μ_0 diketahui. Sebagai gambaran, misalkan μ_0 adalah rata-rata nilai ETS Matematika Statistika dengan metode pembelajaran standar. Dimisalkan metode baru yang melibatkan kemampuan komputasional mempunyai rata-rata nilai ETS $\mu > \mu_0$ dengan $\mu = E(X)$ dan X adalah nilai ETS mahasiswa dengan metode pembelajaran baru. Dugaan ini diuji dengan mengambil sampel mahasiswa yang diajar dengan metode baru ini secara random sebanyak n mahasiswa. Misalkan $X_1, X_2, \dots, X_n$ adalah sampel random yang berasal dari distribusi X dan mean serta variansinya masing-masing dinyatakan dalam $\bar{X}$ dan S^2 . Karena $\bar{X} \xrightarrow{P} \mu$, maka secara intuitif daerah kritiknya adalah

$$\text{Tolak } H_0 \text{ jika } \bar{X} > \mu_0$$

Karena distribusi dari sampel mean tidak dapat dicari dalam bentuk *closed form*, maka akan dicari aproksimasinya menggunakan CLT. Ingat bahwa

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \xrightarrow{d} N(0, 1)$$

Maka diperoleh uji hipotesis dengan tingkat signifikansi α dengan daerah kritik

$$\text{Tolak } H_0 \text{ jika } \frac{\bar{X} - \mu}{S/\sqrt{n}} \geq z_\alpha$$

Uji ini sangat intuitif. Untuk menolak H_0 , $\bar{X}$ harus lebih besar dari μ_0 paling sedikit $z_\alpha \frac{S}{\sqrt{n}}$, dengan aproksimasi fungsi kuasanya adalah

$$\begin{aligned}
\beta(\mu) &= P\left(\frac{\bar{X} - \mu_0}{S/\sqrt{n}} \geq z_\alpha\right) \\
&= P\left(\bar{X} \geq \mu_0 + z_\alpha \frac{S}{\sqrt{n}}\right) \\
&= P\left(\frac{\bar{X} - \mu}{S/\sqrt{n}} \geq \frac{\mu_0 - \mu}{S/\sqrt{n}} + z_\alpha\right) \\
&= 1 - P\left(\frac{\bar{X} - \mu}{S/\sqrt{n}} \leq \frac{\mu_0 - \mu}{S/\sqrt{n}} + z_\alpha\right) \\
&= 1 - \Theta\left(\frac{\mu_0 - \mu}{S/\sqrt{n}} + z_\alpha\right) \\
&= \Theta\left(-z_\alpha - \frac{\mu_0 - \mu}{S/\sqrt{n}}\right)
\end{aligned}$$

Diperoleh fungsi kuasanya adalah

$$\beta(\mu) = P\left(z \leq -z_\alpha - \frac{\mu_0 - \mu}{S/\sqrt{n}}\right)$$

Karena $\beta(\mu)$ monoton naik dalam μ , maka hipotesisnya menjadi

$$H_0 : \mu \leq \mu_0 \text{ lawan } H_1 : \mu > \mu_0$$

dengan tingkat signifikansi α .

6.3 Metode Uji Hipotesis

Pada bagian ini, terdapat dua metode uji hipotesis yang akan dibahas, yaitu uji Rasio Likelihood dan Uji Paling Kuasa (UMP).

6.3.1 Uji Rasio Likelihood

Metode rasio likelihood dalam uji hipotesis berhubungan dengan estimator likelihood maksimum dan uji tersebut secara luas dapat diterapkan. Perhatikan lagi jika $X_1, \dots, X_n$ adalah sampel random dari populasi dengan densitas $f(x|\theta)$ (θ bisa berupa vektor), maka fungsi likelihood didefinisikan sebagai berikut.

$$L(\theta|X_1, \dots, X_n) = f(\underline{x}|\theta) = \prod_{i=1}^n f(x_i|\theta)$$

Misalkan Ω menyatakan ruang parameter, maka uji rasio likelihood didefinisikan sebagai berikut.

Definisi 6.7 Uji statistik rasio likelihood untuk

$$H_0 : \theta \in \Omega_0 \text{ lawan } H_1 : \theta \in \Omega_0^c$$

adalah

$$\lambda(\underline{x}) = \frac{\sup_{\theta \in \Omega_0} L(\theta|\underline{x})}{\sup_{\theta \in \Omega} L(\theta|\underline{x})}$$

Uji rasio likelihood (likelihood ratio test) atau (LRT) adalah uji sedemikian hingga daerah penolakan mempunyai bentuk $\{\underline{X} : \lambda(\underline{X}) \leq c\}$ dengan c adalah sebarang bilangan yang memenuhi $0 \leq c \leq 1$.

Pembilang dari $\lambda(\underline{x})$ adalah probabilitas maksimum dari sampel yang diamati, yaitu maksimum yang dihitung di atas parameter dalam H_0 . Penyebut dari $\lambda(\underline{x})$ adalah probabilitas maksimum dari sampel yang diamati di atas semua parameter yang mungkin. Rasio dari dua maksimum ini kecil jika terdapat titik parameter dalam H_1 di mana sampel yang diamati jauh lebih mungkin daripada titik parameter mana pun dalam H_0 . Dalam situasi ini, kriteria LRT mengatakan bahwa H_0 harus ditolak dan H_1 diterima.

Misalkan $\hat{\theta}$ adalah MLE dari θ dengan ruang parameter Ω dan $\hat{\theta}_0$ adalah MLE dari θ dengan ruang parameter Ω_0 . Persamaan uji statistik rasio likelihood pada Definisi 6.7 dapat ditulis ulang menjadi

$$\lambda(\underline{x}) = \frac{L(\hat{\theta}_0|\underline{x})}{L(\hat{\theta}|\underline{x})}$$

Untuk lebih memahami penggunaan dari uji rasio likelihood, perhatikan contoh berikut.

Contoh 6.4 (Uji Rasio Likelihood - Distribusi Normal) Diberikan $X_1, \dots, X_n$ sampel random iid dengan $X_i \sim N(\theta, 1)$. Misalkan dilakukan uji hipotesis

$$H_0 : \theta = \theta_0 \text{ lawan } H_1 : \theta \neq \theta_0$$

dengan θ_0 adalah nilai yang ditentukan oleh peneliti sebelum eksperimen dilakukan. Ingat kembali bahwa MLE dari θ adalah $\bar{x}$ (**Buktikan!**). Maka diperoleh uji statistik LRT nya adalah

$$\begin{aligned} \lambda(\underline{x}) &= \frac{(2\pi)^{-n/2} \exp \left[\frac{-\sum_{i=1}^n (x_i - \theta_0)^2}{2} \right]}{(2\pi)^{-n/2} \exp \left[\frac{-\sum_{i=1}^n (x_i - \bar{x})^2}{2} \right]} \\ &= \exp \left(\frac{\left[-\sum_{i=1}^n (x_i - \theta_0)^2 + \sum_{i=1}^n (x_i - \bar{x})^2 \right]}{2} \right). \end{aligned}$$

Selanjutnya, perhatikan bahwa

$$\sum_{i=1}^n (x_i - \theta_0)^2 = \sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - \theta_0)^2$$

Diperoleh daerah kritik C dari uji tersebut adalah

$$\begin{aligned}
C &= \{X : \lambda(\underline{x}) \leq c\} \\
&= \left\{ \exp \left(\frac{-n(\bar{x} - \theta_0)^2}{2} \right) \leq c \right\} \\
&= \left\{ \frac{-n(\bar{x} - \theta_0)^2}{2} \leq c_1 \right\} \text{ dengan } c_1 = \log c \\
C &= \{n(\bar{x} - \theta_0)^2 \geq c_2\} \text{ dengan } c_2 = -2c_1
\end{aligned}$$

Ingat kembali bahwa jika $X_i \sim N(\theta, 1)$, maka $n(\bar{x} - \theta_0)^2 \sim \chi_{(1)}^2$, sehingga daerah kritiknya adalah

$$\text{Tolak } H_0 \text{ jika } n(\bar{x} - \theta_0)^2 > \chi_{(1, \alpha)}^2$$

dengan tingkat signifikansi α . Secara ekuivalen, daerah kritik yang lain adalah $C = \{\sqrt{n}(\bar{x} - \theta_0) > \sqrt{c_2}\}$ atau $C = \{\sqrt{n}(\bar{x} - \theta_0) < -\sqrt{c_2}\}$, sehingga daerah kritiknya adalah

$$\text{Tolak } H_0 \text{ jika } \sqrt{n}(\bar{x} - \theta_0) > z_{\frac{\alpha}{2}} \text{ atau } \sqrt{n}(\bar{x} - \theta_0) < -z_{\frac{\alpha}{2}}$$

dengan tingkat signifikansi α .

6.3.2 Uji Paling Kuasa

Berikut adalah definisi dari uji paling kuasa (*Uniformly Most Powerful Test/UMP*).

Definisi 6.8 Uji hipotesis dengan fungsi kuasa $\beta(\theta)$ adalah uji paling kuasa (*Uniformly Most Powerful Test/UMP*) jika untuk setiap $\theta \in \Omega_0^c$ dan untuk setiap uji dengan fungsi kuasa $\beta'(\theta)$ berlaku $\beta(\theta) \geq \beta'(\theta)$.

Syarat pada Definisi 6.8 cukup kuat sehingga uji UMP tidak ada di permasalahan yang umum. Namun pada permasalahan yang mempunyai uji UMP, uji UMP dapat dipandang sebagai uji terbaik. Oleh karena itu, perlu diselidiki apakah pada suatu permasalahan uji hipotesis dapat ditemukan uji UMP atau tidak.

Teorema 6.2 (Lemma Neyman-Pearson) Pandang uji hipotesis $H_0 : \theta = \theta_0$ lawan $H_1 : \theta = \theta_1$ dengan pdf atau pmf yang bersesuaian dengan θ_i adalah $f(\underline{x}|\theta_i)$, $i = 0, 1$. Dengan menggunakan uji hipotesis dengan daerah kritik C yang memenuhi

$$\underline{x} \in C \text{ jika } f(\underline{x}|\theta_1) > k f(\underline{x}|\theta_0) \quad (6.1)$$

atau

$$\underline{x} \in C^c \text{ jika } f(\underline{x}|\theta_1) < k f(\underline{x}|\theta_0) \quad (6.2)$$

untuk suatu $k \geq 0$ dan $\alpha = P_{\theta_0}(\underline{X} \in C)$. Maka

1. (Syarat perlu) Setiap uji yang memenuhi Persamaan 6.1 dan 6.2 adalah uji UMP dengan tingkat signifikansi α .

2. (Syarat cukup) Jika terdapat uji yang memenuhi 6.1 dan 6.2 dengan $k > 0$, maka setiap uji UMP dengan tingkat signifikansi α adalah uji hipotesis dengan tingkat signifikansi α (memenuhi 6.2) dan setiap uji UMP dengan tingkat signifikansi α yang memenuhi 6.1 kecuali mungkin pada himpunan A yang memenuhi $P_{\theta_0}(\underline{X} \in A) = P_{\theta_1}(\underline{X} \in A) = 0$.

Catatan 6.1 Untuk mencari uji UMP dengan tingkat signifikansi α , akan lebih mudah untuk menulis ulang Persamaan 6.1 menjadi

$$\frac{f(\underline{x}|\theta_1)}{f(\underline{x}|\theta_0)} > k$$

Untuk mempermudah pemahaman terkait dengan uji UMP, perhatikan contoh berikut.

Contoh 6.5 Diberikan $X_1, \dots, X_n$ sampel random iid dengan $X_i \sim EXP(\theta)$. Misalkan dilakukan uji hipotesis

$$H_0 : \theta = \theta_0 \text{ lawan } H_1 : \theta = \theta_1$$

dengan $\theta_1 > \theta_0$. Ingat kembali bahwa PDF dari X_i adalah

$$f(x_i|\theta) = \frac{1}{\theta} e^{-\frac{x_i}{\theta}}, x > 0; \theta > 0$$

Diperoleh

$$\begin{aligned} f(\underline{x}|\theta) &= \frac{1}{\theta^n} e^{-\frac{\sum x_i}{\theta}} \\ \frac{f(\underline{x}|\theta_1)}{f(\underline{x}|\theta_0)} &= \frac{\frac{1}{\theta_1^n} e^{-\frac{\sum x_i}{\theta_1}}}{\frac{1}{\theta_0^n} e^{-\frac{\sum x_i}{\theta_0}}} \\ &= \left(\frac{\theta_0}{\theta_1}\right)^n e^{\sum x_i \left(\frac{1}{\theta_0} - \frac{1}{\theta_1}\right)} \end{aligned}$$

Selanjutnya,

$$\begin{aligned} \left(\frac{\theta_0}{\theta_1}\right)^n e^{\sum x_i \left(\frac{1}{\theta_0} - \frac{1}{\theta_1}\right)} &> k \\ e^{\sum x_i \left(\frac{1}{\theta_0} - \frac{1}{\theta_1}\right)} &> k_1 \text{ dengan } k_1 = k \left(\frac{\theta_1}{\theta_0}\right)^n \\ \sum x_i \left(\frac{1}{\theta_0} - \frac{1}{\theta_1}\right) &> k_2 \text{ dengan } k_2 = \ln k_1 \\ \sum x_i &> k_3 \text{ dengan } k_3 = \frac{k_2}{\left(\frac{1}{\theta_0} - \frac{1}{\theta_1}\right)} \end{aligned}$$

Maka diperoleh daerah kritik $C = \{\sum x_i > k_3\}$, dengan k_3 dipilih sedemikian sehingga $P(\underline{X} \in C | \theta = \theta_0) = P(\sum x_i > k_3 | \theta = \theta_0) = \alpha$. Diperoleh

$$P\left(\sum x_i > k_3 | \theta = \theta_0\right) = \alpha$$

$$P(\bar{x} > k_4 | \theta = \theta_0) = \alpha \text{ dengan } k_4 = \frac{K - 3}{n}$$

$$P\left(\frac{\bar{x} - \theta_0}{\theta_0/\sqrt{n}} > \frac{k_4 - \theta_0}{\theta_0/\sqrt{n}}\right) = \alpha$$

$$\frac{k_4 - \theta_0}{\theta_0/\sqrt{n}} = z_\alpha$$

Jadi, diperoleh hampiran daerah kritik uji UMP dari uji hipotesis ini adalah

$$C = \left\{ \frac{\bar{x} - \theta_0}{\theta_0/\sqrt{n}} > z_\alpha \right\}$$

Selanjutnya, untuk mendapatkan daerah kritik eksak dari uji UMP tersebut, perhatikan bahwa untuk $X \sim EXP(\theta)$, diperoleh $M_X(t) = \frac{1}{(1-\theta t)}$. Lebih lanjut, untuk $X \sim GAM(\alpha, \beta)$, dengan $f(x|\alpha, \beta) = \frac{e^{-\frac{x}{\beta}} x^{\alpha-1}}{\Gamma(\alpha)\beta^\alpha}$, diperoleh $M_X(t) = \frac{1}{(1-\beta t)^\alpha}$. Kemudian, jika $Y = \frac{2\sum X_i}{\theta}$ dengan $X_i \sim EXP(\theta)$, maka $Y \sim \chi^2_{(2n)}$ (**Buktikan!**). Akibatnya, diperoleh

$$C = \left\{ \sum x_i > k_3 \right\} \sim C = \left\{ \frac{2\sum x_i}{\theta} > \frac{2k_3}{\theta} \right\}$$

Jadi, daerah kritik eksak uji UMP dari uji hipotesis tersebut adalah

$$\text{Tolak } H_0 \text{ jika } \frac{2\sum x_i}{\theta} > \chi^2_{(2n)}.$$

Latihan Soal

6.1 Diketahui sebuah kotak berisi 4 kelereng, dengan θ kelereng berwarna putih dan $4 - \theta$ kelereng berwarna hitam. Dilakukan uji hipotesis

$$H_0 : \theta = 2 \text{ lawan } H_1 : \theta \neq 2$$

dengan pengujian sebagai berikut: Ambil dua kelereng dengan pengembalian dan tolak H_0 jika kedua kelereng memiliki warna yang sama.

- Hitunglah probabilitas error Tipe I.
- Hitunglah probabilitas error Tipe II untuk semua kasus.
- Kerjakan ulang bagian (a) dan (b) dimana dua kelereng tersebut diambil tanpa pengembalian.

6.2 Diberikan sampel random berukuran 20 berdistribusi normal, $X_1 \sim N(\mu, \sigma^2)$ dan misalkan $\bar{x} = 11$ dan $s^2 = 16$.

(a) Misal diketahui $\sigma^2 = 4$, lakukan uji hipotesis

$$H_0 : \mu \geq 12 \text{ lawan } H_1 : \mu < 12$$

dengan tingkat signifikansi $\alpha = 0.01$.

(b) Hitung probabilitas kesalahan tipe II jika $\mu = 10.5$.

(c) Tentukan jumlah sampel yang diperlukan agar probabilitas fungsi kuasa dengan nilai $\mu = 10.5$ adalah 0.9.

(d) Kerjakan ulang bagian (a) dengan memisalkan σ^2 tidak diketahui nilainya.

6.3 Diberikan sampel random berukuran 25 berdistribusi normal dengan mean θ dan variansi 4. Dilakukan uji hipotesis

$$H_0 : \theta = 0 \text{ lawan } H_1 : \theta > 0$$

dengan daerah kritik: Tolak H_0 jika $\bar{x} < 0.6$. Tentukan fungsi kuasa $\beta(\theta)$, $0 \leq \theta$ untuk uji hipotesis ini.

6.4 Diberikan sampel random berukuran 25 berdistribusi normal dengan mean θ dan variansi 100. Dilakukan uji hipotesis

$$H_0 : \theta = 75 \text{ lawan } H_1 : \theta > 75$$

Tentukan uji paling kuasa (UMP test) dari uji hipotesis tersebut.

6.5 Diberikan $X_1, \dots, X_n$ sampel random berukuran $n = 1, 4, 16, 64, 100$ berdistribusi normal dengan mean μ dan variansi σ^2 diketahui. Dilakukan uji hipotesis

$$H_0 : \mu \leq 0 \text{ lawan } H_1 : \mu > 0$$

dengan tingkat signifikansi $\alpha = 0.05$. Gambarkan fungsi kuasa uji rasio likelihood dari uji hipotesis untuk masing-masing ukuran sampel.

6.6 Diberikan $X_1, \dots, X_n$ sampel random dari suatu distribusi dengan PMF

$$p(x|\theta) = \frac{\left[\frac{\theta}{\theta+1}\right]^x}{\theta+1}, x = 0, 1, \dots \text{ dan } \theta > 0$$

Carilah uji paling kuasa dari uji hipotesis tersebut.

$$H_0 : \theta = \theta_0 \text{ lawan } H_1 : \theta > \theta_0$$

6.7 Diberikan $X_1, \dots, X_n$ sampel random dari suatu distribusi dengan PMF

$$p(x|\theta) = \theta^x (1 - \theta)^{1-x}, x = 0, 1$$

Dilakukan uji hipotesis

$$H_0 : \theta = 0.05 \text{ lawan } H_1 : \theta > 0.05$$

Gunakan Teorema Limit Pusat untuk menentukan jumlah sampel yang dibutuhkan agar uji paling kuasa dari uji hipotesis tersebut mempunyai fungsi kuasa $\beta(\theta)$ sedemikian sehingga $\beta(0.05) = 0.05$ dan $\beta(0.1) = 0.9$.

6.8 Diberikan $X_1, \dots, X_n$ sampel random berdistribusi normal dengan mean θ dan variansi $a\theta$ dengan θ tidak diketahui. Dilakukan uji hipotesis

$$H_0 : a = 1 \text{ lawan } H_1 : a \neq 1$$

Carilah uji rasio likelihood dari uji hipotesis tersebut.

6.9 Diberikan $X_1, \dots, X_n$ sampel random dari suatu distribusi dengan PDF

$$f(x|\theta) = \frac{1}{\theta}, 0 \leq x \leq \theta$$

Dilakukan uji hipotesis

$$H_0 : \theta = \theta_0 \text{ lawan } H_1 : \theta \neq \theta_0$$

Carilah uji rasio likelihood dari uji hipotesis tersebut.

6.10 Diberikan $Y_1 < Y_2 < \dots < Y_5$ adalah order statistics dari sampel random berukuran 5 dari suatu distribusi dengan PDF

$$f(x|\theta) = \frac{1}{2}e^{-|x-\theta|}, -\infty < x < \infty$$

untuk semua $\theta \in \mathbb{R}$. Dilakukan uji hipotesis

$$H_0 : \theta = \theta_0 \text{ lawan } H_1 : \theta \neq \theta_0$$

Carilah uji rasio likelihood dari uji hipotesis tersebut.

Daftar Pustaka

- [1] Bain, L.J. and Engelhardt, M. (1992). *Introduction to Probability and Mathematical Statistics* (2nd ed). Duxbury Press.
- [2] Casella, G. and Berger, R. L. (2002). *Statistical Inference* (2nd ed). Brooks/Cole Cengage Learning.
- [3] Hogg, R. V., McKean, J. W., and Craig, A. T. (2019). *Introduction to Mathematical Statistics* (8th ed). Pearson.
- [4] Bazzara, M. S., Sherali, H. D., and Shetty, C. M. (2006). *Nonlinear Programming* (3rd ed). Wiley-Interscience.

Lampiran A

Tabel Distribusi Khusus

Nama Distribusi	Notasi dan Parameter	PDF (atau PMF)	Mean	Variansi	MGF
Bernoulli	$X \sim BIN(1, p)$ $0 < p < 1$	$p^x(1-p)^{1-x}$ $x = 0, 1$	p	$p(1-p)$	$pe^t + 1 - p$
Binomial	$X \sim BIN(n, p)$ $0 < p < 1$	$\binom{n}{x} p^x (1-p)^{n-x}$ $x = 0, 1, \dots, n$	np	$np(1-p)$	$(pe^t + 1 - p)^n$
Geometrik	$X \sim GEO(p)$ $0 < p < 1$	$p(1-p)^x$ $x = 0, 1, 2, \dots$	$\frac{1-p}{p}$	$\frac{1-p}{p^2}$	$p[1 - (1-p)e^t]^{-1}$
Binomial Negatif	$X \sim NB(r, p)$ $0 < p < 1, r = 1, 2, \dots$	$\binom{x+r-1}{r-1} p^r (1-p)^x$ $x = 0, 1, 2, \dots$	$\frac{r(1-p)}{p}$	$\frac{r(1-p)}{p^2}$	$p^r [1 - (1-p)e^t]^{-r}$
Poisson	$X \sim POI(\lambda)$ $\lambda > 0$	$\frac{e^{-\lambda} \lambda^x}{x!}$ $x = 0, 1, 2, \dots$	λ	λ	$e^{\lambda(e^t - 1)}$
Uniform	$X \sim UNIF(a, b)$ $b > a$	$\frac{1}{b-a}$ $a < x < b$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$	$\frac{e^{bt} - e^{at}}{(b-a)t}$
Normal	$X \sim N(\mu, \sigma^2)$ $\sigma^2 > 0$	$\frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$ $-\infty < x < \infty$	μ	σ^2	$\exp(\mu t + \frac{1}{2}\sigma^2 t^2)$
Gamma	$X \sim GAM(\alpha, \beta)$ $\alpha > 0, \beta > 0$	$\frac{x^{\alpha-1} e^{-x/\beta}}{\Gamma(\alpha)\beta^\alpha}$ $x > 0$	$\alpha\beta$	$\alpha\beta^2$	$(1 - \beta t)^{-\alpha}$

Pembahasan Soal

Latihan Soal Bab 1

1.1 The solution is revealed here.

1.2 Problem Heading

(a) The solution of first part is revealed here.

(b) The solution of second part is revealed here.